BAYESIAN BELIEF NETWORKS

(Bayes İnanç Ağları)

Ders Notu

2026

1. Giriş ve Tanım

Bayesian Belief Network (BBN), yani Bayes İnanç Ağı, rastgele değişkenler (random variables) arasındaki koşullu bağımlılıkları **Yönlü Çevrimsiz Çizge (Directed Acyclic Graph - DAG)** yapısı ile ifade eden olasılık tabanlı bir grafiksel modeldir (*Probabilistic Graphical Model - PGM*).

Bir BBN iki temel bileşenden oluşur:

- **Düğümler (Nodes):** Her bir düğüm bir rastgele değişkeni temsil eder. Bu değişkenler ayrık (discrete) veya sürekli (continuous) olabilir. Örneğin "Hava Durumu", "Mevsim", "Yağmur" gibi değişkenler birer düğüm olarak modellenir.
- **Kenarlar (Edges):** Düğümler arasındaki yönlü bağlantılardır. Bir kenar, iki değişken arasındaki bağımlılık (dependency) ilişkisini gösterir. Örneğin A düğümünden B düğümüne giden bir kenar, B'nin A'ya bağımlı olduğunu ifade eder; bu durumda A, B'nin "ebeveyn düğümü" (parent node) olarak adlandırılır.

DAG yapısının en önemli özelliği çevrim (cycle) içermemesidir; yani bir düğümden çıkılarak aynı düğüme geri dönülemez. Bu özellik, ağdaki olasılıksal hesaplamaların tutarlı bir şekilde yapılabilmesini sağlar.

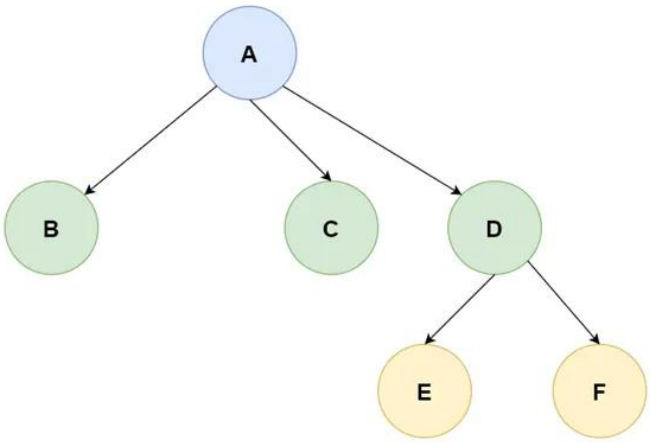

Şekil 1: Örnek bir DAG yapısı (A, B, C, D, E, F düğümleri)

Yukarıdaki şekilde A düğümünden B, C ve D'ye giden kenarlar, bu değişkenlerin A'ya bağımlı olduğunu gösterir. Benzer şekilde D düğümünden E ve F'ye giden kenarlar, E ve F'nin D'ye bağımlı olduğunu ifade eder.

Aşağıda daha karmaşık bir BBN örneği görülmektedir. Bu ağda Season (Mevsim), Atmospheric Pressure (Atmosferik Basınç) gibi üst düğümler, Rain (Yağmur), Allergies (Alerji) gibi ara düğümleri etkilerken, bunlar da Grass (Çim), Umbrellas (Şemsiye), Dog Bark (Köpek Havlama) gibi alt düğümleri etkilemektedir:

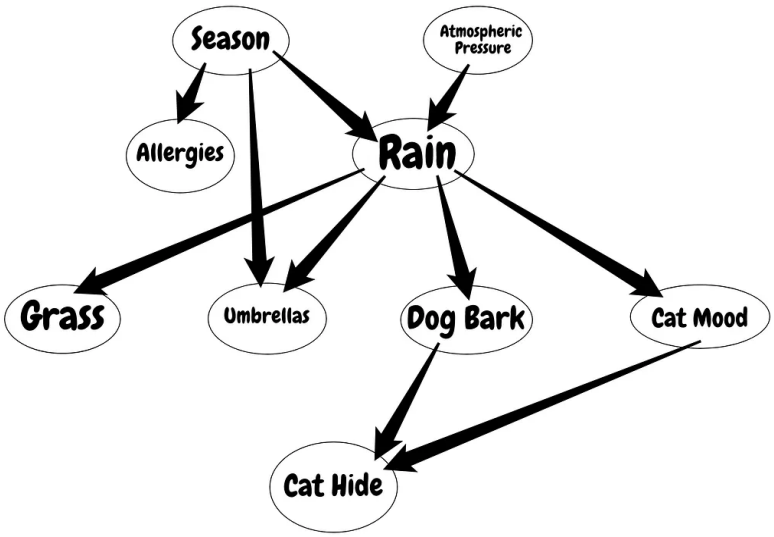

Şekil 2: Örnek Bayesian Belief Network gösterimi

2. BBN ve Naive Bayes Karşılaştırması

Naive Bayes ve Bayesian Belief Networks her ikisi de Bayes teoremine dayanan olasılıksal modellerdir; ancak aralarında temel bir fark vardır.

Naive Bayes yönteminde tüm değişkenler (features) birbirinden bağımsız olarak değerlendirilir. Değişkenler arasındaki ilişkiler ve korelasyonlar dikkate alınmaz. Örneğin bir spam filtresi tasarımında her kelimenin bağımsız olarak spam olasılığına katkısı hesaplanır; kelimeler arası ilişkiler göz ardı edilir.

Bayesian Belief Network ise Naive Bayes'e ek olarak değişkenler arası bağımlılık durumlarını da modelleyebilir. DAG yapısı sayesinde hangi değişkenlerin hangi değişkenlere bağımlı olduğu açıkça ifade edilir.

Ancak bu avantajın bir bedeli vardır: değişkenler arasındaki ilişkileri gösteren DAG yapısını oluşturma süreci, problemin büyüklüğüne göre oldukça zorlayıcı olabilir ve alan uzmanlığı (domain expertise) gerektirebilir.

Özellik	Naive Bayes	Bayesian Belief Network
Değişken bağımlılığı	Tüm değişkenler bağımsız varsayılır	Değişkenler arası bağımlılıklar modellenebilir
Model yapısı	Basit, düz yapı	DAG (Yönlü Çevrimsiz Çizge)
Uygulama kolaylığı	Kolay ve hızlı	Daha karmaşık, alan uzmanlığı gerektirebilir
Doğruluk	Bağımsızlık varsayımı nedeniyle sınırlı	Gerçek dünya ilişkilerini daha iyi yansıtır

Tablo 1: Naive Bayes ve BBN Karşılaştırması

3. Olasılık Temelleri

BBN'leri anlamak için öncelikle koşullu olasılık (conditional probability) kavramının iyi bilinmesi gerekmektedir.

3.1 Koşullu Olasılık

Koşullu olasılık, bir rastgele değişkenin başka bir rastgele değişkenin değeri verildiğinde aldığı olasılıktır. Gösterimi:

$$P(X \mid Y)$$

(X'in Y verildiğindeki koşullu olasılığı)

3.2 Bağımlı Değişkenler

Eğer iki rastgele değişken birbirine bağımlı ise, koşullu olasılık şu şekilde hesaplanır:

$$P(X \mid Y) = P(X, Y) / P(Y)$$

Burada P(X, Y) birleşik olasılık (joint probability), P(Y) ise Y'nin marjinal olasılığıdır.

3.3 Bağımsız Değişkenler

Eğer iki rastgele değişken birbirinden bağımsız ise, Y'nin değeri X'in olasılığını değiştirmez:

$$P(X \mid Y) = P(X)$$

Bu durumda X ve Y arasında herhangi bir istatistiksel ilişki yoktur.

4. BBN'in Matematiksel Tanımı

4.1 Birleşik Olasılık Dağılımı (Joint Probability)

Bir Bayes ağındaki olasılıklar, birleşik olasılık dağılımı üzerinden hesaplanır. Örneğin üç değişkenli basit bir ağ için:

$$P(A, B, C) = P(A) \times P(B \mid A) \times P(C \mid A)$$

Burada P(B|A) ifadesi, B'nin ebeveyn düğümü (parent node) olan A'ya bağımlılığını yani koşullu olasılığını ifade etmektedir.

4.2 Genel Formül

N adet değişken içeren genel bir Bayes ağı için birleşik olasılık dağılımı şu şekilde ifade edilir:

$$P(X_1, X_2, ..., X_n) = \prod P(X_i \mid \text{Parents}(X_i)) \quad (i = 1, 2, ..., N)$$

Bu formüle göre, herhangi bir değişkenin olasılığı yalnızca ebeveyn düğümlerine (parents) bağlıdır. Bu özellik, hesaplama karmaşıklığını önemli ölçüde azaltır.

4.3 Koşullu Olasılık Tablosu (CPT)

DAG üzerindeki her düğüm, bir koşullu olasılık tablosuna (Conditional Probability Table - CPT) sahiptir. CPT, bir değişkenin ebeveyn değişkenlerinin tüm olası değer kombinasyonları için koşullu olasılıkları içerir.

Olasılık değerleri kullanılarak ağ üzerinde çıkarım (inference) yapılmaktadır. Bu sayede gözlemlenen kanıtlara (evidence) dayanarak bilinmeyen değişkenlerin olasılıkları hesaplanabilir.

5. Uygulama Alanları

Bayesian Belief Networks, nedensellik ilişkilerinin (causality relations) yapısını anlamayı amaçlayan birçok farklı alanda başarıyla uygulanmaktadır:

- **Tıbbi Teşhis:** Semptomlar ve hastalıklar arasındaki ilişkileri modelleyerek, yeni bir hastanın belirtilerine dayanarak olası hastalıkların olasılıklarını hesaplamak için kullanılır.
- **Spam Filtreleme:** E-posta içeriklerindeki kelimeler ve özellikler arasındaki bağımlılıkları dikkate alarak spam tespiti yapmak için kullanılır.
- **Gen Düzenleme Ağları:** Genlerin birbirleri üzerindeki etkilerini ve düzenleme mekanizmalarını modellemek için kullanılır.
- **Web Arama Optimizasyonu:** Kullanıcı sorguları ve sonuçlar arasındaki ilişkileri anlamak için kullanılır.
- **Sosyal Ağ Analizi (SNA):** Sosyal ağlardaki düğümlerin önemini, liderlik potansiyelini ve grup üyelik olasılıklarını belirlemek için kullanılır.
- **Risk Değerlendirmesi:** Farklı risk faktörleri arasındaki bağımlılıkları modelleyerek karar destek sistemleri oluşturmak için kullanılır.

6. Hesaplama Örneği: Hava Durumu Senaryosu

Bu bölümde, Bayes ağlarının nasıl çalıştığını somut bir örnek üzerinden göstereceğiz.

6.1 Ağ Yapısı ve CPT Tabloları

Aşağıdaki şekilde hava durumu senaryosunun DAG yapısı ve her düğüme ait koşullu olasılık tabloları (CPT) görülmektedir:

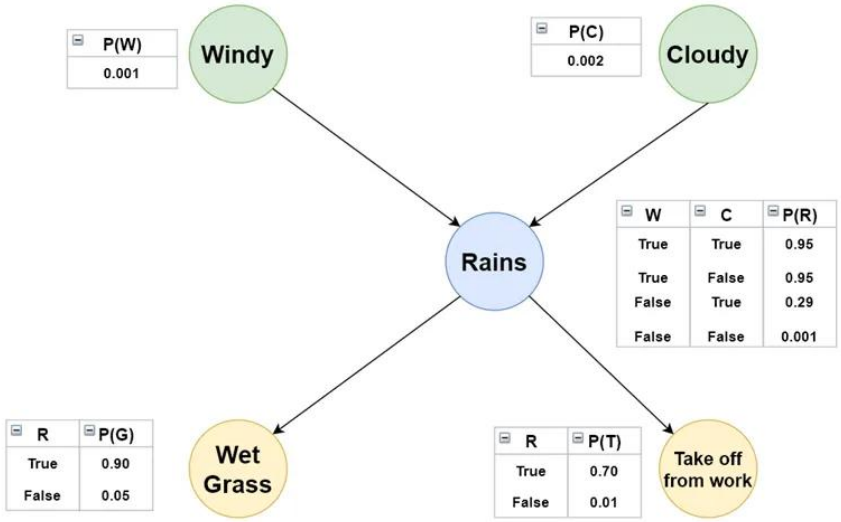

Şekil 3: Hava durumu senaryosu DAG yapısı ve olasılık tabloları

Bu ağda Windy (Rüzgarlı) ve Cloudy (Bulutlu) üst düğümlerdir ve kendi önceki (prior) olasılıklarına sahiptirler: P(W) = 0.001, P(C) = 0.002. Rains (Yağmur) düğümü bu iki değişkene bağımlıdır. Wet Grass (Çim Islak) ve Take off from work (Mola) ise Rains düğümüne bağımlıdır.

6.2 P(R) Hesaplaması: Yağmur Yağma Olasılığı

Yağmur yağma olasılığını hesaplamak için, Rains düğümünün ebeveynleri olan Windy ve Cloudy'nin tüm olası değer kombinasyonları üzerinden toplam olasılık hesaplanır:

$$
\begin{aligned}
P(R) = {} & P(R \mid W, C) * P(W) * P(C) \; + \\
& P(R \mid \bar{W} C) * P(\bar{W}) * P(C) \; + \\
& P(R \mid W, \bar{C}) * P(W) * P(\bar{C})) + \\
& P(R \mid \bar{W} \bar{C}) * P(\bar{W}) * P(\bar{C}))
\end{aligned}
$$

$$
\begin{aligned}
P(R) = {} & 0.95 * 0.001 * 0.002 + \\
& 0.29 * 0.999 * 0.002 + \\
& 0.95 * 0.001 * 0.998 + \\
& 0.001 * 0.999 * 0.998
\end{aligned}
$$

Şekil 4: P(R) hesaplaması

$$\mathbf{P(R) = 0.00252}$$

Benzer şekilde yağmur yağmama olasılığı: P(¬R) = 1 - 0.00252 = 0.99748

6.3 P(G) Hesaplaması: Çimin Islak Olma Olasılığı

Wet Grass düğümünün ebeveyn düğümü Rains olduğu için, P(G) hesaplaması aşağıdaki gibidir:

$$P(G) = P(G \mid R) * P(R) + P(G \mid \bar{R}) * P(\bar{R})$$

$$= 0.9 * P(R) + 0.05 * P(\bar{R})$$

$$P(R) = 0.00252$$

$$P(\bar{R}) = 0.99744$$

$$P(G) = 0.0521 \text{ olarak hesaplanır.}$$

Şekil 5: P(G) hesaplaması ve sonucu

Sonuç: Rüzgarlı ve bulutlu olma olasılıkları çok düşük olduğundan, yağmur yağma olasılığı da düşük çıkmaktadır. Buna bağlı olarak çimin ıslak olma olasılığı da düşük çıkmaktadır (P(G) = 0.0521). Bu hesaplama, BBN'in nedensellik zincirini matematiksel olarak takip edebildiğini göstermektedir.

6.4 Bayesian Inference ile Ters Çıkarım

Şimdiye kadar P(R) ve P(G) hesaplamalarını yaptık. Bunlar gerekli olmakla birlikte asıl amaç değildir. Asıl amaç: **gözlem geldikten sonra inancı güncellemektir.**

Problem: Çimenin ıslak olduğunu gözlemliyoruz. Acaba yağmur yağmış mıdır? Yani P(R | G) nedir?

Elimizdeki bilgiler: P(R) = 0.00252, P(¬R) = 0.99748, P(G | R) = 0.9, P(G | ¬R) = 0.05, P(G) = 0.0521

Bayes Formülü:

$$P(R \mid G) = P(G \mid R) \times P(R) / P(G)$$

Adım 1 - Pay (numerator):

$$P(G \mid R) \times P(R) = 0.9 \times 0.00252 = 0.002268$$

Adım 2 - Payda (denominator):

$$P(G) = 0.0521$$

Adım 3 - Sonuç:

$$P(R \mid G) = 0.002268 / 0.0521 \approx 0.0435$$

Sonuç Yorumu

Öncesinde yağmur yağma olasılığı P(R) = 0.00252, yani yaklaşık %0.25 idi. Çimenin ıslak olduğu gözlemlendikten sonra bu olasılık P(R | G) ≈ 0.0435, yani yaklaşık %4.35'e yükseldi. **Çimenin ıslak olması, yağmur ihtimalini yaklaşık 17 kat artırdı.**

Ancak olasılık hala düşüktür. Çünkü yağmur başlangıçta çok nadir bir olay olarak tanımlanmıştı ve ıslaklık başka sebeplerden de kaynaklanabilir.

Aynı mantıkla: Yağmur yok mu?

$$P(\neg R \mid G) = 1 - P(R \mid G) = 1 - 0.0435 = 0.9565$$

Yani: **Çimen ıslaksa %95.65 ihtimalle yağmur yağmamıştır.**

BBN'in Gücü: Ters Çıkarım

Bu örnek şunu net gösterir: Modelde ileri yönlü ilişki R → G (yağmur çimi ıslatır) şeklindedir. Ama gerçek kullanımda G → R (çim ıslak, yağmur yağdı mı?) şeklinde ters çıkarım yapılır. BBN'in asıl gücü buradadır.

Genel Form

Herhangi bir gözlem E ve hipotez H için:

$$P(H \mid E) = P(E \mid H) \times P(H) / P(E)$$

Burada H hipotezi (örneğin Rain), E ise gözlemi (örneğin Wet Grass) temsil eder.

Özet

Grafik yapısı bağımlılıkları tanımlar. Koşullu Olasılık Tablosu (CPT) yerel olasılıkları verir. Toplam olasılık global dağılımı üretir. **Bayes formülü ise gözlemle inancı günceller.**

Bayesian Belief Network, olasılıkları hesaplamak için değil, gözlem geldikten sonra doğru kararı vermek için vardır.

7. Python ile BBN Uygulaması: Hava Durumu Senaryosu

Bu bölümde, Şekil 3'teki hava durumu senaryosu `pybbn` kütüphanesi ile Python'da adım adım gerçekleştireceğiz. Elle yapılan hesaplamaların pybbn sonuçlarıyla örtüştüğünü doğrulayacağız.

7.1 Kurulum ve Import

```
!pip install pybbn networkx matplotlib
from pybbn.graph.dag import Bbn
from pybbn.graph.edge import Edge, EdgeType
from pybbn.graph.jointree import EvidenceBuilder
from pybbn.graph.node import BbnNode
from pybbn.graph.variable import Variable
from pybbn.pptc.inferencecontroller import InferenceController
from pybbn.generator.bbngenerator import convert_for_drawing
import networkx as nx
```

7.2 Düğümlerin Tanımlanması

Her düğüm bir `BbnNode` nesnesi olarak tanımlanır. Kök düğümler için doğrudan önceki olasılık (prior probability), ara ve yaprak düğümler için ise ebeveyn kombinasyonlarına göre koşullu olasılık tablosu (CPT) verilir. Olasılık değerleri her zaman [P(True), P(False)] sırasıyla girilir.

```
# KÖK DÜĞÜMLER (Ebeveyn düğümü yok)
# Windy: P(W=True)=0.001, P(W=False)=0.999
windy = BbnNode(Variable(0, 'Windy', ['true', 'false']), [0.001, 0.999])
# Cloudy: P(C=True)=0.002, P(C=False)=0.998
cloudy = BbnNode(Variable(1, 'Cloudy', ['true', 'false']), [0.002, 0.998])
# ARA DÜĞÜM: Rains - Windy ve Cloudy'ye bağımlı
#   W=T, C=T -> P(R=T)=0.95  |  W=T, C=F -> P(R=T)=0.95
#   W=F, C=T -> P(R=T)=0.29  |  W=F, C=F -> P(R=T)=0.001
rains = BbnNode(Variable(2, 'Rains', ['true', 'false']),
  [0.95, 0.05, 0.95, 0.05, 0.29, 0.71, 0.001, 0.999])
# YAPRAK DÜĞÜMLER
wet_grass = BbnNode(Variable(3, 'WetGrass', ['true', 'false']),
  [0.90, 0.10, 0.05, 0.95])
take_off = BbnNode(Variable(4, 'TakeOff', ['true', 'false']),
  [0.70, 0.30, 0.01, 0.99])
```

7.3 Ağın Oluşturulması

Düğümler eklendikten sonra Şekil 3'teki DAG yapısına uygun kenarlar (edges) tanımlanır: Windy → Rains, Cloudy → Rains, Rains → WetGrass, Rains → TakeOff.

```
bbn = Bbn() \
  .add_node(windy).add_node(cloudy).add_node(rains) \
  .add_node(wet_grass).add_node(take_off) \
  .add_edge(Edge(windy, rains, EdgeType.DIRECTED)) \
```

```
  .add_edge(Edge(cloudy, rains, EdgeType.DIRECTED)) \
  .add_edge(Edge(rains, wet_grass, EdgeType.DIRECTED)) \
  .add_edge(Edge(rains, take_off, EdgeType.DIRECTED))
# Cikti: Düğüm sayısı: 5, Kenar sayısı: 4
```

7.4 P(R) Hesaplaması ve pybbn Karşılaştırması

Toplam olasılık formülü kullanılarak P(R) hem elle hesaplanır, hem de pybbn için önceki olasılıklar (prior) çıktısıyla doğrulanır:

```
# Elle hesaplama
P_R = (0.95*0.001*0.002 + 0.29*0.999*0.002
  + 0.95*0.001*0.998 + 0.001*0.999*0.998)
# pybbn ile prior olasılıklar
join_tree = InferenceController.apply(bbn)
for node in join_tree.get_bbn_nodes():
  print(join_tree.get_bbn_potential(node))
```

Çıktı:

```
P(R=true)  = 0.00253
P(R=false) = 0.99747
P(G=true)  = 0.05215  (WetGrass)
P(T=true)  = 0.01174  (TakeOff)
```

7.5 Bayesian Inference: P(R|G) - Ters Çıkarım

Çimin ıslak olduğunu gözlemlediğimizde (WetGrass=true), yağmur yağma olasılığı nasıl güöncellenir? Şimdi pybbn'e bu kanıtı ekleyip Bayes formülü sonuçlarını doğrulayacağız:

```
# Kanet: WetGrass = true (çim ıslak)
join_tree_ev = InferenceController.apply(bbn)
ev_grass = EvidenceBuilder() \
  .with_node(join_tree_ev.get_bbn_node_by_name('WetGrass')) \
  .with_evidence('true', 1.0).build()
join_tree_ev.set_observation(ev_grass)
```

Kanıt (WetGrass=true) eklenmiş çıktı:

```
P(R=true  | G=true) = 0.04360  (%4.36)
P(R=false | G=true) = 0.95640  (%95.64)
P(T=true  | G=true) = 0.04009  (TakeOff güöncellendi)
Artis: 0.00253 -> 0.04360 (yaklaşık 17 kat)
```

pybbn sonuçları, Bölüm 6.4'teki Bayes formülü ile elle hesaplanan P(R|G) ≈ 0.0435 değeriyle birebir örtüşmektedir. Bu, hem formülün hem de modelin doğru çalıştığını kanıtlar.

7.6 Çift Kanıt: WetGrass=true ve Windy=true

Hem çimin ıslak olduğunu hem de rüüzgarlı olduğunu gözlemlersek ne olur? İkinci bir kanıt ekleyelim:

```
join_tree_ev2 = InferenceController.apply(bbn)
# Kanet 1: WetGrass = true
ev_grass2 =
EvidenceBuilder().with_node(...'WetGrass').with_evidence('true',1.0).build()
# Kanet 2: Windy = true
ev_windy = EvidenceBuilder().with_node(...'Windy').with_evidence('true',1.0).build()
join_tree_ev2.set_observation(ev_grass2)
```

```
join_tree_ev2.set_observation(ev_windy)
```

Çift kanıt çıktısı:

```
P(R=true  | G=true, W=true) = 0.99708  (%99.71)
P(T=true  | G=true, W=true) = 0.69799  (TakeOff)
Artis: 0.00253 -> 0.04360 -> 0.99708 (394 kat)
```

Çimin ıslak olduğu bilgisi yağmur olasılığını %0.25'ten %4.36'ya (~17 kat) yükseltirken, buna ek olarak rüüzgarlı olduğu bilgisi de eklenince olasılık %99.71'e (~394 kat) çıkar. Bu, BBN'lerin birden fazla kanıtı birlikte değerlendirebilme güüçnü açıkça ortaya koymaktadır.

8. Sosyal Ağ Analizinde (SNA) BBN Kullanımı

Sosyal Ağ Analizi (Social Network Analysis - SNA), bir sosyal ağın yapısını ve düğümlerin önemini anlamaya çalışır. Bayes ağları, SNA'da belirsizlik içeren durumları modellemek için güçlü bir araçtır.

8.1 Düğüm Önemi (Node Importance)

Bir sosyal ağda düğümün önemini belirlemek için Derece Merkeziliği (Degree Centrality) ve Bağlantı Merkeziliği (Link Centrality) gibi metrikler kullanılır. Bu metriklerin düğüm önemi üzerindeki etkisi bir Bayes ağı ile modellenebilir:

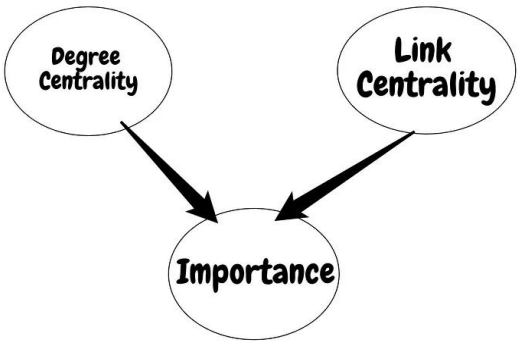

Şekil 7: Düğüm önemi için basit BBN modeli

8.2 Lider Tespiti

Daha karmaşık bir uygulama olarak, bir sosyal ağdaki potansiyel liderlerin belirlenmesi için Bayes ağı kullanılabilir. Aşağıdaki modelde Derece Merkeziliği ve Bağlantı Merkeziliği düğüm önemini belirlerken, önceki liderlik deneyimi ve liderlik eğitimi gibi ek faktörler de "Muhtemel Lider" düğümünü etkilemektedir:

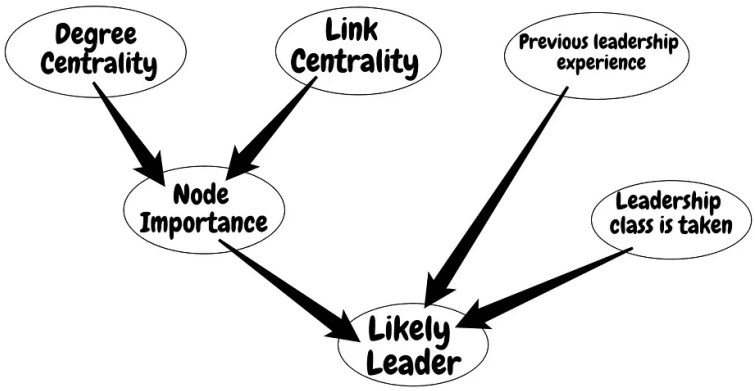

Şekil 8: Sosyal ağda lider tespiti için BBN modeli

8.3 Grup Üyeliği Tahmini

Bayes ağları ayrıca mevcut bağlantılardan yeni bağlantılar çıkarmak için de kullanılabilir. Örneğin bir sosyal ağdaki grup üyeliği olasılığını tahmin etmek için, kişinin gruptaki arkadaşları ve grubun mevcut üyeleri gibi faktörler kullanılabilir.

9. Avantajlar ve Dezavantajlar

9.1 Avantajlar

- **Eksik veri toleransı:** BBN, eksik veri içeren veri setleri ile çalışabilir. Tüm değişkenlerin gözlemlenmesi gerekmez; mevcut kanıtlarla çıkarım yapabilir.
- **Değişkenler arası ilişkilerin modellenmesi:** Benzer yöntemlerden farklı olarak değişkenler arasındaki ilişkileri kullanarak daha doğru sonuçlar üretebilir.
- **Görsel ve sezgisel yapı:** Grafik yapısı sayesinde modelin yapısı kolay anlaşılabilir ve alan uzmanlarıyla paylaşılabilir.
- **Dinamik güncelleme:** Yeni kanıtlar (evidence) elde edildikçe olasılık değerleri anında güncellenebilir.
- **Çift yönlü çıkarım:** Hem nedenlerden sonuçlara, hem de sonuçlardan nedenlere doğru çıkarım yapılabilir.

9.2 Dezavantajlar

- **Overfitting riski:** Graph yapısı başlangıç verisinden oluşturulduğundan, modelin eğitim verisine aşırı uyum sağlaması (overfitting) riski vardır.
- **DAG oluşturma zorluğu:** Değişkenler arası ilişkilerin ve DAG yapısının belirlenmesi, problem büyüklüğüne göre çok karmaşık bir hal alabilir ve derin alan uzmanlığı isteyebilir.
- **Hesaplama karmaşıklığı:** Değişken sayısı arttıkça olasılık tabloları üstel olarak büyür ve hesaplama maliyeti artar.

- **Sürekli değişkenler:** Standart BBN'ler ayrık değişkenler için tasarlanmıştır; sürekli değişkenler için ayrıklaştırma veya özel yöntemler gerekebilir.

10. Kaynaklar

- Arık, A. (2020). "Bayesian Belief Networks". Medium.
- Güney, A. (2019). "Introduction to Bayesian Belief Networks". Towards Data Science, Medium.
- Koelle, D. & Pfautz, J. & Farry, M. & Cox, Z. & Catto, G. & Campolongo, J. (2006). "Applications of Bayesian Belief Networks in Social Network Analysis".
- https://www.edureka.co/blog/bayesian-networks/
- https://www.probabilisticworld.com/bayesian-belief-networks-part-1/