DERS KODU: BLM0462

DÖNEM: 2025–2026 BAHAR

Örüntü Tanıma

Hafta 1 — Örüntü Tanımaya Giriş

Örüntü Tanıma (Pattern Recognition)

Öğretim Üyesi: Prof. Dr. Turgay Tugay BİLGİN

İçindekiler

01 Makine Algısı ve Örüntü Tanımanın Motivasyonu

02 Balık Sınıflandırma Örneği: Uçtan Uca Akış

03 İlgili Alanlar ve Sistem Boru Hattı

04 Örüntü Sınıflandırmanın Alt Problemleri (1): Temsil ve Veri Sorunları

05 Örüntü Sınıflandırmanın Alt Problemleri (2): Yapısal Sorunlar ve Karar Süreci

06 Öğrenme ve Uyum: Öğrenme Türleri

07 Hafta Özeti ve Sonraki Adımlar

Örüntü Tanıma Nedir?

Örüntü tanıma (pattern recognition): ham veriden karara

- **Tanım:** Ham veriyi (görüntü, ses, metin) alıp bir kategoriye atama ve buna göre eylem üretme.
- **Neden zor?** Aynı nesne/sinyal farklı koşullarda çok farklı görünebilir (ışık, açı, gürültü).
- **Çıktı bir "bilgi indirgeme"dir:** Binlerce piksel → tek bir etiket (ör. "somon").

GERÇEK HAYAT ÖRNEKLERİ

Yüz Tanıma
(face recognition)

Spam Filtresi
(spam filtering)

Tıbbi Teşhis
(medical diagnosis)

Otonom Araç
(autonomous driving)

Makine Algısı: Hedef ve Kullanım Alanları

- **Amaç:** İnsan algısına benzer şekilde örüntüleri otomatik tanımak.
- **Tasarım Motivasyonu:** Güvenilirlik, hız, ölçeklenebilirlik; aynı zamanda insan algısını anlamaya katkı.
- **Doğadan İlham:** Bazı alanlarda biyolojik sistemlere dair bilgi, algoritma ve donanım tasarımını etkiler.

Tipik Uygulamalar

- konuşma tanıma (speech recognition)
- parmak izi (fingerprint identification)
- optik karakter tanıma (OCR)
- DNA dizi tanıma (DNA sequence identification)

Balık Örneği: Problem Tanımı

- **Senaryo:** Konveyör bantta gelen balıkları türe göre otomatik ayırma.
- **Algılayıcı:** Kamera (transducer) ile görüntü alma.
- **Amaç:** Her balık için “somon” ya da “levrek (sea bass)” kararı vermek.
- **Zorluk:** Görüntüde değişkenlik—ışık, konum, sensör gürültüsü.

SİSTEM FİKRİ (PİPELİNE)

Ön İşleme (Preprocessing)

↓

Bölütleme (Segmentation)

↓

Özellik Çıkarımı (Feature Extraction)

↓

Sınıflandırıcı (Classifier)

Balık Örneği: Uçtan Uca Sistem Akışı

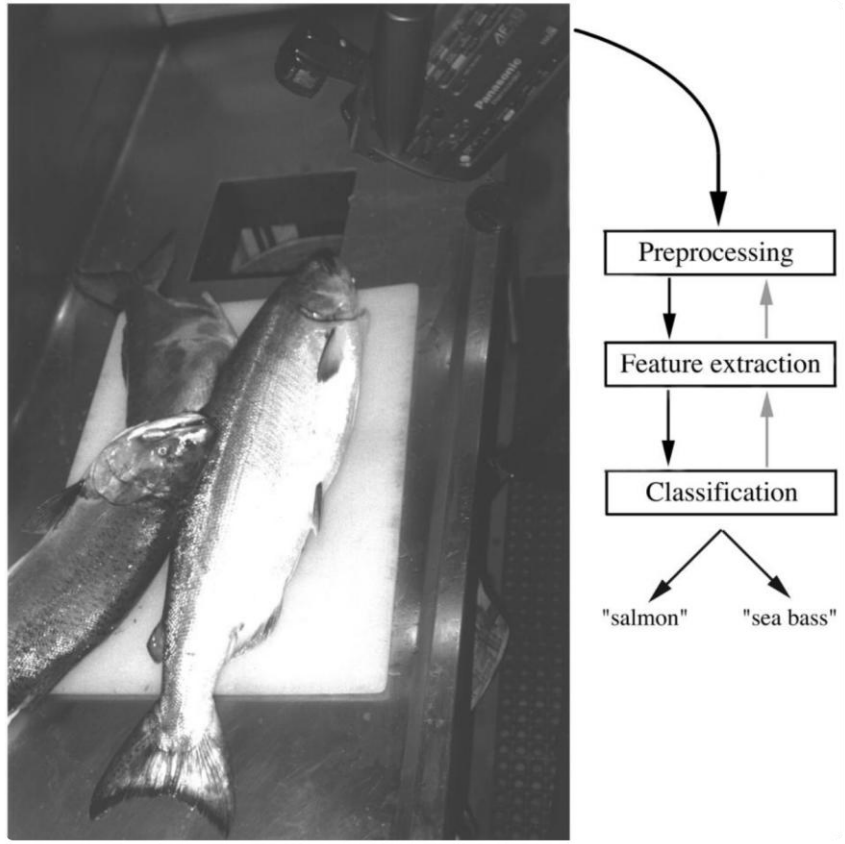

Algılama → ön işleme → özellik → sınıflandırma

Ana Mesaj

Çoğu sistem “aşağıdan yukarı” (bottom-up) çalışır; bazıları “yukarıdan aşağı” (top-down) geri besleme de kullanır.

Not

Bazı tasarımlarda bölütleme ve özellik çıkarımı birleştirilebilir.

Adım 1: Veri Toplama ve Gürültü Kaynakları

- **Ham görüntü:** ışıklandırma, gölge, konveyör titreşimi, sensör ‘statik’i gibi etkiler içerir.
- **Gürültü (noise) tanımı:** Gerçek modele (balık türüne) ait olmayan, rastlantısal/sensörel değişkenlik.
- **Ön işleme hedefi:** İlgili bilgiyi kaybetmeden gürültüyü azaltmak (örn. ortalama ışık düzeyi düzeltme, eşikleme).

Gürültü Kaynakları

- Işıklandırma
- Gölge
- Konveyör Titreşimi
- Sensör hataları

Tek özellik ile sınıflandırma: uzunluk (length)

Varsayım Levrek ortalama olarak daha uzundur.

Yaklaşım Kritik eşik değeri (l*) ise
karar: l > l*
olursa levrek.

Tasarım Eğitim örneklerinden (training samples) uzunluk ölç, dağılıma bak.

Sonuç Dağılımların çakışması → tek başına zayıf ayırıcı.

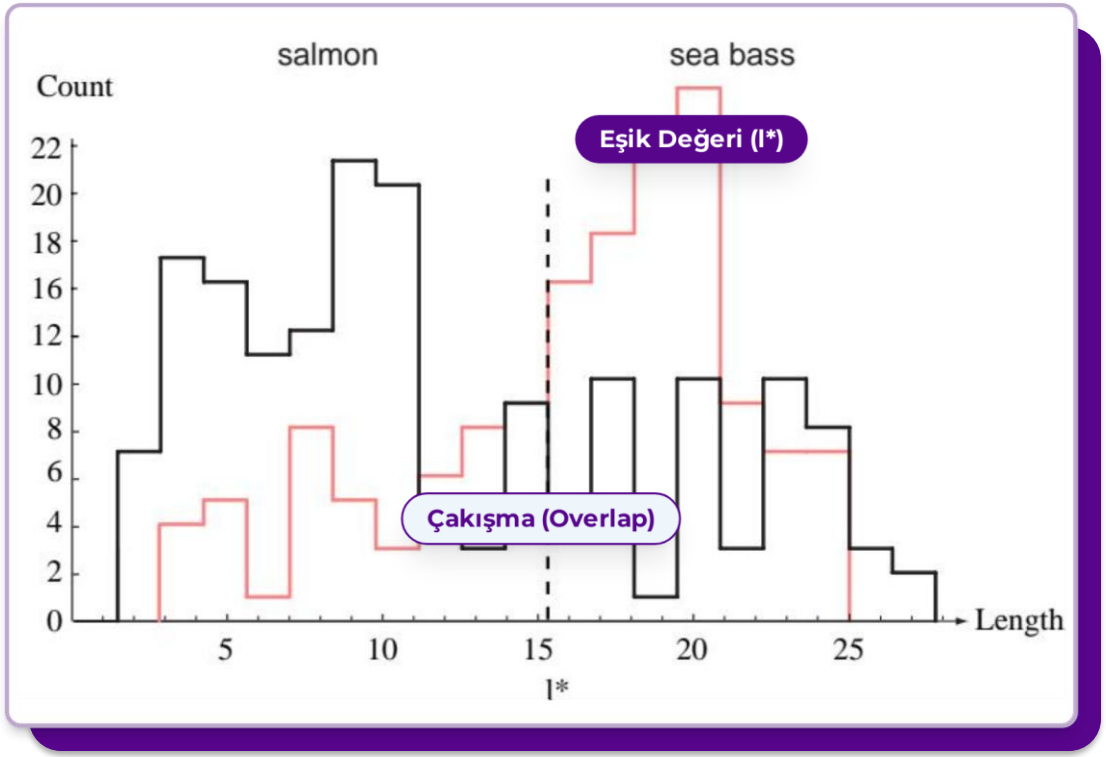

Şekil 1.2: İki sınıfın uzunluk histogramları

Neden uzunluk yeterli değil?

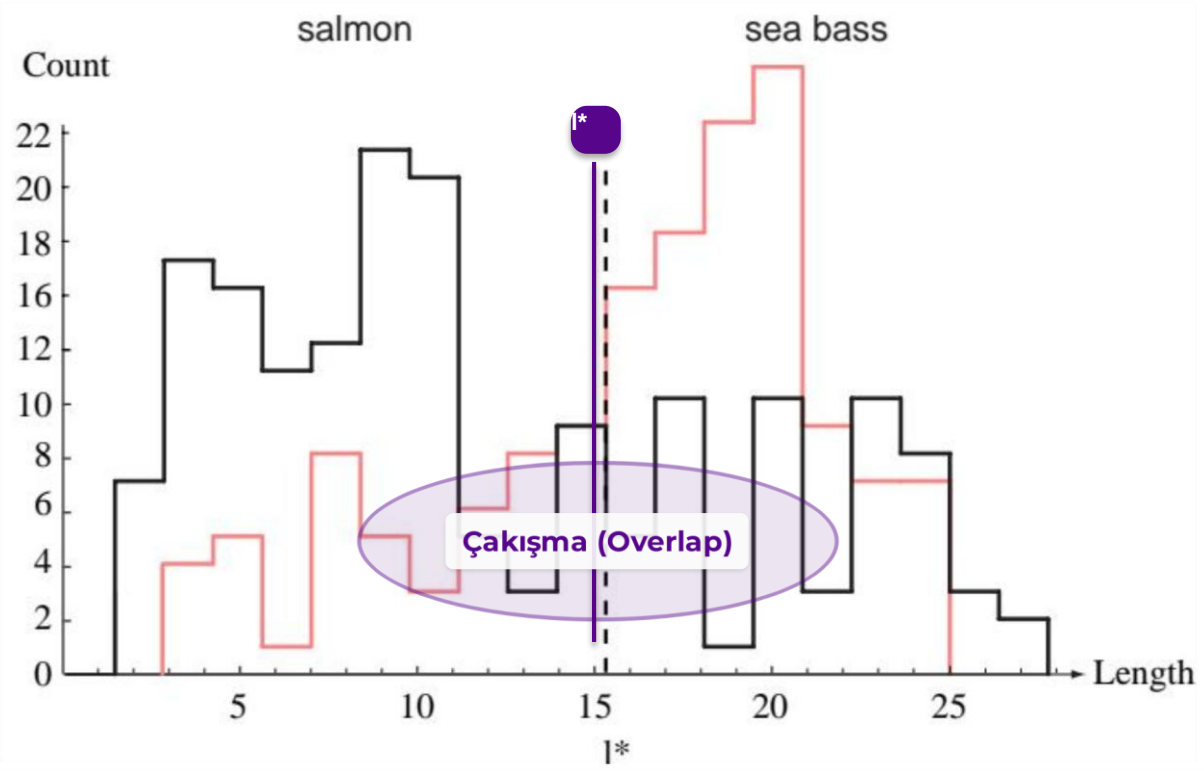

Gözlem

l* ne seçilirse seçilsin hata kaçınılmaz (overlap).

Ders

“Ayrıştırıcı özellik *(discriminative feature)*” seçimi kritik.

İkinci özellik: Parlaklık (lightness)

Yeni fikir Pulların ortalama parlaklığı, türleri daha iyi ayırabilir.

Önemli şart Aydınlatma değişimini azalt (ön işleme).

Karar Eşik x^* ile sınıflandır; hatayı minimize eden eşik seç.

Beklenti Sınıflar daha iyi ayrışır ama yine kusursuz değildir.

↓ Ön İşleme Etkisi

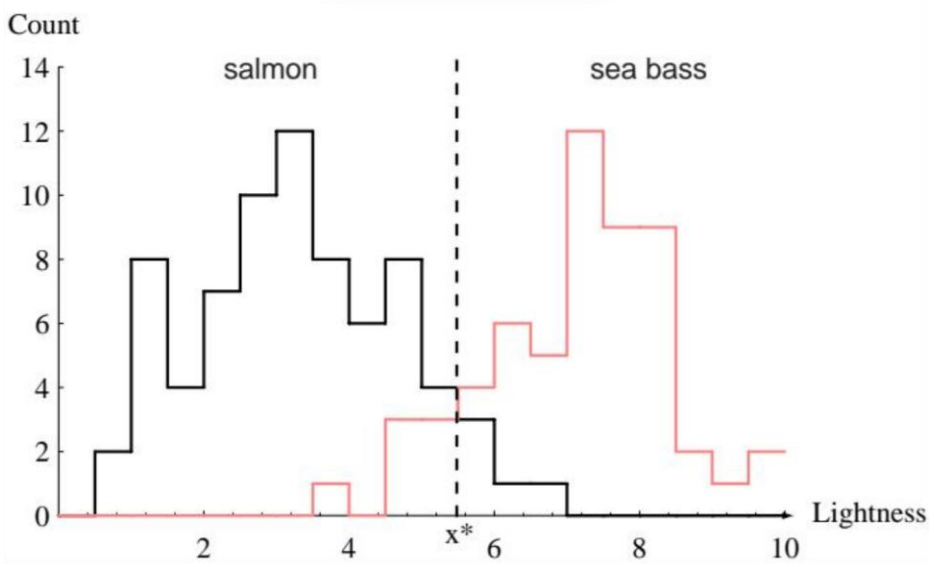

Şekil 1.3: Parlaklık histogramları

Karar sınırı (decision boundary) tek boyutta nasıl seçilir?

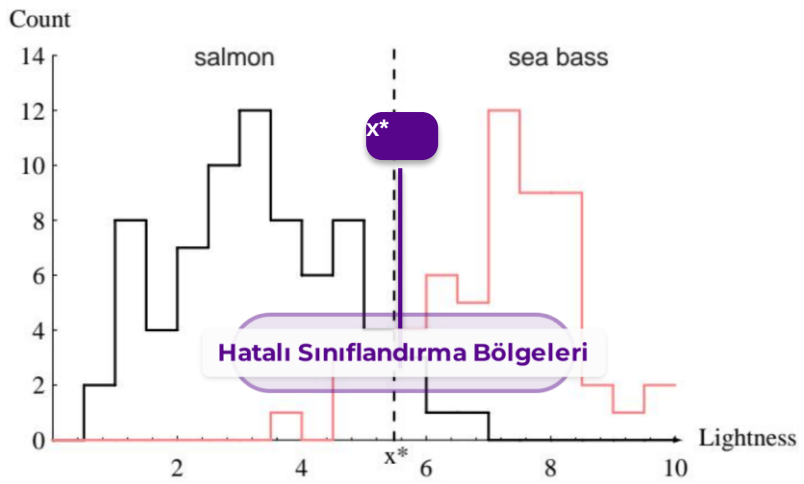

x* hatayı en aza indirecek şekilde ayarlanır.

Not: Tek özellikte bile “optimum eşik” eğitim verisine bağlıdır.

Adım 4: Maliyet/Risk ile Eşiği Kaydırmak

- **Varsayım bozulabilir:** “Somon diye levrek satmak” daha maliyetli olabilir.
- **Karar teorisi (decision theory) fikri:** Toplam beklenen maliyeti minimize edecek eşik seç.
- **Balık örneği:** Levreği somon diye etiketlemek daha kötüyse, **x*** daha küçük seçilerek bu hata azaltılır.
- **Gerçek hayat:** Tıbbi teşhiste yanlış negatif (false negative) vs yanlış pozitif (false positive) maliyetleri farklıdır.

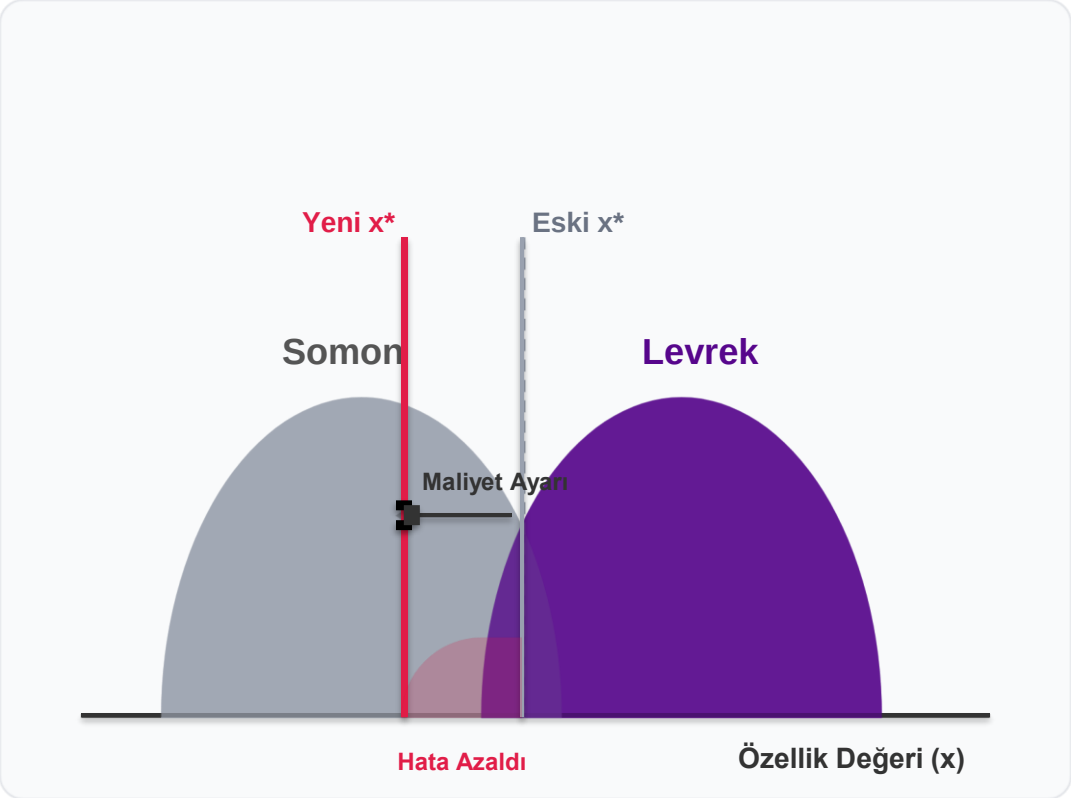

Adım 5: İki Özellik ile Daha İyi Ayrım

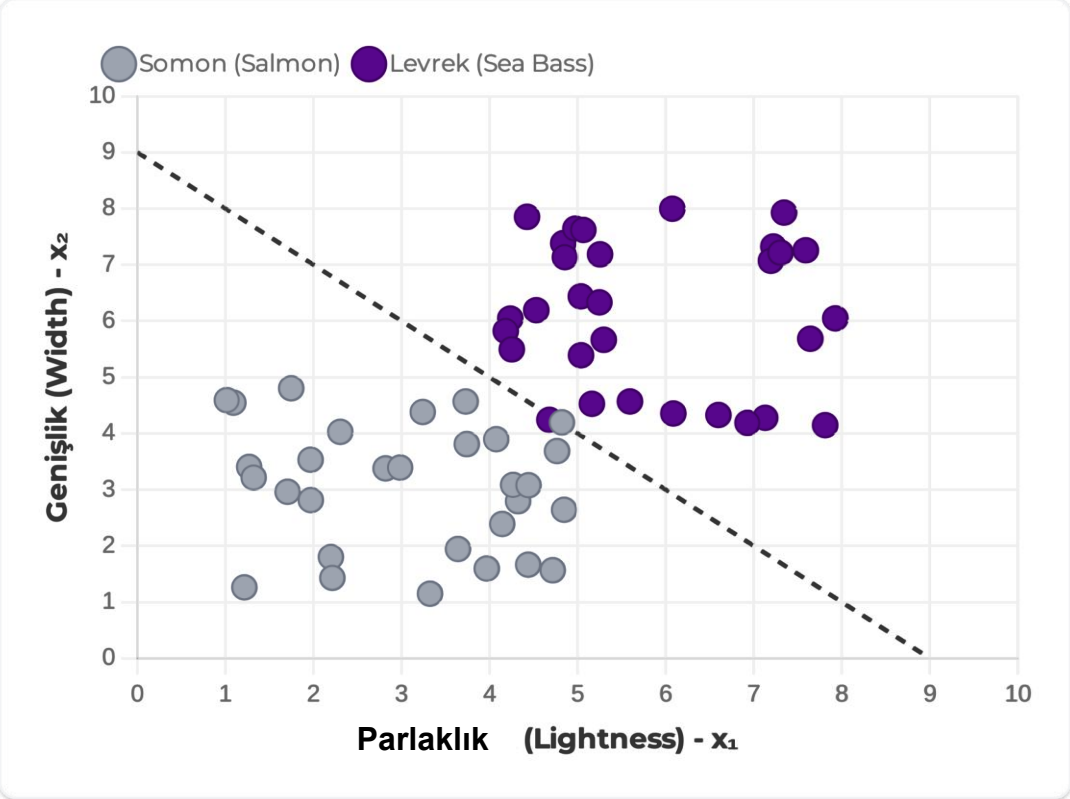

Şekil: 2 Boyutlu Özellik Uzayı ve Karar Sınırı

Parlaklık (x_1) + genişlik (x_2) → özellik vektörü (feature vector)

- Tek özellik yetmeyince: iki özelliği birlikte kullan.
- Gösterim: $\mathbf{x} = [x_1, x_2]^T$; her balık özellik uzayında (feature space) bir nokta.
- Amaç: Uzayı iki bölgeye ayır: üst bölge levrek, alt bölge somon.
- Kazanç: Karar sınırı (decision boundary) daha düşük hata sağlanabilir.

2B Özellik Uzayı Görseli (Şekil 1.4)

Karar sınırı: iki boyutta ayrım

Çıkarım

Çoklu özellik, sınıflar arası ayrımı belirginleştirir.

Uyarı

Hala hata olabilir; ‘mükemmel çizgi’ hiçbir zaman yoktur.

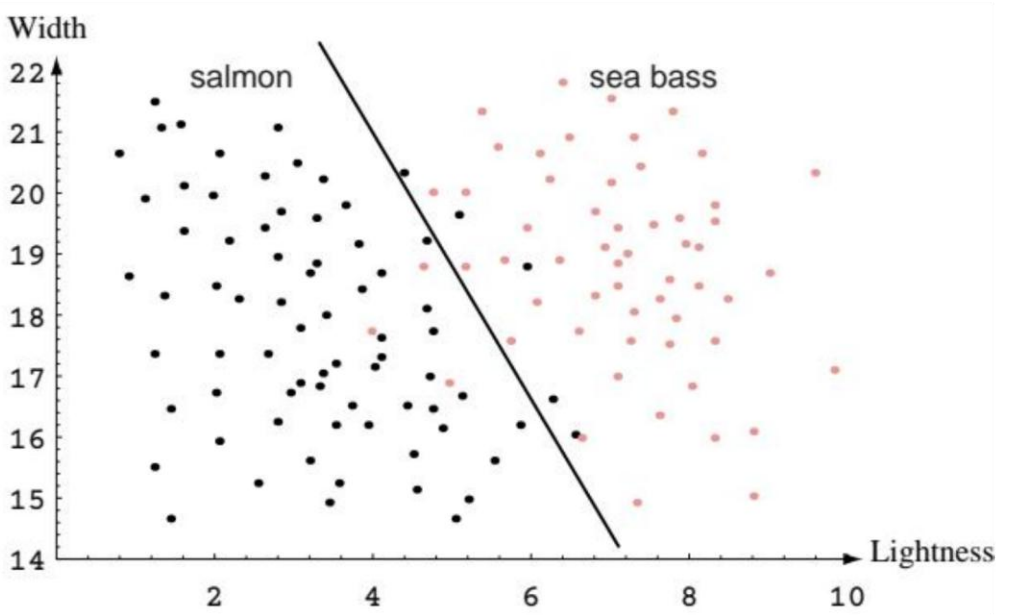

Şekil 1.4: Parlaklık ve Genişlik Özellik Uzayı

Aşırı Öğrenme (Overfitting) Problemi (Şekil 1.5)

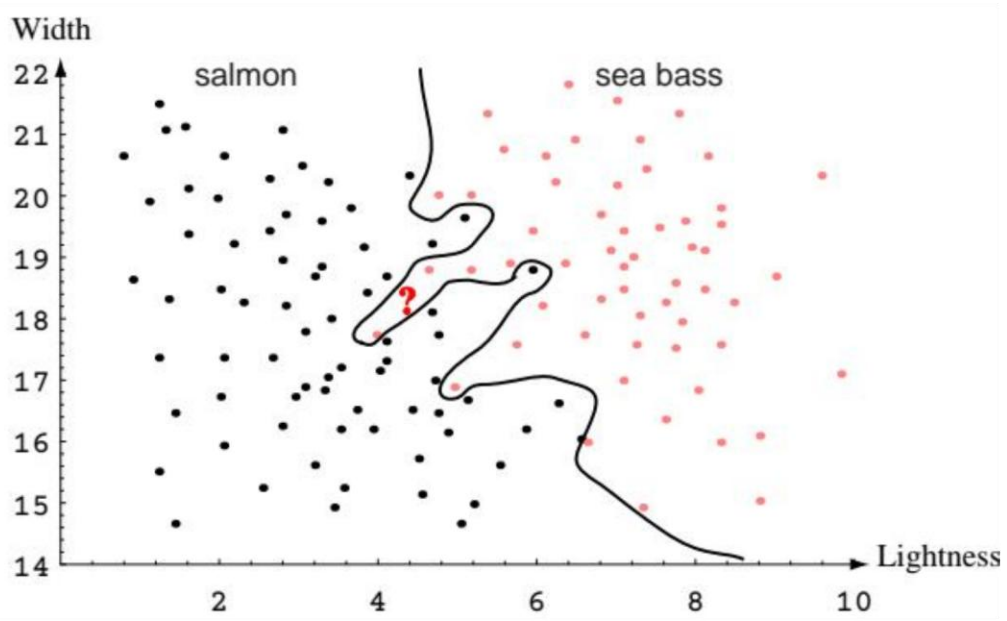

Şekil 1.5: Karmaşık Karar Sınırı ve Aşırı Öğrenme

Eğitimde kusursuz ≠ gerçekte iyi

Aşırı Öğrenme (Overfitting)

Çok karmaşık sınır eğitim örneklerini ezberler, yeni örneklerde hata yapar.

Genel Geçerlik (Generalization)

Asıl hedef görülmemiş veride performanstır.

Basitlik–Başarı Dengesi

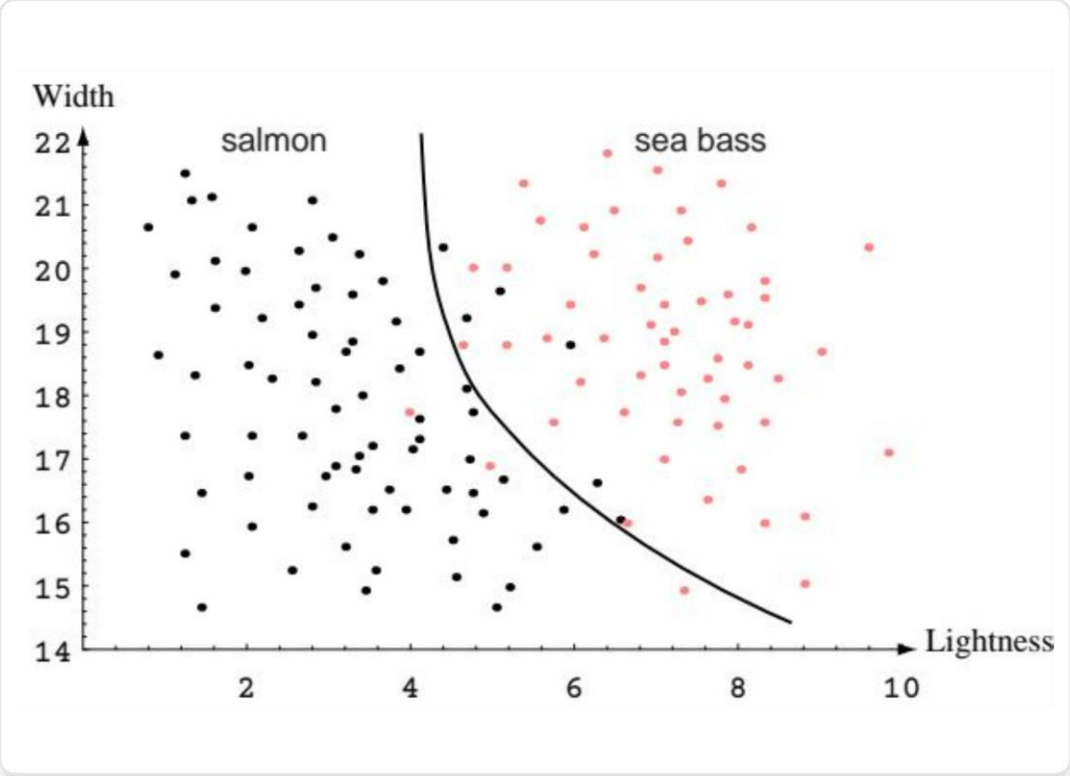

Şekil 1.6

Doğru karmaşıklık nasıl seçilir?

- **Amaç:** Eğitim hatası ile model basitliği arasında optimum denge.
- **Soru:** Doğrulamayı (validation) nasıl yaparız? (Sonraki haftalarda işlenecek)

Balık Örneğinden Çıkan Dersler

1 Özellik Kalitesi

İyi özellikler sınıfları ayırmayı kolaylaştırırken, kötü özellikler örtüşmeye (overlap) neden olur.

2 Ön İşleme

Gürültü azaltma ve bölütleme (segmentation), sınıflandırma öncesi erken aşamalarda kritik öneme sahiptir.

3 Maliyet ve Risk

Karar sınırının (decision boundary) konumu, sadece doğruluğa değil, hataların maliyetine ve risklere göre belirlenir.

4 Karmaşıklık Dengesi

Çoklu özellik kullanımı başarıyı artırabilir, ancak aşırı karmaşıklık "aşırı öğrenmeye" (overfitting) yol açar.

İlgili Alanlar

Örüntü tanıma ve Örüntü sınıflandırma (pattern classification) hangi alanlarla kesişir?

Bilgisayarla görme
(computer vision)

Görüntüden nesne/olay çıkarımı.

Konuşma tanıma
(speech recognition)

Ses sinyalinden fonem/kelime/niyet.

Veri madenciliği
(data mining)

Büyük veride örüntü ve ilişki keşfi.

Örüntü tanıma ve Örüntü sınıflandırma (pattern classification) arasındaki fark?

→ Çıktı yine görüntü

→ Çıktı etiket/karar

Örüntü Tanıma Sistemi: Boru Hattı

Standart akış ve her adımın rolü

01
Algılama
(sensing)
Sensör verisi
(kamera, mikrofon)

02
Ön İşleme
(preprocessing)
Normalizasyon,
gürültü azaltma

03
Bölütleme
(segmentation)
Hedef nesneyi
arka plandan ayırma

04
Özellik Çıkarımı
(feature extraction)
Veri indirgeme
ve temsil

05
Sınıflandırma
(classification)
Karar kuralı
ve çıktı etiketi

06
Son-İşleme
(post-processing)
Bağlam (context) /
maliyet (cost) ile düzeltme

Örüntü Tanımada alt-problemler

- Pratikte zorlukların çoğu alt problemlerdedir.
- Bu bölümde: Her alt problemi kısa tanım + gerçek hayat örneği ile göreceğiz.

Özellik çıkarımı (feature extraction): temsilin kalbi

Amaç

Ham veriyi daha düşük boyutlu, ayırt edici bir temsile dönüştürmek.

Neden alan bağımlı?

Balık için iyi özellik, parmak izi için işe yaramayabilir.

Tasarım soruları

Hangi özellikler?

Kaç özellik?

Otomatik seçilebilir mi?

Örnekler

Yüz tanıma

yüz noktaları/embedding (face embedding)

Spam filtresi

kelime istatistikleri/TF-IDF (TF-IDF)

Gürültü (noise) ve belirsizlikle baş etme

Gürültü

Modele ait olmayan rastgele değişkenlik (sensör/çevre).

Etkisi

Özellik değerlerini kaydırır → karar sınırına yakın örneklerde hata artar.

Yaklaşımlar

Ön işleme ile temizleme; dayanıklı (robust) özellik/algoritma seçimi.

Örnek

Otonom araçta yağmur/sis, tıbbi görüntüde ölçüm artefaktı.

Gürültü Etki Zinciri

Gürültü (Noise)

↓

Özellik Bozulması

↓

Sınıflandırma Hatası

Aşırı öğrenme (overfitting) nasıl ortaya çıkar?

Belirti

Eğitim verisinde çok düşük hata, testte yüksek hata.

Neden

Model çok esnek; gürültüyü ‘kural’ sanar.

Önleme fikirleri

Daha fazla veri, daha basit model, düzenlileştirme (regularization).

Balık örneği

Şekil 1.5’teki karmaşık sınır.

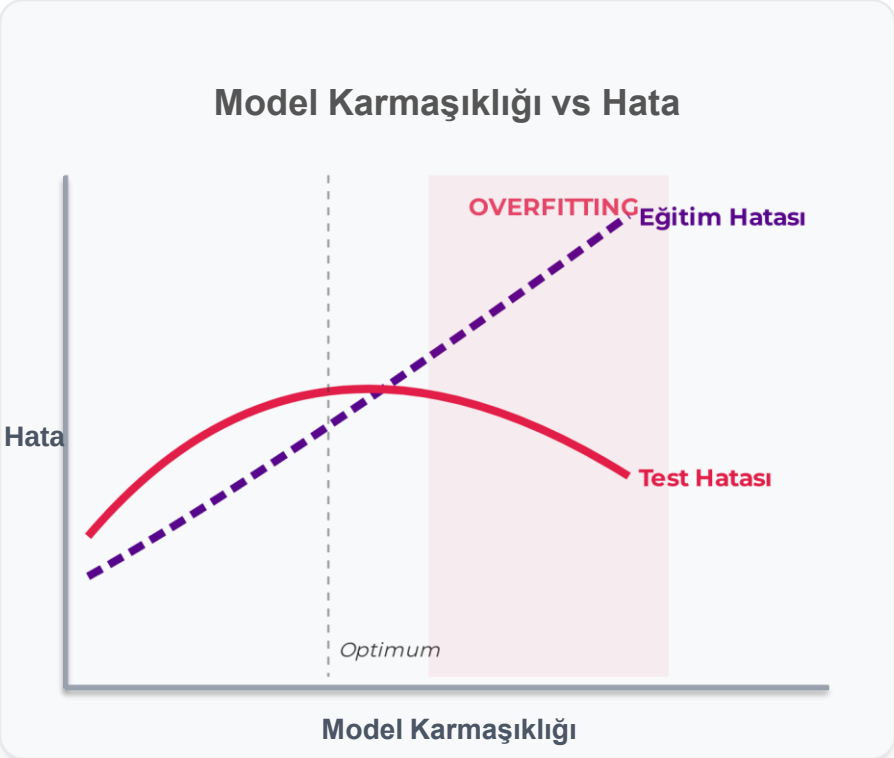

Model seçimi (model selection): doğru model sınıfını seçmek

Soru

Mevcut model ailesi yeterli değilse ne zaman değiştirmeli?

Örnek

Doğrusal sınır yetmezse doğrusal olmayan (nonlinear) sınırlara geçmek.

Pratik Yaklaşım

Aday modelleri dene → doğrulama ile kıyasla.

Risk

‘Deneme-yanılma’ maliyeti; otomasyon ihtiyacı.

Eksik özellikler (missing features): ölçüm yoksa karar nasıl verilir?

Sorun

Örnek: Balığın genişliği **üst üste binme (occlusion)** nedeniyle ölçülemez.

Yetersiz Çözüm

Ortalamaya göre doldurma (**optimal değildir**.)

İhtiyaç

Eksik bilgiyle karar verebilen **yöntemler** ve **eğitim stratejileri**.

Gerçek Hayat

Sensör arızası, veri kaybı, klinikte eksik test sonuçları.

Bölütleme (segmentation): nesne nerede başlar, nerede biter?

- **Balık örneği:** Balıklar üst üste gelebilir; tek balığı arka plandan ayırmak gerekir.
- **“Tavuk-yumurta” sorunu:** Tanımadan bölütlemek zor; bölütlemeden tanımak zor.
- **Örnekler:**
  - Konuşmada fonem sınırları (phoneme boundaries).
  - Bitişik el yazısında karakter ayrımı.
- **Tasarım hedefi:** Arka plan/‘kategori yok’ durumunu da modellemek.

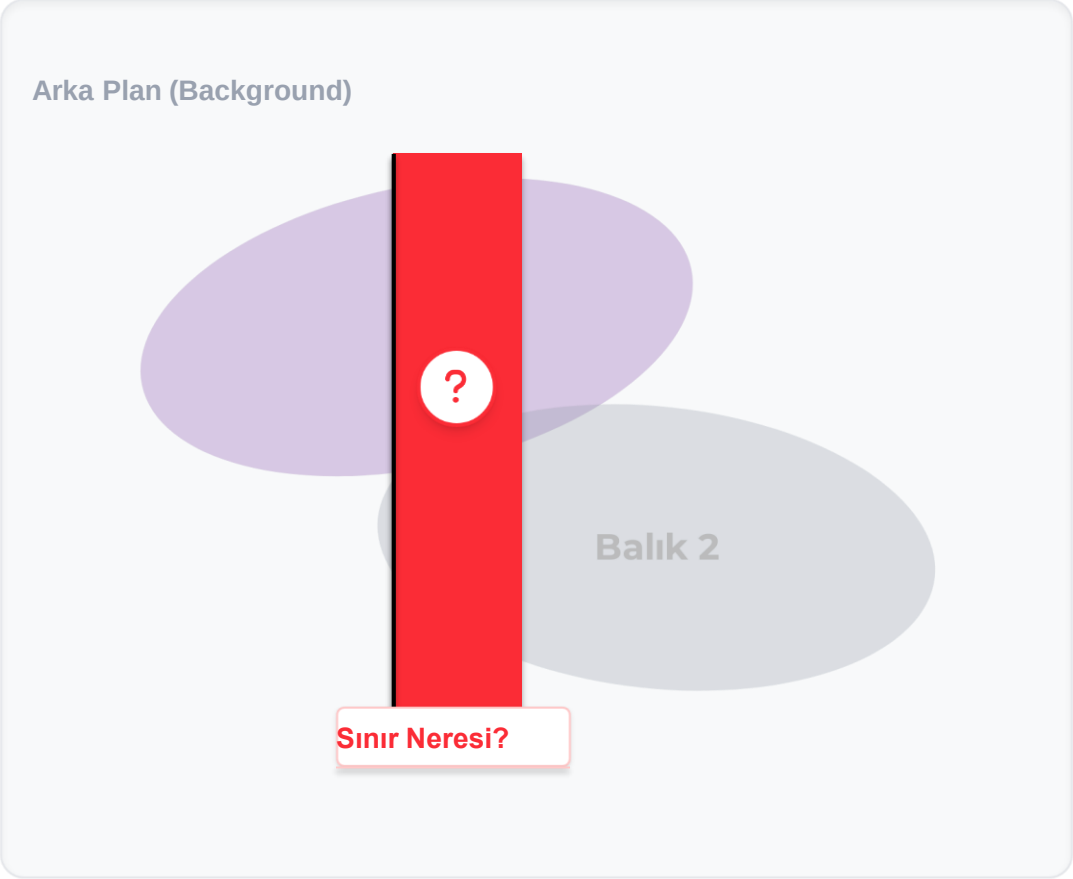

Bağlam (context) ile kararı güçlendirmek

Tanım Hedef örüntü dışındaki, girdiye bağlı ek bilgi.

Balık Örneği Uzun ‘somon’ dizisinden sonra belirsiz bir örnek yine somon olabilir.

Risk Yanlış bağlam varsayımı hatayı artırabilir; dikkatli entegrasyon gerekir.

Değişmezlikler (Invariances)

Temel Kavram

Değişmezlik (invariance): Sınıflandırıcının, kategoriye etkisi olmayan dönüşümlere karşı duyarsız olması gerekir. Örneğin balığın taşıma bandındaki konumu veya yönelimi türünü değiştirmez — bu nedenle sistemimiz bu tür değişimlere karşı değişmez (invariant) olmalıdır.

Taşıma bandında bir balık yatay, dikey veya eğik konumda olabilir; kamera hattı etrafında herhangi bir açıyla dönmüş olabilir. Ancak bu dönüşümler balığın levrek mi yoksa somon mu olduğunu değiştirmez. Dolayısıyla sınıflandırıcımız **öteleme (translation)** ve **dönme (rotation)** değişmezliğine sahip olmalıdır.

Hangi değişmezliklerin gerekli olduğunu nasıl belirleriz? Bu bilgiyi sınıflandırıcıya nasıl verimli şekilde dahil ederiz?

Öğrenme ve Uyum Gerekliliği

Neden İhtiyaç Var?

Çoğu pratik problemde (örneğin yüz tanıma veya konuşma algılama), karmaşık karar kurallarını baştan tahmin etmek veya elle yazmak neredeyse imkansızdır.

Öğrenme Nedir?

Genel bir model yapısı varsayarak, bu modelin bilinmeyen parametrelerini **eğitim örnekleri (training samples)** üzerinden tahmin etme sürecidir.

Temel Amaç

Eğitim verisi üzerindeki hatayı azaltan bir algoritma geliştirmektir. Bu süreç genellikle bir hata fonksiyonunun minimize edilmesine dayanır.

Genelleme ve Uyum

Sadece eğitim hatasını düşürmek yetmez; asıl hedef, görülmemiş verilerde doğru karar verebilmek **(generalization)** ve **aşırı öğrenmeden (overfitting)** kaçınmaktır.

Denetimli Öğrenme

Denetimli öğrenme (supervised learning): etiketli veri ile öğrenme

- **Öğretmen sinyali:** Her örnek için sınıf etiketi veya maliyet.
- **Amaç:** Toplam maliyeti/hataları minimize eden parametreleri öğrenmek.
- **Tipik kullanım:** yüz tanıma (etiketli yüzler), spam filtresi (spam/ham), tıbbi teşhis (hasta/sağlıklı).
- **Soru:** Yakınsama (convergence), ölçeklenebilirlik (scalability), basitlik tercihi.

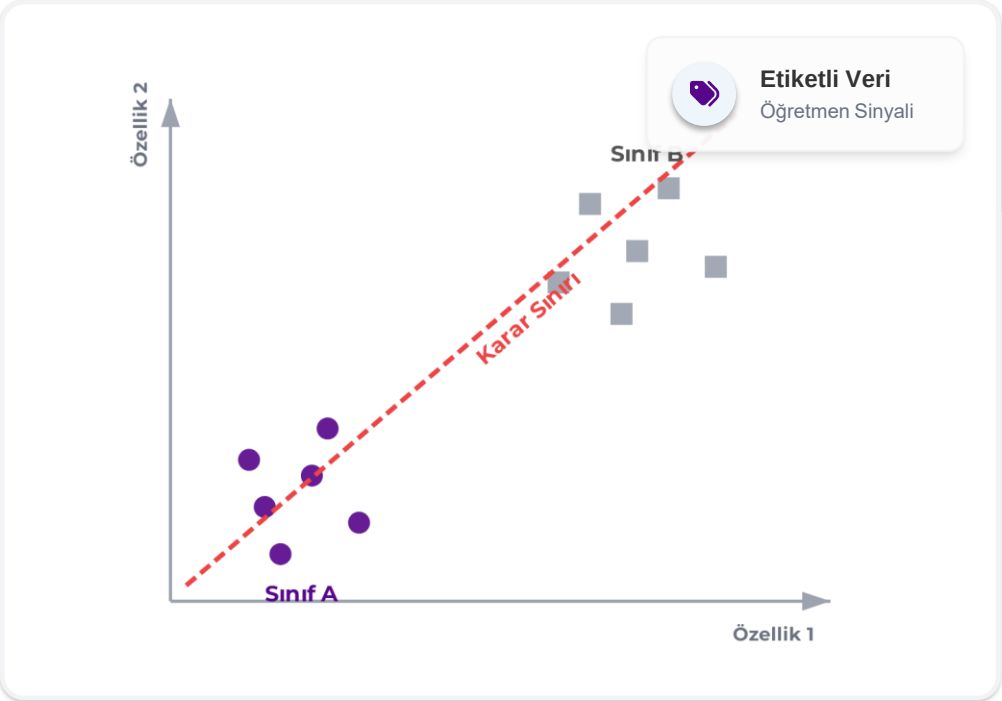

Denetimsiz Öğrenme

Denetimsiz öğrenme (unsupervised learning): kümeleme (clustering)

- **Etiket yok:** Sistem ‘doğal grupları’ bulmaya çalışır.
- **Çıktı:** kümeler; yorumlanması probleme bağlıdır.
- **Zorluk:** Küme sayısı ve ‘doğallık’ kriteri (objective) seçimleri.
- **Örnek:** Müşteri segmentasyonu (customer segmentation), anomali keşfi (anomaly detection).

Pekiştirmeli Öğrenme

Pekiştirmeli öğrenme (reinforcement learning): eleştirmen (critic) ile geri bildirim

- **Öğretmen:** Doğru etiketi söylemez; sadece doğru/yanlış veya tek skaler ödül verir.
- **Soru:** “Nasıl düzeltmeliyim?” bilgisi eksik → öğrenme daha zordur.
- **Örnek bağlam:** sınıflandırmada yalnızca kararın doğruluğu geri besleniyorsa.
- **Not:** İki sınıf ve eşit maliyette, bazen denetimli öğrenmeye yakınsar.

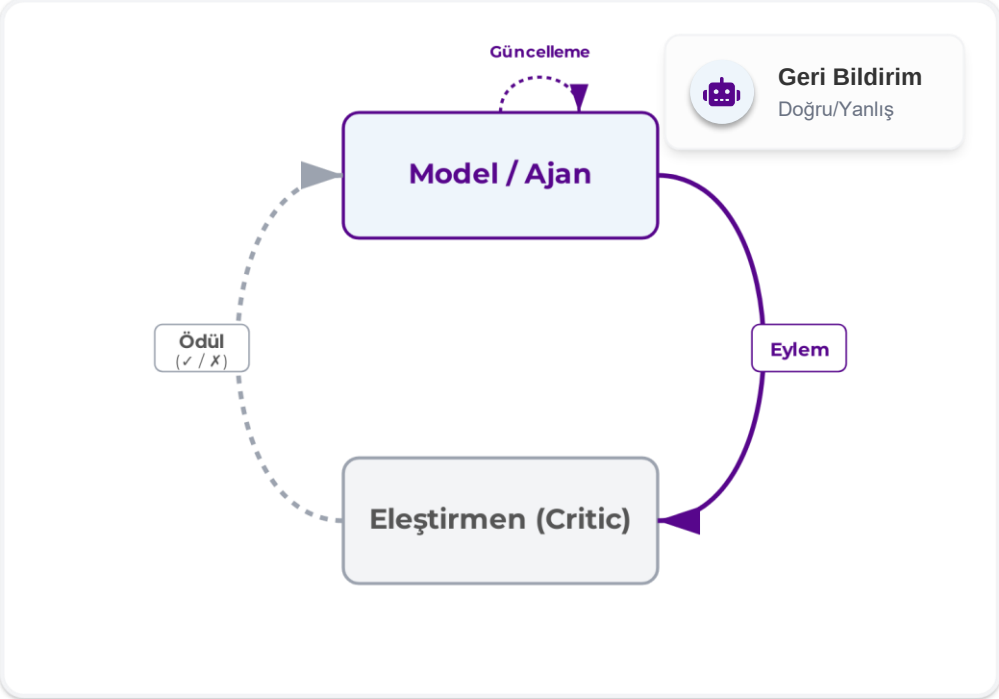

Öğrenme Türleri: Net Karşılaştırma

Özellik	Denetimli Öğrenme (Supervised)	Denetimsiz Öğrenme (Unsupervised)	Pekiştirmeli Öğrenme (Reinforcement)
Girdi (Input)	**Etiketli veri** *Labeled data*	**Etiketsiz veri** *Unlabeled data*	**Ödül sinyali** *Reward signal*
Çıktı (Output)	**Sınıflandırıcı** *Classifier*	**Kümeler** *Clusters*	**Politika** *Policy*
Tipik Riskler (Typical Risks)	**Aşırı öğrenme** *Overfitting*	**Anlamsız kümeler** *Meaningless clusters*	**Yavaş, kararsız öğrenme** *Slow, unstable learning*
Uygulama (Application)	**Spam filtresi** *Spam filter*	**Müşteri segmentasyonu** *Customer segmentation*	**Robot navigasyonu** *Robot navigation*

Özet

Makine algısı → boru hattı → balık örneği ile karar sınırı, maliyet ve overfitting.

Hazırlık

Bir sonraki hafta istatistiksel modeller ve temel sınıflandırıcılar.

Sorular?