Bölüm 2: Bayesian Karar Teorisi

Bayesian Decision Theory

Prof. Dr. Turgay Tugay BİLGİN

BLM0462 – Örüntü Tanıma *(Pattern Recognition)*

2025–2026 Bahar Dönemi

İçindekiler

1. 2.1 Giriş
2. 2.2 Bayesian Karar Teorisi – Sürekli Özellikler
3. 2.2.1 İki Kategorili Sınıflandırma
4. 2.3 Minimum Hata Oranı Sınıflandırması
5. 2.3.1 Minimax Kriteri
6. 2.3.2 Neyman-Pearson Kriteri
7. 2.4 Sınıflandırıcılar, Ayrım Fonksiyonları ve Karar Yüzeyleri
8. 2.4.1 Çok Kategorili Durum
9. 2.4.2 İki Kategorili Durum

Tanım

Bayesian karar teorisi *(Bayesian decision theory)*, örüntü sınıflandırma problemine **istatistiksel** bir yaklaşım sunar. Farklı sınıflandırma kararlarının **maliyetlerini (kayıplarını)** ve **olasılıklarını** birleştirerek *en iyi kararı* verir.

Temel Varsayımlar:

- Karar problemi **olasılıksal terimlerle** ifade edilebilmektedir.
- Tüm ilgili **olasılık dağılımları bilinmektedir**.
- Hatalı sınıflandırmaların maliyeti sayısal olarak tanımlanabilir.

Neden Önemli?

Bayesian karar teorisi, **optimal sınıflandırıcının teorik sınırını** tanımlar. Dağılımlar bilindiğinde daha iyi bir sınıflandırıcı *üretilemez*.

Gerçek Hayat: E-posta spam filtresi – kelimelerin koşullu olasılıkları (olabilirlik) ve genel spam oranı (önsel) birleştirilerek karar verilir.

Senaryo: Fabrikada konveyör bant üzerinde otomatik balık sınıflandırması yapılacak.

- **Doğa durumu** *(state of nature)*: ω
  - ω_1 : Levrek *(sea bass)*
  - ω_2 : Somon *(salmon)*
- **Özellik** *(feature)*: x (parlaklık ölçümü)
- Sıradaki balığın türünün olasılığı **rassaldır**.

Önsel Olasılık *(Prior Probability)*

Balığı görmeden önce tahminimiz:

$$P(\omega_1) + P(\omega_2) = 1$$

Örneğin $P(\omega_1) = 2/3$, $P(\omega_2) = 1/3$

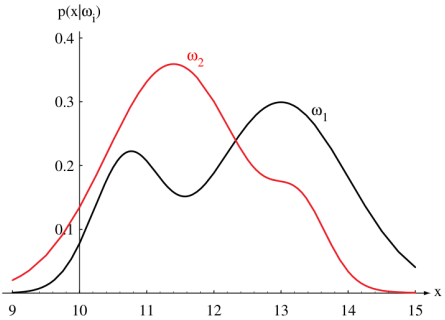

Şekil 2.1: Levrek (ω_1) ve somon (ω_2) için parlaklık ölçümünün **sınıf-koşullu yoğunluk fonksiyonları** *(class-conditional density functions)*. Her eğrinin altındaki alan 1'dir.

Balığı ölçtükten sonra (x değeri bilinince) bilgimiz güncellenir. Ortak yoğunluk iki biçimde yazılabilir:

$$p(\omega_j, x) = P(\omega_j|x)\, p(x) = p(x|\omega_j)\, P(\omega_j)$$

Bayes Formülü

$$\underbrace{P(\omega_j|x)}_{\text{sonsal}} = \frac{\underbrace{p(x|\omega_j)}_{\text{olabilirlik}} \cdot \underbrace{P(\omega_j)}_{\text{önsel}}}{\underbrace{p(x)}_{\text{kanıt}}}$$

$$p(x) = \sum_{j=1}^{c} p(x|\omega_j)\, P(\omega_j)$$

Sezgisel ifade:

$$\text{sonsal} = \frac{\text{olabilirlik} \times \text{önsel}}{\text{kanıt}}$$

Terimlerin Anlamı:

- $P(\omega_j|x)$: **sonsal** *(posterior)* – x ölçüldükten *sonra* sınıf olasılığı
- $p(x|\omega_j)$: **olabilirlik** *(likelihood)* – ω_j sınıfında x'i görme yoğunluğu
- $P(\omega_j)$: **önsel** *(prior)* – ölçümden *önce* sınıf olasılığı
- $p(x)$: **kanıt** *(evidence)* – kararı *etkilemez*, x'in olma olasılığıdır.

Bayes Karar Kuralı *(Bayes Decision Rule)*

$$\text{Karar: } \omega_1 \quad \text{eğer } P(\omega_1|x) > P(\omega_2|x), \qquad \text{aksi halde } \omega_2$$

Eşdeğer formlar (kanıt $p(x)$ her iki tarafı da böldüğünden sadeleşir):

$$\omega_1 \text{ iff } p(x|\omega_1)\,P(\omega_1) > p(x|\omega_2)\,P(\omega_2)$$

Belirli x için hata olasılığı:

$$P(\text{hata}|x) = \begin{cases} P(\omega_1|x) & \omega_2 \text{ kararı verilirse} \\ P(\omega_2|x) & \omega_1 \text{ kararı verilirse} \end{cases}$$

Optimal kural:

$$P(\text{hata}|x) = \min\big[P(\omega_1|x),\, P(\omega_2|x)\big]$$

Ortalama hata olasılığı:

$$P(\text{hata}) = \int_{-\infty}^{\infty} P(\text{hata}|x)\,p(x)\,dx$$

Her x'te hatayı minimize etmek $\Rightarrow$ integrali minimize eder.

Sonuç

Bayes karar kuralı, ortalama hata olasılığını **minimize eden** optimal karar kuralıdır. Her gözlem noktasında lokal olarak en düşük hatayı seçmek, global hatayı da minimize eder.

Sonsal olasılıklar ve karar:

- Her x noktasında $P(\omega_1|x)$ ve $P(\omega_2|x)$ hesaplanır.
- İkisi her zaman $P(\omega_1|x) + P(\omega_2|x) = 1$ koşulunu sağlar.
- Karar sınırı: $P(\omega_1|x^*) = P(\omega_2|x^*) = 0.5$

Minimum Hata İlkesi

$$\omega^*(x) = \arg\max_{\omega_i} \; P(\omega_i|x)$$

Bu, **maksimum a posteriori** *(Maximum A Posteriori (MAP))* kuralıdır.

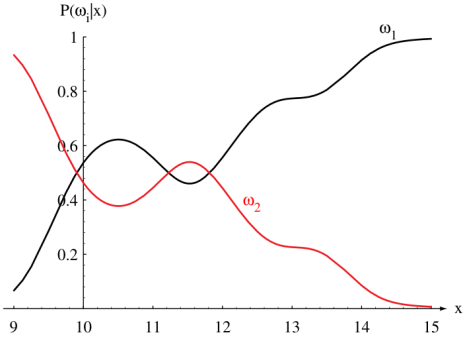

Şekil 2.2: $P(\omega_1) = 2/3$, $P(\omega_2) = 1/3$ için sonsal olasılıklar. $x = 14$'te $P(\omega_1|x) \approx 0.92$ ve $P(\omega_2|x) \approx 0.08$. Her noktada toplamları 1'dir.

Giriş bölümündeki iki kategorili, tek özellikli örnek genelleştiriliyor:

1. **Birden fazla özellik**: $\mathrm{x} = (x_1, \ldots, x_d)^\top \in \mathbb{R}^d$ *(özellik uzayı / feature space)*
2. **İkiden fazla sınıf**: $\omega_1, \omega_2, \ldots, \omega_c$
3. **Ret eylemi**: $\alpha_1, \ldots, \alpha_a$ – yalnızca sınıf kararı değil, belirsiz durumlarda *ret (rejection)* de seçilebilir.
4. **Genel kayıp fonksiyonu**: $\lambda(\alpha_i|\omega_j)$ – durum ω_j iken α_i eylemini almanın maliyeti.

Notasyon:

- $\mathrm{x} \in \mathbb{R}^d$: d boyutlu özellik vektörü
- $p(\mathrm{x}|\omega_j)$: sınıf-koşullu yoğunluk fonksiyonu
- $P(\omega_j)$: önsel olasılık
- $\lambda(\alpha_i|\omega_j)$: kayıp – büyükse o eylem pahalı
- $P(\omega_j|\mathrm{x})$: sonsal olasılık (Bayes formülünden)
- R^*: Bayes riski (mümkün olan minimum)

Gerçek Hayat: Tıbbi Tanı

Birden fazla biyobelirteç (d özellik), birden fazla hastalık sınıfı, biopsi (maliyetli eylem) veya ilaç (daha az maliyetli eylem). Kanserliyi sağlıklı sanmak, sağlıklıyı kanserli sanmaktan çok daha pahalıdır $\Rightarrow$ asimetrik kayıp fonksiyonu.

Adım 1 – Sonsal Olasılık

- Bir gözlem x geldiğinde her sınıf için **sonsal olasılık** hesaplanır.
- Bu değer, örneğin hangi sınıfa ait olma olasılığının daha yüksek olduğunu gösterir.

Adım 2 – Koşullu Risk

- Her kararın bir **maliyeti (kayıp)** vardır.
- Koşullu risk, x gözlemlendiğinde bir karar vermenin **beklenen maliyetidir**.

Adım 3 – Genel Risk

- Tüm olası x değerleri için ortalama risk hesaplanır.
- Bu değer sınıflandırıcının **genel performansını** gösterir.

Bayes Karar İlkesi

Her x için **en küçük beklenen kayba** sahip karar seçilir.

Sonsal Olasılık

$$P(\omega_j|x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

Koşullu Risk

$$R(\alpha_i|x) = \sum_j \lambda(\alpha_i|\omega_j)\, P(\omega_j|x)$$

Genel Risk

$$R = \int R(\alpha(x)|x)\, p(x)\, dx$$

Örnek: Spam Filtresi

- α_1: spam sil, α_2: gelen kutusuna al
- $\lambda(\alpha_2|\text{spam}) \gg \lambda(\alpha_1|\text{normal})$
  (spam'i gözden kaçırmanın maliyeti yüksek)

Problem
İki sınıf vardır: ω_1, ω_2
İki karar verilebilir:

$$\alpha_1 : \omega_1 \text{ seç}, \qquad \alpha_2 : \omega_2 \text{ seç}$$

$\lambda_{ij} = \lambda(\alpha_i|\omega_j)$: gerçek sınıf ω_j iken α_i kararının kaybı.
Koşullu Risk
Bir kararın beklenen maliyeti:

$$R(\alpha_1|x) = \lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x)$$

$$R(\alpha_2|x) = \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x)$$

	Gerçek ω_1	**Gerçek** ω_2
Karar ω_1	λ_{11}	λ_{12}
Karar ω_2	λ_{21}	λ_{22}

Kayıp matrisi
Yanlış kararların maliyeti genellikle doğru karardan daha büyüktür.

- λ_{12}: ω_2 iken ω_1 seçmenin maliyeti
- λ_{21}: ω_1 iken ω_2 seçmenin maliyeti

Minimum Risk Kuralı

En küçük beklenen maliyete sahip karar seçilir:

$$R(\alpha_1|x) < R(\alpha_2|x) \Rightarrow \omega_1 \text{ seç}$$

Bu koşul şu eşitsizliğe dönüşür:

$$(\lambda_{21} - \lambda_{11})P(\omega_1|x) > (\lambda_{12} - \lambda_{22})P(\omega_2|x)$$

Olabilirlik Oranı Kuralı *(Likelihood Ratio)*

$$\underbrace{\frac{p(x|\omega_1)}{p(x|\omega_2)}}_{\text{olabilirlik oranı}} \underset{\omega_2}{\overset{\omega_1}{>}} \underbrace{\frac{(\lambda_{12} - \lambda_{22})\,P(\omega_2)}{(\lambda_{21} - \lambda_{11})\,P(\omega_1)}}_{\text{eşik } \theta}$$

Yorum

- Sol taraf: olabilirlik oranı

$$\frac{p(x|\omega_1)}{p(x|\omega_2)}$$

Verinin iki sınıf altında ne kadar olası olduğunu karşılaştırır.

- Sağ taraf: karar eşiği: θ kayıp değerleri ve önsel olasılıklardan belirlenir.

Özel Durum

Eğer

$$P(\omega_1) = P(\omega_2)$$

ve kayıplar simetrik ise $\theta = 1$ olur ve Karar yalnızca

$$p(x|\omega_1) > p(x|\omega_2)$$

karşılaştırmasına indirgenir.Yani "hangisi daha olası ise onu seç"anlamına gelir.

Sıfır-Bir Kayıp (Zero-One Loss)

$$\lambda(\alpha_i|\omega_j) = \begin{cases} 0 & \text{doğru karar} \\ 1 & \text{hatalı karar} \end{cases}$$

Doğru kararın kaybı yoktur, tüm hatalar **aynı maliyete sahiptir**.

Koşullu risk

Bir kararın beklenen maliyeti:

$$R(\alpha_i|x) = 1 - P(\omega_i|x)$$

Yorum

- $P(\omega_i|x)$: kararın doğru olma olasılığı
- $1 - P(\omega_i|x)$: hata yapma olasılığı

Risk = Hata Olasılığı

Zero-one loss kullanıldığında

$$R = P(\text{hata})$$

Yani Bayes riski doğrudan **ortalama hata oranıdır**.

Sezgisel olarak

- doğru karar $\rightarrow$ kayıp 0
- yanlış karar $\rightarrow$ kayıp 1

Bu nedenle

$$\text{risk} = \text{hata olasılığı}$$

Olabilirlik oranı

$$\frac{p(x|\omega_1)}{p(x|\omega_2)}$$

verinin hangi sınıf altında daha olası olduğunu gösterir.

Karar kuralı

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \theta$$

ise ω_1 seçilir, aksi halde ω_2 seçilir.
Sıfır-bir kayıp (Zero-one loss)
Tüm hatalar eşit maliyetli olduğunda eşik θ_a olur ve karar sınırları Şekil 2.2 ile aynıdır.

Asimetrik Kayıp Etkisi

Eğer $\lambda_{12} > \lambda_{21}$ ise (ω_2'yi ω_1 sanmanın maliyeti daha yüksek):

- eşik değeri büyür: $\theta_b > \theta_a$
- ω_1 karar bölgesi küçülür

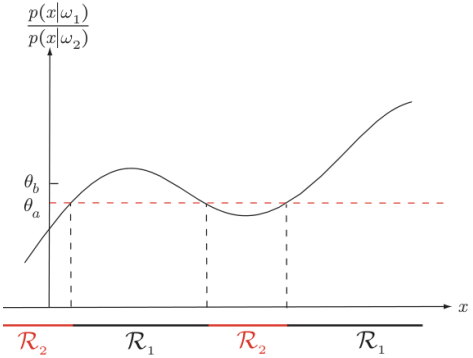

Şekil 2.3
Olabilirlik oranı $p(x|\omega_1)/p(x|\omega_2)$.
Sıfır-bir kayıpta eşik θ_a kullanılır. Hata maliyetleri asimetrik olduğunda eşik θ_b olur ve karar bölgeleri değişir.

Problem: Önsel Olasılıklar Bilinmiyorsa?

Balık sınıflandırma probleminde levrek/somon oranı fabrikadan fabrikaya veya mevsime göre değişebilir. Özellikler (parlaklık, genişlik) aynı kalsa bile

$$P(\omega_1),\ P(\omega_2)$$

değerleri **bilinmeyebilir veya değişebilir**.

Minimax Yaklaşımı

Önsel olasılıklar bilinmediğinde sınıflandırıcı, **en kötü durumda bile mümkün olan en küçük riski** verecek şekilde tasarlanır.

$$\min_{\text{sınıflandırıcı}} \max_{P(\omega_1)\in[0,1]} R\big(P(\omega_1)\big)$$

Yani **maksimum (en kötü) riski minimize etmek için**:.

1. önce en kötü risk bulunur
2. sonra bu riski minimum yapan kural seçilir

Problem: Kısıt Altında Optimizasyon

Bazı uygulamalarda belirli bir sınıfın yanlış sınıflandırılma oranını sabit bir üst sınırla kısıtlamak isteriz.

Neyman-Pearson Problemi

$$\min_{\text{sınıflandırıcı}} R \qquad \text{öyle ki} \qquad \int_{R_i} p(\mathrm{x}|\omega_i)\, d\mathrm{x} \;\leq\; \varepsilon \quad (\text{sabit})$$

Tıbbi Tanı

Kanser testi: **sağlıklı bir hastayı kanserli sanma** (yanlış pozitif / false positive) oranı en fazla %1 olsun. Bu kısıt altında sahte negatif oranını (kanserliyi gözden kaçırma) minimize et.

Balık Sınıflandırma

Yasal düzenleme: Somonu levrek olarak sınıflandırma oranı %1'i geçmesin. Bu kısıt altında levreği somon sanma oranını minimize et.

- Gaussian ve bazı dağılımlar için çözüm **analitik** olarak bulunabilir.
- Genel dağılımlar için karar sınırları **sayısal** yöntemlerle ayarlanır.

Kriter	Hedef	Ne Zaman Kullanılır?
Bayes	Toplam riski minimize et	Önsel olasılıklar ve kayıplar biliniyorsa
Minimax	En kötü senaryodaki riski minimize et	Önsellar bilinmiyor veya değişken; farklı ortamlarda kullanılacak sınıflandırıcı
Neyman-Pearson	Kısıt altında riski minimize et	Belirli bir sınıf için hata üst sınırı (yasal, güvenlik vs.) varsa

Siber Güvenlik

Saldırı tespiti: Saldırıyı gözden kaçırma oranı (*false negative rate*) %0.1 altında olmalı $\Rightarrow$ **Neyman-Pearson**

Üretim Kalite Kontrolü

Üretim hattı oranları fabrikadan fabrikaya değişiyor. Evrensel sınıflandırıcı gerekiyor $\Rightarrow$ **Minimax**

Classifier pratikte **discriminant function** kullanır.
Her sınıf için bir fonksiyon tanımlanır:

$$g_i(x)$$

Karar kuralı

$$\text{if } g_i(x) > g_j(x) \textit{then} \text{ Decide } \omega_i$$

Başka bir deyişle:

$$\omega^*(x) = \arg\max_i g_i(x)$$

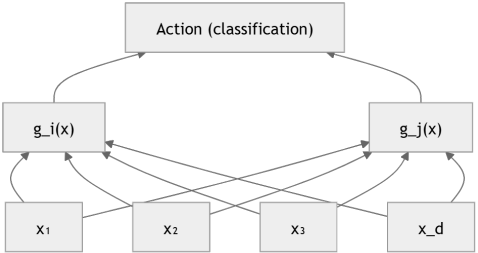

Karar sınırı, discriminant fonksiyonları eşit olduğunda oluşur:

$$g_i(x) = g_j(x)$$

Bu yüzeye
decision surface denir.

Boyuta göre

- 1D → decision boundary (nokta)
- 2D → eğri veya doğru
- 3D → yüzey

Lineer discriminant:

$$g(x) = w^T x + w_0$$

Nonlineer discriminant:

$$g(x) = x^T A x + w^T x + w_0$$

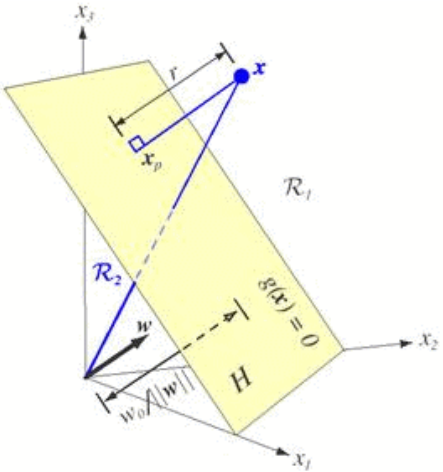

Decision surface: $g_1(x) = g_2(x)$.

Bir classifier şu adımları izler:

- Giriş özellikleri: $x = (x_1, x_2, \ldots, x_d)$
- Bu özellikler kullanılarak c adet discriminant fonksiyon hesaplanır: $g_1(x), g_2(x), \ldots, g_c(x)$
- En büyük discriminant değeri seçilir: $\omega^*(x) = \arg\max_i g_i(x)$

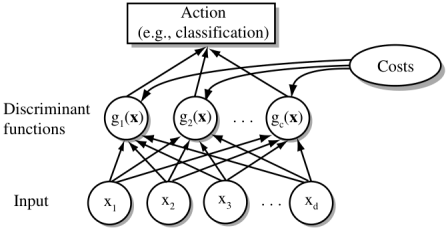

Genel pattern classifier yapısı.

Giriş özellikleri $\rightarrow$ discriminant fonksiyonları $\rightarrow$ karar.

Discriminant fonksiyonları feature space'i **karar bölgelerine** böler.

$$g_i(x) > g_j(x) \Rightarrow x \in R_i$$

Decision boundary
Karar sınırı şu noktada oluşur:

$$g_i(x) = g_j(x)$$

Önemli gözlem
Karar bölgeleri her zaman tek parça olmayabilir.

- R_2 iki ayrı bölgeden oluşabilir
- bu durumda bölge **not simply connected** olur

Bu durum karmaşık olasılık yoğunluklarında doğal olarak ortaya çıkar.

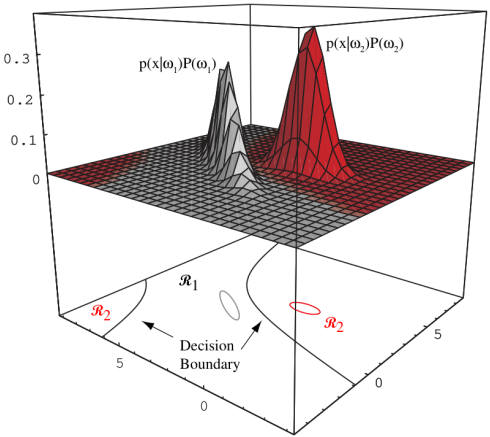

Şekil 2.6: İki boyutlu iki kategorili Gaussian sınıflandırıcı. Decision boundary iki hiperbolden oluşur. R_2 bölgesi iki ayrı parçaya ayrılmıştır.

Tanım

Bir örüntüyü yalnızca iki sınıftan birine atayan sınıflandırıcıya **dikotomizer** *(dichotomizer)* denir. İki ayrım fonksiyonu yerine **tek** fonksiyon yeterlidir:
$g(\mathrm{x}) \equiv g_1(\mathrm{x}) - g_2(\mathrm{x})$

Karar Kuralı

$$g(\mathrm{x}) > 0 \;\Rightarrow\; \omega_1; \qquad g(\mathrm{x}) < 0 \;\Rightarrow\; \omega_2$$

Karar yüzeyi: $g(\mathrm{x}) = 0$

Yorumlama:

- $g(\mathrm{x}) > 0$: ω_1 daha olası
- $g(\mathrm{x}) < 0$: ω_2 daha olası
- $g(\mathrm{x}) = 0$: karar sınırı (eşit sonsal)

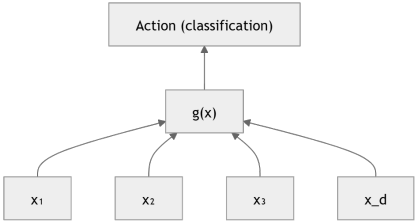

İkili Sınıflandırma Örnekleri

- Spam / spam değil
- Kanserli / sağlıklı
- Sahte / gerçek işlem (fraud detection)
- Pozitif / negatif duygu analizi

Sorularınız ?

Prof. Dr. Turgay Tugay BİLGİN

BLM0462 – Örüntü Tanıma *(Pattern Recognition)*

2025–2026 Bahar Dönemi