Bölüm 3: Parametrik Kestirim

Maximum Likelihood and Bayesian Estimation

Prof. Dr. Turgay Tugay BİLGİN

BLM0462 – Örüntü Tanıma *(Pattern Recognition)*

2025–2026 Bahar Dönemi

İçindekiler

1. 3.1 Giriş ve Motivasyon
2. 3.2 Maximum Likelihood Estimation (MLE)
3. 3.3 Bayesian Kestirim
4. 3.4 Boyutluluk Problemleri
5. 3.5 Expectation-Maximization (EM)
6. 3.6 Bayesian Belief Networks
7. 3.7 Hidden Markov Models (HMM)
8. 3.8 Kapanış

Temel Soru

Bayes sınıflandırıcısı çalışmak için dağılımları bilmek zorunda. Peki bu dağılımları nereden bulacağız? **Veriden öğreneceğiz.**

Senaryo: Balık Fabrikası

- 50 levrek ve 50 somon ölçtünüz.
- Her balığın parlaklık değerini kaydettiniz.
- Soru: Bu ölçümlerden levrek ve somon için **ortalama** ve **yayılım** değerlerini nasıl bulursunuz?

Bu Bölümde İki Yöntem Öğreneceğiz

- **MLE** *(Maximum Likelihood)*: Veriyi en iyi açıklayan parametreleri bul.
- **Bayes Kestirimi**: Elindeki ön bilgiyi de işe kat, veriyle birleştir.

Sezgi: MLE Ne Yapar?

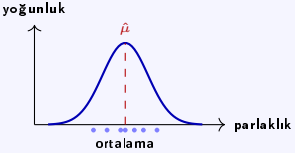

Veri noktaları (mavi) verildiğinde, üzerlerine en iyi oturan Gaussian eğrisinin $\hat{\mu}$ (tahmin edilen ortalama) ve $\hat{\sigma}^2$ (tahmin edilen varyans) değerleri MLE ile bulunur.

MLE ile Bayes Arasındaki Fark

MLE yalnızca **eldeki veriye** bakar. Bayes kestirimi ise buna ek olarak **önceden ne bildiğinizi** de hesaba katar. Az veri varsa Bayes daha güvenilirdir.

Soru

Elimizde birkaç ölçüm var. Bu ölçümleri **en iyi açıklayan** dağılım parametrelerini nasıl buluruz?

Örnek Bir sınıfa ait 5 parlaklık ölçümü aldınız:

$$\mathcal{D} = \{6,\ 7,\ 8,\ 7,\ 7\}$$

Şimdi şunu soruyoruz: hangi μ (ortalama) değeri bu veriyi **en olası** kılar?

- $\mu = 1$ deseydik, 6-8 arası değerler çok uzak kalırdı.
- $\mu = 7$ desek, tüm ölçümler ortalamanın etrafında toplanıyor. Bu çok daha makul.

MLE tam olarak bunu yapıyor: **veriyi en olası kılan parametreyi seç.**

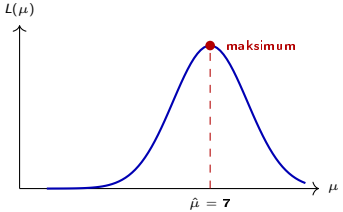

Farklı μ değerleri için olabilirlik $L(\mu)$ hesaplanır.

En yüksek noktadaki μ değeri MLE tahminidir.

MLE Fikri

$$\hat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}}\ p(\mathcal{D} \mid \boldsymbol{\theta})$$

$p(\mathcal{D} \mid \boldsymbol{\theta})$: parametreler $\boldsymbol{\theta}$ iken bu verinin gözlemlenme olasılığı. Buna **olabilirlik** *(likelihood)* denir.

Temel Kural

Olabilirliği maksimize eden $\hat{\boldsymbol{\theta}}$ değeri MLE tahminidir. Bu değer veri arttıkça gerçek parametreye yaklaşır.

Problem: Çarpım Patlar

Olabilirlik, tüm ölçümlerin olasılıklarının **çarpımıdır**. 100 bağımsız ölçüm için:

$$L(\boldsymbol{\theta}) = p(\mathrm{x}_1|\boldsymbol{\theta}) \cdot p(\mathrm{x}_2|\boldsymbol{\theta}) \cdots p(\mathrm{x}_n|\boldsymbol{\theta})$$

Her terim 0 ile 1 arasında olduğundan n büyüdükçe bu çarpım **sıfıra yaklaşır** ve bilgisayar onu sıfır olarak kaydeder. Buna *underflow* denir. Üstelik bu ifadenin türevini almak da çok zorlaşır.

Çözüm: Logaritma Al

Logaritma çarpımları toplamaya dönüştürür:

$$\ell(\boldsymbol{\theta}) = \ln L(\boldsymbol{\theta}) = \sum_{k=1}^{n} \ln p(\mathrm{x}_k|\boldsymbol{\theta})$$

Logaritma **artan** bir fonksiyon olduğundan, L'yi maksimize etmek ile ℓ'yi maksimize etmek **aynı sonucu** verir. Zirvenin yeri değişmez, ama üzerinde çalışmak çok daha kolay olur.

Sezgi

Logaritma almak, yüksek dağlık bir arazinin düzleştirilmiş bir haritasını çıkarmak gibidir. Zirvenin yeri değişmez ama üzerinde çalışmak çok daha kolay olur.

Pratik Faydaları

- Sayısal hesaplama kararlı hale gelir.
- Türev almak kolaylaşır.
- Toplam işlemi çarpıma göre çok daha hızlıdır.

Log-Olabilirlik *(Log-Likelihood)*

$$\hat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}} \sum_{k=1}^{n} \ln p(\mathrm{x}_k|\boldsymbol{\theta})$$

$\hat{\boldsymbol{\theta}}$: tahmin edilen parametre, x_k: k'ıncı ölçüm, n: toplam ölçüm sayısı.

Maksimum Nasıl Bulunur?

- $\ell(\boldsymbol{\theta})$'yı $\boldsymbol{\theta}$'ya göre türevini alıp sıfıra eşitleriz.
- Bu denklemin çözümü $\hat{\boldsymbol{\theta}}$'yı verir.
- Gaussian dağılım için bu işlem kapalı form bir çözüm üretir, yani doğrudan formülle hesaplanabilir.

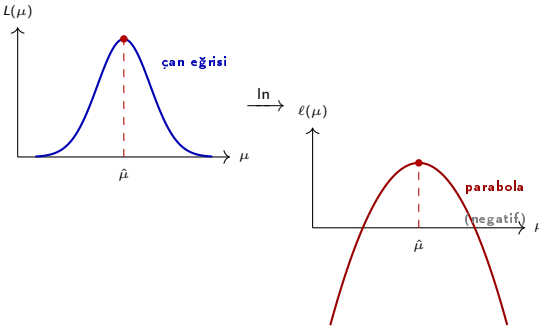

$L(\mu)$ ve $\ell(\mu)$ farklı şekillere sahip olsa da **maksimuma aynı noktada** ulaşırlar.

Özet

MLE: veriyi en iyi açıklayan parametreyi bul.
Log-likelihood: bunu sayısal olarak sağlıklı ve türev alınabilir hale getir.

Senaryo
3 levrek ölçümünüz var:

$$\mathcal{D} = \{5,\ 7,\ 6\}$$

Dağılımın Gaussian olduğunu biliyorsunuz, $\sigma^2 = 1$ sabit kabul ediliyor. Hangi μ değeri bu veriyi en iyi açıklar?
İki aday değer deneyelim:

$$\mu = 4 \quad \text{ve} \quad \mu = 6$$

Gaussian Log-Olabilirlik

$$\ell(\mu) = -\frac{1}{2\sigma^2}\sum_{k=1}^{n}(x_k - \mu)^2 + \text{sabit}$$

Sabit terim her iki adayda da aynı olduğundan yalnızca **karesel sapma toplamına** bakıyoruz.

Temel Kural

Karesel sapma toplamı **küçüldükçe** log-olabilirlik **büyür**.
En küçük sapma = en iyi μ.

Sezgi

Hangi μ değeri veri noktalarına daha yakınsa, o değer veriyi daha iyi açıklıyor demektir. Uzaklıkların karesini alıp topluyoruz çünkü hem sağdaki hem soldaki sapmaları aynı şekilde cezalandırmak istiyoruz.

$\mu = 4$ **için karesel sapmalar:**

x_k	$x_k - 4$	$(x_k - 4)^2$
5	$+1$	1
7	$+3$	9
6	$+2$	4
	toplam	**14**

$\mu = 6$ **için karesel sapmalar:**

x_k	$x_k - 6$	$(x_k - 6)^2$
5	-1	1
7	$+1$	1
6	0	0
	toplam	**2**

Karşılaştırma

$\mu = 4$ için toplam sapma: **14**
$\mu = 6$ için toplam sapma: **2**
$\mu = 6$ veri noktalarına çok daha yakın, dolayısıyla veriyi çok daha iyi açıklıyor.

Soru

Elimizde n adet ölçüm var. Bu ölçümlerin ortalamasını $\hat{\mu}$ ile tahmin etmek istiyoruz. MLE bize ne diyor?

Adım adım düşünelim:

- Her ölçüm x_k, bilinmeyen μ etrafında dağılmış durumdadır.
- MLE şunu soruyor: hangi μ değeri bu ölçümleri **en olası** kılar?
- Cevap şaşırtıcı değil: **ölçümlerin ortalaması**.

MLE Tahmini

$$\hat{\mu} = \frac{1}{n}\sum_{k=1}^{n} x_k$$

Veri noktalarının sıradan **aritmetik ortalaması**.

Önemli Mesaj MLE'nin gücü şuradan geliyor: sıradan bir ortalama hesabının arkasına **sağlam bir olasılıksal gerekçe** koyuyor.

Balık Fabrikası Örneği

5 levreğin parlaklığını ölçtünüz:

$$\mathcal{D} = \{6,\ 7,\ 8,\ 7,\ 7\}$$

MLE tahmini:

$$\hat{\mu} = \frac{6+7+8+7+7}{5} = 7$$

Zaten aklınızın köşesinde hep yaptığınız şey buydu. MLE bunu matematiksel olarak **doğruladı**

Soru

Ortalamayı bulduk. Peki ölçümlerin ne kadar **yayıldığını**, yani varyansı nasıl tahmin ederiz?

MLE aynı mantıkla şunu söylüyor: her ölçümün tahmini ortalamadan ne kadar uzakta olduğuna bak, bu uzaklıkların karesinin ortalamasını al.

MLE Tahmini: Varyans

$$\hat{\sigma}^2 = \frac{1}{n}\sum_{k=1}^{n}(x_k - \hat{\mu})^2$$

Her ölçümün ortalamadan **karesel sapmasının** ortalaması.

Balık Fabrikası Örneği

$\mathcal{D} = \{6,\ 7,\ 8,\ 7,\ 7\}, \quad \hat{\mu} = 7$

Her ölçümün sapmalarının karesi:

x_k	$x_k - \hat{\mu}$	$(x_k - \hat{\mu})^2$
6	-1	1
7	0	0
8	$+1$	1
7	0	0
7	0	0

$$\hat{\sigma}^2 = \frac{1+0+1+0+0}{5} = 0.4$$

Gerçek Hayata Bir Adım Daha Yakın

Tek bir özellik yerine artık **birden fazla özellik** ölçüyoruz. Örneğin hem parlaklık hem ağırlık. Bu durumda her ölçüm tek bir sayı değil, bir **vektör** oluyor:

$$\mathbf{x}_k = (x_{k1},\ x_{k2},\ \ldots,\ x_{kd})^\top$$

d: özellik sayısı, n: ölçüm sayısı.

Ortalama Vektörü Tahmini

Tek değişkenli durumla tamamen aynı mantık geçerli. Tek fark: her özellik için **ayrı ayrı** ortalama alınıyor ve bunlar bir vektörde birleştiriliyor.

MLE: Ortalama Vektörü

$$\hat{\boldsymbol{\mu}} = \frac{1}{n}\sum_{k=1}^{n} \mathbf{x}_k$$

Balık Fabrikası: 2 Özellik

Her levrek için hem parlaklık hem ağırlık ölçülüyor.

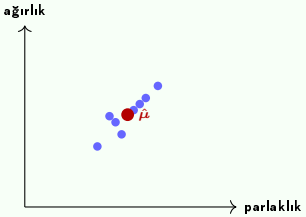

Mavi noktalar ölçümleri, kırmızı nokta ise MLE ile bulunan ortalama vektörünü gösteriyor. Her eksen kendi ortalamasını bağımsız olarak hesaplıyor.

Özellikler Arasındaki İlişki

Tek değişkenli durumda yayılımı ölçmek için varyans yeterliydi. Birden fazla özellik olunca şunu da sormak gerekiyor: özellikler birlikte nasıl hareket ediyor? Parlaklık artınca ağırlık da artıyor mu? Bunu **kovaryans matrisi** $\hat{\Sigma}$ yakalıyor.

MLE: Kovaryans Matrisi

$$\hat{\Sigma} = \frac{1}{n}\sum_{k=1}^{n}(x_k - \hat{\mu})(x_k - \hat{\mu})^\top$$

Her ölçümün ortalamadan sapması hesaplanıyor, bu sapmalar çarpılarak ortalaması alınıyor.

Kovaryans Ne Anlatır?

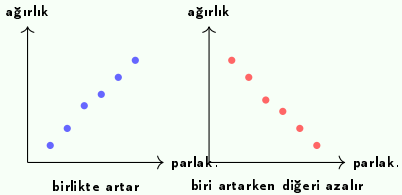

Kovaryans matrisi bu iki durumu birbirinden ayırt eder ve sınıflandırıcıya özellikler arasındaki ilişkiyi öğretir.

3 levrek ölçümü: parlaklık ve ağırlık

	Parlaklık x_1	**Ağırlık** x_2
Balık 1	2	4
Balık 2	4	5
Balık 3	6	9
$\hat{\boldsymbol{\mu}}$	4	6

Ortalamadan sapmalar:

	$x_1 - \hat{\mu}_1$	$x_2 - \hat{\mu}_2$
Balık 1	-2	-2
Balık 2	0	-1
Balık 3	$+2$	$+3$

Her satır için sapma vektörünü kendisiyle çarpıyoruz:

Kovaryans Matrisi

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{3}\left[\begin{pmatrix}-2\\-2\end{pmatrix}(-2\ -2)+\begin{pmatrix}0\\-1\end{pmatrix}(0\ -1)+\begin{pmatrix}2\\3\end{pmatrix}(2\ 3)\right]$$

$$= \frac{1}{3}\begin{pmatrix}8 & 10\\10 & 14\end{pmatrix} = \begin{pmatrix}2.67 & 3.33\\3.33 & 4.67\end{pmatrix}$$

Dikkat

Her sapma vektörü 2×1 boyutunda, transpozesi 1×2 boyutunda. Bunların çarpımı 2×2 boyutunda bir matris üretiyor. Üç matrisin toplamının $\frac{1}{3}$ ile çarpılması kovaryans matrisini veriyor.

Hesapladığımız matris şuydu:

$$\hat{\Sigma} = \begin{pmatrix} 2.67 & 3.33 \\ 3.33 & 4.67 \end{pmatrix}$$

Köşegen elemanlar her özelliğin kendi varyansıdır. Parlaklığın varyansı 2.67, ağırlığın varyansı 4.67. Ağırlık ölçümleri ortalama etrafında parlaklığa göre daha fazla yayılıyor.
Köşegen dışı eleman iki özellik arasındaki kovaryansı gösteriyor: 3.33. Bu değer ne parlaklığın ne de ağırlığın varyansıyla aynı, tamamen ayrı bir bilgi taşıyor: parlaklık artınca ağırlık da artma eğiliminde.
İşaret neyi değiştirir?

- **Pozitif**: birlikte artar.
- **Negatif**: biri artarken diğeri azalır.
- **Sıfır**: birbirinden bağımsız.

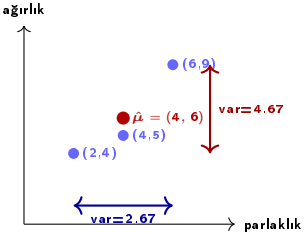

Önemli Mesaj

Üç değer de birbirinden farklı: parlaklık varyansı (2.67), ağırlık varyansı (4.67) ve kovaryans (3.33). Kovaryans ayrı bir bilgi taşıyor: iki özelliğin birlikte ne kadar hareket ettiğini ölçüyor.

MLE'nin Zayıf Noktası

MLE yalnızca **eldeki veriye** bakar. Veri azsa tahmin güvenilmez olabilir. Örneğin 3 balık ölçümünden elde edilen ortalama, gerçek ortalamadan çok uzakta olabilir.

Bayesian Kestirim Ne Yapar?

- Parametre $\boldsymbol{\theta}$ hakkında **önceden** bir bilginiz var. Buna **önsel** *(prior)* denir.
- Veriyi gözlemledikten sonra bu bilgiyi **güncellersiniz**. Elde ettiğiniz yeni bilgiye **sonsal** *(posterior)* denir. Güncelleme Bayes formülüyle yapılır.

Bayesian Güncelleme

$$\underbrace{p(\boldsymbol{\theta}|\mathcal{D})}_{\text{sonsal}} \propto \underbrace{p(\mathcal{D}|\boldsymbol{\theta})}_{\text{olabilirlik}} \cdot \underbrace{p(\boldsymbol{\theta})}_{\text{önsel}}$$

Veriyi gördükten sonra ne biliyoruz? Veri öncesi ne biliyorduk, veri bunu nasıl değiştirdi?

Balık Fabrikası Benzetmesi

Yeni bir fabrikaya geçtiniz. Levreğin ortalama parlaklığı hakkında hiç fikriniz yok mu? Aslında var: geçmiş deneyimlerinizden levreğin genellikle belli bir parlaklık aralığında olduğunu biliyorsunuz. Bu sizin **önseliniz**.
Şimdi 3 levrek ölçüyorsunuz. Bu az veri MLE için zayıf, ama Bayesian kestirim için önselinizle birleştirerek hâlâ makul bir tahmin üretiyor.

MLE ile Farkı Tek Cümlede

MLE parametre $\boldsymbol{\theta}$'yı **tek bir sabit değer** olarak tahmin eder. Bayesian kestirim ise $\boldsymbol{\theta}$ hakkındaki **belirsizliği bir dağılımla** ifade eder ve veri geldikçe bu dağılımı günceller.

Önsel Dağılım Nedir?

Veriyi görmeden önce $\boldsymbol{\theta}$ (parametre) hakkında ne biliyorsunuz? Bu bilgiyi bir **olasılık dağılımıyla** ifade ediyorsunuz. Buna **önsel dağılım** *(prior distribution)* denir.

Gaussian Örneği

Levreğin ortalama parlaklığını μ ile tahmin etmek istiyorsunuz. Geçmiş deneyimlerinizden μ'nun yaklaşık 6 civarında olduğunu, ama tam emin olmadığınızı düşünüyorsunuz. Bunu şöyle ifade edebilirsiniz:

$$p(\mu) = \mathcal{N}(\mu_0, \sigma_0^2)$$

$\mu_0 = 6$: başlangıç tahmininiz, σ_0^2: bu tahminden ne kadar emin olduğunuzu gösteriyor.

Önsel Dağılımın Genişliği

- **Dar önsel**: μ'nun nerede olduğuna dair güçlü bir ön bilginiz var.
- **Geniş önsel**: çok emin değilsiniz, μ geniş bir aralıkta olabilir.

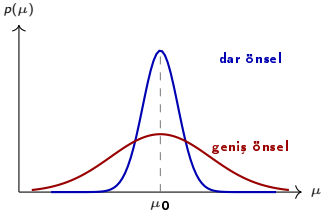

Her iki önsel de μ_0 etrafında ortalanmış. Mavi (dar): μ'nun kesin olarak μ_0 yakınında olduğunu söylüyor. Kırmızı (geniş): μ'nun geniş bir aralıkta olabileceğini söylüyor, yani daha az kesin bir bilgi.

Sezgi

Geniş önsel, veriye daha fazla söz hakkı tanır. Dar önsel ise ön bilgiyi daha baskın kılar. Veri çok fazlaysa her iki durumda da sonuç birbirine yaklaşır.

Veri Geldikten Sonra Ne Değişir?

Önsel dağılım veriyi görmeden önceki bilginizi temsil ediyordu. Veriyi $\mathcal{D}$ gözlemledikten sonra bu bilgi **güncellenir** ve **sonsal dağılım** *(posterior distribution)* elde edilir:

$$p(\mu|\mathcal{D}) = \mathcal{N}(\mu_n, \sigma_n^2)$$

Gaussian dağılım ve Gaussian önsel için güncelleme formülleri kapalı form olarak elde edilir:

Güncelleme Formülleri

$$\mu_n = \frac{\sigma^2\,\mu_0 + n\sigma_0^2\,\hat{\mu}}{\sigma^2 + n\sigma_0^2} \qquad \sigma_n^2 = \frac{\sigma^2\,\sigma_0^2}{\sigma^2 + n\sigma_0^2}$$

μ_0: önsel ortalama, $\hat{\mu}$: veri ortalaması, n: ölçüm sayısı.

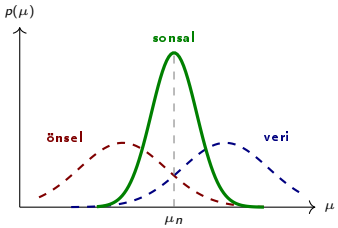

Önsel (kırmızı) ve verinin işaret ettiği bölge (mavi) birleşerek sonsal dağılımı (yeşil) oluşturuyor. Sonsal ikisi arasında bir noktaya yerleşiyor ve her ikisinden de daha **dar**, yani daha emin.

Veri Arttıkça Ne Olur?

n büyüdükçe σ_n^2 küçülür, yani sonsal dağılım giderek daralır. Parametre hakkındaki belirsizlik azalır ve sonsal MLE tahminine yaklaşır.

Senaryo

Levreğin ortalama parlaklığını tahmin ediyorsunuz. Geçmiş deneyimden önseliniz var:

$$\mu_0 = 6, \quad \sigma_0^2 = 4$$

Parlaklık ölçümlerinin gerçek varyansı:

$$\sigma^2 = 2$$

Şimdi 3 levrek ölçüyorsunuz:

$$\mathcal{D} = \{5,\ 7,\ 6\} \quad \Rightarrow \quad \hat{\mu} = 6$$

Sonsal Ortalama:

$$\mu_n = \frac{\sigma^2\,\mu_0 + n\sigma_0^2\,\hat{\mu}}{\sigma^2 + n\sigma_0^2} = \frac{2 \times 6 + 3 \times 4 \times 6}{2 + 3 \times 4} = \frac{84}{14} = 6$$

Sonsal Varyans:

$$\sigma_n^2 = \frac{\sigma^2\,\sigma_0^2}{\sigma^2 + n\sigma_0^2} = \frac{2 \times 4}{2 + 12} = \frac{8}{14} \approx 0.57$$

Ne Değişti?

	Ortalama	Varyans
Önsel	6.00	4.00
Sonsal	6.00	0.57

Ortalama değişmedi çünkü veri ortalaması ($\hat{\mu} = 6$) önsel ortalama ($\mu_0 = 6$) ile aynıydı. Ama varyans **dramatik biçimde küçüldü**: 4'ten 0.57'ye. Yani **aynı noktada daha emin olduk.**

Sezgi

3 ölçüm önselinizi doğruladı. Artık $\mu = 6$ tahminine çok daha güvenle bakıyorsunuz. Belirsizliğiniz yedide birine indi. Daha fazla ölçüm yapılsaydı varyans sıfıra yaklaşmaya devam edecekti.

Peki Veri Önsellle Çelişseydi? Örneğin $\hat{\mu} = 9$ çıksaydı, sonsal ortalama 6 ile 9 arasında bir yerde yerleşecekti. Hangisine daha yakın olacağı n ve σ_0^2 değerlerine göre belirlenirdi.

İki Yöntem Ne Zaman Ayrışır?

Veri çok fazlaysa MLE ve Bayesian kestirim birbirine çok yakın sonuç üretir. Asıl fark **az veri** durumunda ortaya çıkar.

Somut Senaryo

Levreğin ortalama parlaklığını tahmin ediyorsunuz. Gerçek ortalama $\mu = 6$.

- **MLE** yalnızca eldeki ölçümlere bakıyor. 3 ölçümden biri uç değerse tahmin ciddi şekilde sapıyor.
- **Bayes** ise önsel bilgiyi devreye sokuyor. Önsel $\mu_0 = 6$ etrafında yoğunlaşmışsa, uç bir ölçüm tahmini o kadar saptıramıyor.

Veri Arttıkça

$n \to \infty$ durumunda önsel bilginin etkisi giderek azalır ve Bayesian kestirim MLE ile aynı sonuca ulaşır. Yani Bayes, MLE'yi özel bir durum olarak içeriyor.

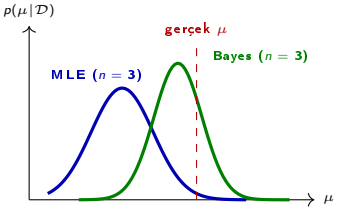

Az veriyle ($n = 3$) MLE (mavi) gerçek değerden uzakta kalıyor. Bayes (yeşil) önsel bilgi sayesinde gerçeğe daha yakın duruyor.

Hangi Yöntemi Seçmeli?

Veri bolsa MLE yeterli ve basit. Veri azsa ve parametreler hakkında ön bilginiz varsa Bayesian kestirim daha güvenilir sonuç verir.

Problem

Özellik sayısı d arttıkça iyi bir tahmin için gereken **veri miktarı katlanarak artıyor**. Buna boyutluluk laneti denir.

Sezgisel Açıklama

Tek özellikle (parlaklık) çalışıyorsunuz. 10 ölçüm yeterli diyelim. Şimdi ikinci bir özellik (ağırlık) ekliyorsunuz. Artık her iki özelliği birlikte iyi kapsayabilmek için çok daha fazla ölçüme ihtiyaç duyuyorsunuz. Üçüncü, dördüncü özellikler ekledikçe bu ihtiyaç patlamaya başlıyor.

Basit Kural

d özellik varsa ve her özellik için k ölçüm yeterliyse, tüm uzayı kapsamak için kabaca k^d ölçüme ihtiyaç var. $k = 10$, $d = 3$ için bu **1000** demek.

Sonuç

Boyut arttıkça veri noktaları uzayda **seyrekleşir**. Seyrek veriyle tahmin edilen dağılım güvenilmez olur ve sınıflandırıcı zayıflar.

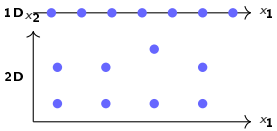

1D'de 7 nokta alanı iyi kaplıyor. Aynı nokta sayısı 2D'de uzayı çok daha seyrek dolduruyor. 3D, 4D... düşündükçe durum giderek kötüleşiyor.

Pratik Öneri

Gereksiz özellikler eklemek sınıflandırıcıyı güçlendirmiyor, aksine zayıflatıyor. Her yeni özellik beraberinde daha fazla veri ihtiyacı getiriyor. Az veriyle çalışıyorsanız az ama anlamlı özellikler seçin.

Somut Senaryo

Her özellik için 10 farklı değer gözlemlemek istiyorsunuz. Yeterli kapsama için kaç ölçüme ihtiyaç var?

Özellik Sayısı	İhtiyaç	Örnek
1 özellik	$10^1 = 10$	parlaklık
2 özellik	$10^2 = 100$	+ ağırlık
3 özellik	$10^3 = 1.000$	+ uzunluk
5 özellik	$10^5 = 100.000$	+ 2 özellik daha
10 özellik	$10^{10} = 10$ milyar	+ 5 özellik daha

Çarpıcı Sonuç

1 özellikten 10 özelliğe geçince ihtiyaç duyulan veri miktarı **10'dan 10 milyara** çıkıyor. Oysa sadece 9 özellik ekledik.

Peki Gerçekte Ne Olur?

Elimizde genellikle sınırlı sayıda ölçüm var. Özellik sayısı arttıkça veri noktaları uzayda **giderek seyrekleşiyor**.

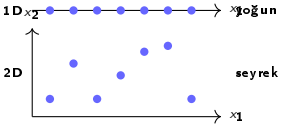

Aynı 7 nokta 1D'de alanı iyi kaplıyor. 2D'de ise uzay çok daha boş kalıyor. 3D, 4D düşününce durum giderek kötüleşiyor.

Pratik Öneri

Her yeni özellik beraberinde katlanarak artan veri ihtiyacı getiriyor. Az veriyle çalışıyorsanız **az ama anlamlı** özellikler seçmek çok daha iyi sonuç veriyor.

Problem

Model eğitim verisini çok iyi öğrenirse **eğitim hatasını sıfıra** yaklaştırabilir. Ama yeni bir veri geldiğinde **berbat tahminler** üretir. Buna overfitting denir.

Ne Zaman Olur?

- Veri az, model karmaşıksa.
- Model veriyi ezberliyor, genel örüntüyü öğrenmiyor.
- Eğitim hatası düşük, test hatası yüksek.

Balık Fabrikası Benzetmesi

10 levrek ölçtünüz ve bu 10 balığa mükemmel uyan karmaşık bir eğri çizdiniz. Ama fabrikaya yeni gelen levrekler bu eğriye uymayabilir. Siz genel levrek profilini değil, o 10 balığı ezberlediniz.

Basit Kural

Eğitim ve test hatası arasındaki **makas ne kadar büyükse** overfitting o kadar şiddetlidir.

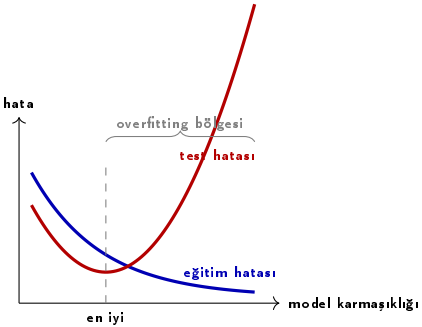

Model karmaşıklaştıkça eğitim hatası düşmeye devam eder. Test hatası ise önce düşer, sonra tekrar yükselir. Makasın açıldığı bölge overfitting bölgesidir.

Çözüm Yolları

Daha fazla veri toplamak en etkili çözümdür. Veri toplanamıyorsa modeli basitleştirmek ya da regularization uygulamak overfitting'i azaltır.

Problem: Eksik Veri

Bazen verinin bir kısmını **gözlemleyemiyoruz**. Örneğin elimizdeki balık ölçümlerinin hangi türe ait olduğunu bilmiyoruz. Etiket yok. MLE bu durumda doğrudan uygulanamıyor çünkü log-olabilirliği maksimize etmek zorlaşıyor. EM algoritması tam bu sorunu çözüyor.

EM İki Adımı Sırayla Tekrarlıyor:

- **E-adımı** *(Expectation):* Mevcut parametre tahminlerini kullanarak her ölçümün hangi gruba ait olduğunu **tahmin et.**
- **M-adımı** *(Maximization):* Bu grup tahminlerini kullanarak parametreleri **güncelle.**

Bu iki adım parametreler **sabit bir değere oturana kadar** tekrarlanır.

Temel Garanti

Her iterasyonda parametreler biraz daha iyileşir. Bir süre sonra değişim o kadar küçülür ki tahminler **sabit bir değere oturur**. EM bu noktada durur. Geriye gitmez, her adım ya ileri gider ya da yerinde sayar.

Balık Fabrikası Benzetmesi

Karışık bir kovadan balık çekiyorsunuz ama levrek mi somon mu olduğunu göremiyorsunuz.
E-adımı: Şu anki tahminlerinize göre her balığın levrek olma olasılığını hesapla.
M-adımı: Bu olasılıkları kullanarak levrek ve somon için yeni ortalama ve varyans tahminleri üret.
Tekrarla. Her turda $\hat{\mu}$ ve $\hat{\Sigma}$ tahminleri biraz daha iyileşiyor ve sonunda sabit kalıyor.

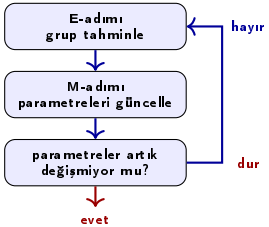

Senaryo
4 balık ölçümü var, etiket yok. Hangileri levrek, hangileri somon bilinmiyor:

$$\mathcal{D} = \{3,\ 4,\ 7,\ 8\}$$

2 grup olduğunu biliyoruz. Başlangıç tahminlerimiz:

$$\mu_1 = 4, \quad \mu_2 = 7$$

E-adımı: Her ölçümü gruplara ata
Her ölçüm için hangi ortalamaya daha yakın olduğuna bakıyoruz:

x_k	$\lvert x_k - \mu_1 \rvert$	$\lvert x_k - \mu_2 \rvert$	**Grup**
3	1	4	Grup 1
4	0	3	Grup 1
7	3	0	Grup 2
8	4	1	Grup 2

M-adımı: Parametreleri Güncelle
Her grubun yeni ortalamasını hesaplıyoruz:

$$\mu_1^{\text{yeni}} = \frac{3+4}{2} = 3.5$$

$$\mu_2^{\text{yeni}} = \frac{7+8}{2} = 7.5$$

İkinci Tur E-adımı
Güncellenmiş $\mu_1 = 3.5$, $\mu_2 = 7.5$ ile tekrar atama yapıyoruz. Atamalar değişmedi, **parametreler sabit kaldı. Dur.**

Sonuç

	Grup 1	**Grup 2**
Ölçümler	{3, 4}	{7, 8}
Ortalama	3.5	7.5

Etiket olmadan EM iki grubu kendiliğinden **doğru biçimde ayırdı.**

Fikir

Bazen verinin tamamı tek bir Gaussian ile açıklanamıyor. Veri **birden fazla gruptan** geliyor olabilir. Gaussian Karışım Modeli her grubu ayrı bir Gaussian ile temsil ediyor ve EM ile bu grupları otomatik olarak öğreniyor.

Balık Fabrikası Örneği

Levrek ve somon ölçümleri etiket olmadan karışık geldi. Her tür kendi ortalaması ve varyansı olan ayrı bir Gaussian. EM bu iki Gaussian'ın parametrelerini veriden öğreniyor.

GMM Modeli

$$p(\mathrm{x}) = \sum_{k=1}^{K} \pi_k \, \mathcal{N}(\mathrm{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

K: grup sayısı, π_k: k. grubun karışım ağırlığı (o gruba ait olma olasılığı), $\boldsymbol{\mu}_k$, $\boldsymbol{\Sigma}_k$: k. grubun ortalama ve kovaryansı.

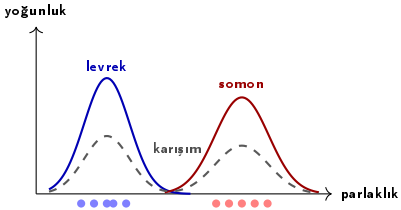

Mavi ve kırmızı noktalar iki farklı gruptan gelen ölçümler. EM etiket olmadan bu iki Gaussian'ı otomatik olarak buluyor.

E ve M Adımları GMM'de

E-adımı: Her ölçüm için hangi Gaussian'a ait olduğunun olasılığını hesapla.
M-adımı: Bu olasılıkları kullanarak her Gaussian'ın $\boldsymbol{\mu}_k$, $\boldsymbol{\Sigma}_k$ ve π_k değerlerini güncelle.

Sorularınız?

Prof. Dr. Turgay Tugay BİLGİN

BLM0462 – Örüntü Tanıma *(Pattern Recognition)*

2025–2026 Bahar Dönemi