Hidden Markov Model

Ders Notu

1. Giris: HMM Nedir?

Hidden Markov Modeli (HMM), gizli (yani dogrudan gozlemlenemeyen) durumlar arasindaki gecisleri ve bu durumlardan uretilen gozlemleri modelleyen istatistiksel bir araçtir.

Adini iki bileseninden alir: "Hidden" (gizli) kismi, modelin iç durumlarinin dogrudan gorulemedigini; "Markov" kismi ise bir durumun yalnizca bir onceki duruma bagimli oldugunu ifade eder.

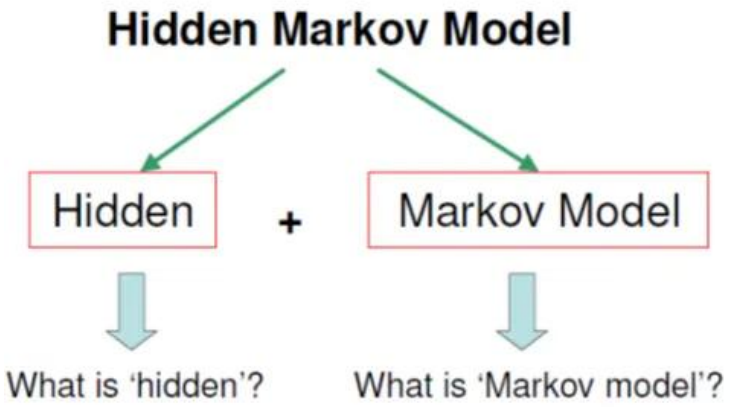

Sekil 1.1: HMM = Gizli (Hidden) + Markov Modeli. Solda gizli durumlar, sagda Markov zinciri anlamini gostermektedir.

Ornek: Gunluk Hayattan Analoji

Bir arkadasinizin sadece sosyal medya paylasimlarini (emoji, fotograf) goruyorsunuz; ama o arkadasinizin o an nasil hissettigi (mutlu, uzgun, yorgun) sizin icin gizli.

Gizli durum = Arkadasinizin hissi (mutlu / uzgun / yorgun)
Gozlem = Paylasiminin icerik turu (gulen emoji, manzara foto, sikayet mesaji)

HMM, bu "paylasimlardan" yola cikarak arkadasinizin "hissini" tahmin etmeye calisir.

HMM'in kullanildigi bazi alanlar: konusma tanima, el yazisi tanima, DNA dizi analizi, hava durumu tahmini ve robotlarin konum takibi.

2. Markov Zinciri ve Markov Ozelligi

HMM'i anlamak icin once Markov Zinciri kavramindan baslamamiz gerekir.

2.1. Markov Ozelligi

Tanim: "Bir sistemin gelecekteki durumu, yalnizca mevcut durumuna baglidir; gecmis durumlara bakmak gerekli degildir."

Ornek: Hava Durumu Markov Zinciri

Durumlar: Gunes / Yagmur

Gec.Olas. Tablosu:
Bugun Gunes -> Yarin Gunes: 0.9 Yarin Yagmur: 0.1
Bugun Yagmur -> Yarin Gunes: 0.3 Yarin Yagmur: 0.7

Yorum: Bugun gunes aciksa, yarin da gunes olma ihtimali %90'dir.
Gecen haftanin hava durumu bu hesaba dahil DEGILDIR; sadece "bugun" onemlidir.

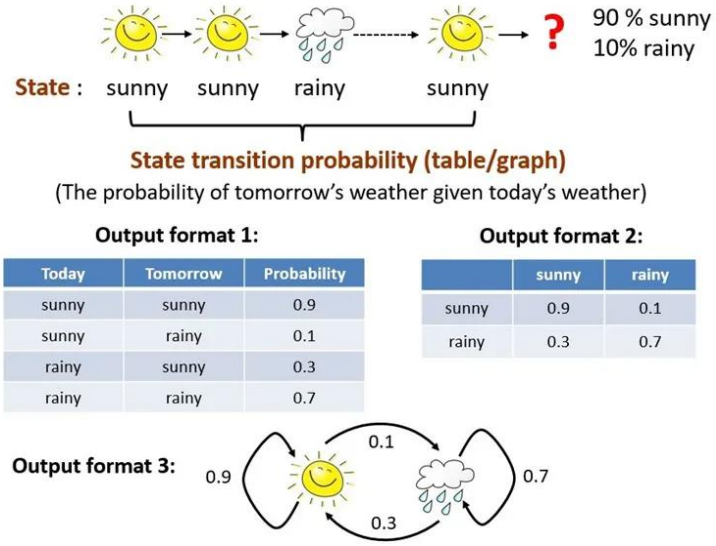

Today	Tomorrow	Probability
sunny	sunny	0.9
sunny	rainy	0.1
rainy	sunny	0.3
rainy	rainy	0.7

	sunny	rainy
sunny	0.9	0.1
rainy	0.3	0.7

Sekil 2.1: Hava durumu icin durum gecis olasiliklari. Ayni tablonun uc farkli gosterim bicimi (satir/sutun tablo, matris ve cizge).

2.2. Markov Zinciri vs. HMM

Markov Zincirinde butun durumlar gozlemlenebilir. HMM'de ise durumlar gizlidir; sadece bu durumlardan uretilen "ipuclari" (gozlemler) elimizdedir.

Ozellik	Markov Zinciri	Hidden Markov Model
Durumlar	Dogrudan gorulur	Gizlidir, tahmin edilir

Neler biliniyor?	Gecis olasiliklari	Gecis + Emisyon olasiliklari
Temel soru	Siradaki durum ne?	Gizli durum dizisi nedir?
Ornek kullanim	Sade hava tahmini	Konusma tanima, DNA analizi

3. HMM Yapisi ve Parametreler

Bir HMM tanimlamak icin bes parametreye ihtiyac vardir. Bir tane somut ornek uzerinden tum bunlari gorelim.

Ornek: Dondurma Tüketimi Ornegi (Klasik HMM Ornegi)

Senaryo: Bir arastirmaci, gunluk tüketilen dondurma sayisini not ediyor (1, 2 veya 3 top).
Ama o gunku havanin SICAK mi yoksa SOGUK mu oldugunu bilmiyor.

Gizli durumlar = Havanin sicakligi: HOT (sicak) veya COLD (soguk)
Gozlemler = Yenilen dondurma sayisi: 1, 2 veya 3

Soru: Dondurma sayisi verilerinden havanin sicakligini tahmin edebilir miyiz?

3.1. Bes Parametre

Sembol	Ad	Anlami	Ornek
N	Durum Sayisi	Kac gizli durum var	2 (HOT, COLD)
Q	Durumlar	Gizli durum kumesi	{HOT, COLD}
V	Gozlemler	Gozlemlenebilir ciktilar	{1, 2, 3}
pi	Baslangic Olasiliklari	Ilk durumun dagilimi	P(HOT)=0.8, P(COLD)=0.2
A	Gecis Matrisi	Bir durumdan digerine gecme	P(COLD|HOT)=0.3
B (veya E)	Emisyon Matrisi	Durumdan gozlem uretme	P(3|HOT)=0.4

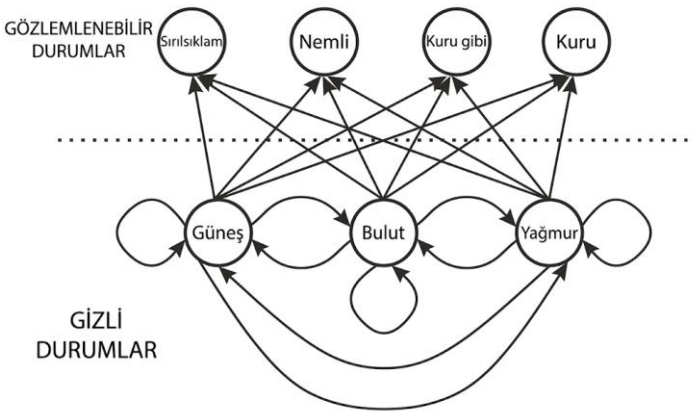

Sekil 3.1: Markov Zinciri (sol) ile HMM (sag) parametre farki. HMM'e ek olarak V (gozlemler) ve E (emisyon olasiliklari) eklenmistir.

3.2. Baslangic Olasiliklari (pi)

Modelin hangi durumda BASLADIGINI olasiliklarla ifade eder. Tum baslangic olasiliklaerinin toplami 1 olmalidir:

$pi_i = P(q1 = s_i)$, yani t=1 aninda sistemin s_i durumunda olma olasiligi

Kural: $pi_1 + pi_2 + ... + pi_N = 1$

Dondurma orneginde: pi_HOT = 0.8, pi_COLD = 0.2
(Yani model %80 olasilikla "sicak" bir gunle baslıyor.)

3.3. Gecis Matrisi (A)

Bir durumdan diger bir duruma gecme olasiligini gosterir. Satirlardaki degerler toplamda 1 olmalidir.

Ornek: Dondurma ornegi - Gecis Matrisi A

	Siradaki Durum	
	HOT	COLD
Simdi HOT	0.7	0.3
Simdi COLD	0.4	0.6

Yorum: Bugun hava sicaksa (%70 ihtimalle) yarin da sicak olur; %30 ihtimalle soguk olur.

3.4. Emisyon Matrisi (B veya E)

Bir gizli durumda bulunurken hangi gozlemin uretileceginin olasiligini gosterir. Satirlardaki degerler toplamda 1 olmalidir.

Ornek: Dondurma ornegi - Emisyon Matrisi B

```
            Gozlem (dondurma sayisi)
                    1 top   2 top   3 top
Durum  HOT    [ 0.2     0.4     0.4   ]
Durum  COLD   [ 0.5     0.4     0.1   ]
```

Yorum: Hava sicakken 3 top dondurma yenme ihtimali %40'tir.
Hava sogukken ise bu ihtimal yalnizca %10'dur.

4. HMM'in Üç Temel Problemi

HMM ile ilgili her soru, üç farkli problem turunden birine girer. Her problem icin farkli bir algoritma kullanilir:

Problem	Soru Soruyor	Algoritma	Gercek Hayat Ornegi
1. Evaluation (Degerlendirme)	"Bu gozlem dizisi bu modelden mi geldi?"	Forward	Konusma tanima: ses hangi kelime?
2. Decoding (Cozumleme)	"Hangi gizli durum dizisi en olasiliklidir?"	Viterbi	Dondurma: hangi gunler sicakti?
3. Learning (Ogrenme)	"Model parametrelerini veriden ogrenemez miyiz?"	Baum-Welch	Hiç etiket yok, parametreleri bul

5. Evaluation - Forward Algoritmasi

5.1. Problem Tanimi

Elimizde bir HMM (A, B, pi biliyor) ve gozlem dizisi O = [o_1, o_2, ..., o_T] var. Soru: Bu gozlem dizisinin bu modelden gelme olasiligi P(O | model) nedir?

Neden bu soruyu sorariz? Birden fazla HMM modelimiz varsa (ornegin, farkli diller icin farkli konusma modelleri), hangi modelin bu sesle daha uyumlu oldugunu bulmak isteriz.

5.2. Forward Algoritmasi (Verimli Yol)

Forward algoritmasi, dinamik programlama ile bu hesabi cok daha verimli yapar. Daha once hesaplanan kucuk sonuclari tekrar kullanarak tekrar hesaplamaktan kacinar.

alfa_t(j) = t anina kadar gelen gozlemleri gormus ve t aninda j durumunda olma olasiligi.

```
Adim 1 - Baslangic: alfa_1(j) = pi_j x B_j(o_1)
  Her j durumu icin: baslangic olasiligi x ilk gozlemin emisyon olasiligi

Adim 2 - Ozyineleme (t=2'den T'ye):
  alfa_t(j) = [ TOPLAM_i ( alfa_t-1(i) x A_ij ) ] x B_j(o_t)
  Onceki adimdan j'ye gelen tum yollar topla, sonra yeni gozlemi carpan

Adim 3 - Sonlandirma:
  P(O | model) = TOPLAM_j alfa_T(j)
```

6. Decoding - Viterbi Algoritmasi

6.1. Problem Tanimi

Elimizde yine O = [o_1, ..., o_T] gozlem dizisi var. Bu sefer soru farkli: Bu gozlemleri en iyi aciklayan gizli durum dizisi hangisidir?

Dondurma orneginde: "3 1 3 gozlemini gorduk; o gunler hava HOT muydu COLD muydu?"

```
Forward ile Viterbi arasindaki fark:

Forward:  Tum olasilikli durum yollarini TOPLAR  ->  P(O | model)
Viterbi:  En yuksek olasilikli TEK yolu BULUR    ->  argmax P(Q | O, model)
```

6.2. Viterbi Algoritmasi Adimlari

Forward ile cok benzer yapidadir, ama TOPLAM yerine MAX kullanir ve hangi yoldan geldigini kaydeder (backpointer).

v_t(j) = t anina kadar o_1,...,o_t gozlemlerini gormüs ve t aninda j durumunda olmanin EN YUKSEK olasilikli yol degeri.

```
Adim 1 - Baslangic: v_1(j) = pi_j x B_j(o_1)

Adim 2 - Ozyineleme (t=2'den T'ye):
  v_t(j) = MAX_i [ v_t-1(i) x A_ij ] x B_j(o_t)
  bt_t(j) = argmax_i [ v_t-1(i) x A_ij ]  <- En iyi onceki durumu kaydet

Adim 3 - Sonlandirma:
  En iyi son durum: q_T* = argmax_j v_T(j)
  Geriye git: bt dizisini sondan basa takip ederek tum yolu bul
```

7. Learning - Baum-Welch Algoritmasi

7.1. Problem Tanimi

Forward (Evaluation) ve Viterbi (Decoding) problemlerinde A, B ve pi matrislerini zaten biliyorduk. Peki ya bu matrisleri bilmiyor, sadece gozlem dizilerini elinde bulunduruyorsak?

Learning (ogrenme) problemi su soruyu sorar: "Gozlem verilerine en iyi uyan HMM parametrelerini nasil buluruz?"

Ornek: Learning Probleminin Mantigi

Elimizde var: Cok sayida gozlem dizisi (ornegin bir aylik dondurma verileri)
Bilmiyoruz : A (gecis matrisi), B (emisyon matrisi), pi (baslangic)

Soru: Bu gozlem verilerini en iyi aciklayan A, B, pi nedir?

Benzetme: Bir dil ogrencisi kelime kitabi olmadan sadece ses dinleyerek konusma kaliplarini cikarimaya çalışıyor olması.

7.2. Baum-Welch Yontemi

Baum-Welch, Beklenti Maksimizasyonu (Expectation-Maximization, EM) algoritmasinin HMM'e ozel uyarlamasidir. Iki adimli bir dongu seklinde calisir:

- E-Adimi (Beklenti): Mevcut parametrelerle, gizli durum istatistikleri tahmin edilir (gamma ve xi degerleri hesaplanir).
- M-Adimi (Maksimizasyon): Bu istatistikler kullanilarak A, B ve pi parametreleri yeniden hesaplanir.
- Dongu: E ve M adimlari, parametreler yakinsamaya (degisim cok kucuklesene) kadar tekrar edilir.

Baum-Welch, her ne kadar global optimuma ulasmayi garantilemese de pratikte cok iyi sonuclar verir. Konusma tanima, DNA analizi ve dogal dil isleme gibi alanlarda yaygin olarak kullanilmaktadir.

8. Gercek Dunya Uygulamalari

HMM'in guclu yani sudur: cok farkli alanlarda "gozlemlenebilir veri" ve "gizli durum" kalibina uygun problemler vardir.

Uygulama	Gozlemlenen (Observable)	Gizli Durum (Hidden)	Algoritma
Konusma Tanima	Akustik ses dalgasi	Kelimeler / fonemler	Forward + Viterbi
El Yazisi Tanima	Cizilen cizgilerin koordinatlari	Karakterler	Viterbi
Sozcuk Turu Etiketleme	Cumledeki kelimeler	Isim/fiil/sifat etiketleri	Viterbi
Makine Cevirisi	Kaynak dil kelimeleri	Hedef dil kelimeleri	Viterbi
Robot Konumlandirma	Sensor mesafe okumalar	Haritadaki konum	Forward
DNA Dizi Analizi	Nükleotid (A,T,G,C) dizisi	Gen bolgesi / tipi	Viterbi

9. Python ile HMM Uygulamasi

Asagidaki Python kodu, hava durumu tahmini icin sifirdan yazilmis bir HMM sinifini ve Viterbi algoritmasinin uygulamasini gostermektedir. Kod, hmm.pdf kaynagindan alinmistir.

9.1. HiddenMarkovModel Sinifi

Sinif, HMM'in bes parametresini alir ve predict() metodu ile Viterbi algoritmasini kullanarak en olasilikli gizli durum dizisini dondurur:

```
import numpy as np


class HiddenMarkovModel:
```

```
    def __init__(self, states, observations, start_prob,
transition_prob, emission_prob):
        self.states = states
        self.observations = observations

        self.state_to_idx = {s: i for i, s in enumerate(states)}
        self.obs_to_idx = {o: i for i, o in enumerate(observations)}

        self.start_prob = np.array(start_prob)
        self.transition_prob = np.array(transition_prob)
        self.emission_prob = np.array(emission_prob)

        self._validate()

        # log-space (numerical stability)
        self.log_start = np.log(self.start_prob)
        self.log_trans = np.log(self.transition_prob)
        self.log_emit = np.log(self.emission_prob)

    def _validate(self):
        assert np.allclose(self.start_prob.sum(), 1), "Başlangıç
olasılıkları 1 olmalı"
        assert np.allclose(self.transition_prob.sum(axis=1), 1), "Geçiş
matrisinde her satır 1 olmalı"
        assert np.allclose(self.emission_prob.sum(axis=1), 1), "Emisyon
matrisinde her satır 1 olmalı"

    def predict(self, obs_sequence):
        obs_idx = [self.obs_to_idx[o] for o in obs_sequence]

        T = len(obs_idx)
        N = len(self.states)

        V = np.full((T, N), -np.inf)   # log probabilities
        B = np.zeros((T, N), dtype=int)

        # başlangıç
        V[0] = self.log_start + self.log_emit[:, obs_idx[0]]

        # ileri (Viterbi)
        for t in range(1, T):
            for s in range(N):
                scores = V[t-1] + self.log_trans[:, s]
                best_prev = np.argmax(scores)

                V[t, s] = scores[best_prev] + self.log_emit[s,
obs_idx[t]]
                B[t, s] = best_prev

        # geri izleme
        states_seq = np.zeros(T, dtype=int)
        states_seq[-1] = np.argmax(V[-1])

        for t in range(T-2, -1, -1):
            states_seq[t] = B[t+1, states_seq[t+1]]

        return [self.states[i] for i in states_seq]
```

9.2. Hava Durumu Senaryosu

Uc gizli durum (gunesli, bulutlu, yagmurlu) ve ayni adlarda gozlemler kullanan bir senaryo:

```
def main():
    # Gizli durumlar (gerçek ama görünmez)
    states = ['güneş', 'bulut', 'yağmur']

    # Gözlemler (bizim gördüğümüz şey)
    observations = ['kuru', 'nemli', 'ıslak']

    # Başlangıç olasılıkları
    start_prob = [0.5, 0.3, 0.2]

    # Geçiş olasılıkları
    transition_prob = [
        [0.7, 0.2, 0.1],  # güneş -> ...
        [0.3, 0.4, 0.3],  # bulut -> ...
        [0.2, 0.3, 0.5]   # yağmur -> ...
    ]

    # Emisyon olasılıkları
    emission_prob = [
        [0.8, 0.15, 0.05],  # güneş -> kuru, nemli, ıslak
        [0.3, 0.4, 0.3],    # bulut -> ...
        [0.1, 0.3, 0.6]     # yağmur -> ...
    ]
```

9.3. Modeli Olusturma ve Tahmin Yapma

```
hmm = HiddenMarkovModel(
        states,
        observations,
        start_prob,
        transition_prob,
        emission_prob
    )

    # Gözlem dizisi (örnek)
    obs_sequence = ['kuru', 'kuru', 'nemli', 'ıslak', 'ıslak']

    predicted_states = hmm.predict(obs_sequence)

    print("=== SONUÇ ===")
    for t, (obs, state) in enumerate(zip(obs_sequence,
predicted_states)):
        print(f"t={t} | Gözlem: {obs:5} -> Tahmin edilen durum:
{state}")


if __name__ == "__main__":
    main()
```

Beklenen cikti:

```
=== SONUÇ ===
t=0 | Gözlem: kuru  -> Tahmin edilen durum: güneş
t=1 | Gözlem: kuru  -> Tahmin edilen durum: güneş
t=2 | Gözlem: nemli -> Tahmin edilen durum: bulut
t=3 | Gözlem: ıslak -> Tahmin edilen durum: yağmur
t=4 | Gözlem: ıslak -> Tahmin edilen durum: yağmur
```

10. Avantajlar ve Sinirliliklar

10.1. Avantajlar

- Belirsizligi modeller: Gizli durumlar tam bilinemese bile mantikli tahminler uretebilir.
- Ardisik veriler icin dogal: Zaman serisi, ses ve metin gibi sirali verileri dogal olarak modellemek icin tasarlanmistir.
- Matematiksel seffaflik: Forward, Viterbi ve Baum-Welch algoritmalari iyi tanimli, analiz edilebilir algoritmalardir.
- Genis uygulama alani: Konusma tanima, biyoinformatik, robotik, finans ve daha pek cok alanda kullanilir.
- Ogrenme destegi: Baum-Welch ile etiketli veri olmadan parametreler veriden ogrenebilir.

10.2. Sinirliliklar

- Durum sayisinin onceden belirlenmesi: Kac gizli durum oldugunun belirlenmesi cogunlukla deneme-yanilmayla yapilir.
- Uzun vadeli bagimliliklar: Uzun cumleler veya uzun ses kayitlarinda Derin Ogrenme modelleri (LSTM, Transformer) HMM'i gecmektedir.
- Yerel optimum: Baum-Welch global en iyiyi garantilemez; baslangic degerlerine duyarlidir.

Kaynaklar

Besli, E. (2023). "Hidden Markov Model ve Uygulamalari". Medium, 29 Mayis 2023.

Jurafsky, D. & Martin, J. H. (2024). Speech and Language Processing (3. baski). Stanford Universitesi. Bolum 8: Sequence Labeling for Parts of Speech and Named Entities.

Rabiner, L. R. (1989). A tutorial on hidden Markov models and selected applications in speech recognition. Proceedings of the IEEE, 77(2), 257-286.