BLM0462 — Örüntü Tanıma

(Pattern Recognition)

Ünite 4

Parametrik Olmayan Yöntemler

(Non-Parametric Methods)

Prof. Dr. Turgay Tugay BİLGİN

Bilgisayar Mühendisliği Bölümü

3. Sınıf Ders Notu

Kaynak: Duda, Hart & Stork, *Pattern Classification*, Bölüm 4

İçindekiler

1 Giriş: Parametrik Olmayan Yöntemler Neden Gerekli? 2
1.1 Önceki Derslerde Yaptığımız Varsayımlar . . . 2
1.2 Parametrik Yöntemlerin Sınırlılıkları . . . 2
1.3 Parametrik Olmayan Yöntemlerin Temel Fikri . . . 3
1.4 Bu Ünitede İşlenecek Yöntemler . . . 3

2 Yoğunluk Kestirimi: Temel Fikir 4
2.1 Bölge Tabanlı Yaklaşım . . . 4
2.2 Bölge Büyüklüğü ve Yoğunluk İlişkisi . . . 5
2.3 MLE ile Olasılık Tahmini . . . 6
2.4 Temel Yoğunluk Kestirim İfadesinin Türetilmesi . . . 6

3 Yoğunluk Kestirimi: Histogram Yaklaşımı ve Doğruluk 7
3.1 Histogram ile Yoğunluk Kestirimi . . . 7
3.2 Bölge Boyutu: Denge Sorunu (Trade-off) . . . 9
3.3 Pratik Durum: Sabit n ile Ne Yapılabilir? . . . 9

4 İki Temel Yaklaşım: Parzen Pencereleri ve k-En Yakın Komşu 9
4.1 Temel Formülden İki Farklı Strateji . . . 9
4.2 Parzen Pencereleri (Parzen Windows) . . . 10
4.3 k-En Yakın Komşu (k-NN) . . . 11
4.4 Teorik Yakınsama Sonucu . . . 11
4.5 Pratik Karşılaştırma ve Yöntem Seçimi . . . 12

5 Parzen Pencereleri: Yöntemin Detayı 12
5.1 Adım Adım Yöntem: Nasıl Hesaplanır? . . . 12
5.2 Temel Varsayım: Hiperküp Pencere . . . 13
5.3 Pencere Fonksiyonu $\varphi(u)$ . . . 14
5.4 Veri Noktasının Pencere İçinde Olup Olmadığını Belirleme . . . 15
5.5 Pencere İçindeki Nokta Sayısı . . . 16
5.6 Analitik Yoğunluk Formu . . . 16

6 Parzen Yoğunluğunun Pencere Fonksiyonları 19
6.1 Pencere Fonksiyonunun Genelleştirilmesi: KDE . . . 19
6.2 Hiperküp (Box) Kernel'in Dezavantajı . . . 19
6.3 Ünite Özeti . . . 21

1 Giriş: Parametrik Olmayan Yöntemler Neden Gerekli?

1.1 Önceki Derslerde Yaptığımız Varsayımlar

Örüntü tanıma dersinin önceki ünitelerinde, bir sınıflandırıcı tasarlamak için iki temel yaklaşım incelendi.

1. **Yoğunluk fonksiyonu doğrudan verilir.**
   Biri bize $p(x)$ fonksiyonunu hazır olarak sunuyordu. Gerçek uygulamalarda bu senaryo neredeyse hiç gerçekleşmez.

2. **Fonksiyonun formu bilinir, parametreleri bilinmez.**
   $p(x \mid \theta)$ şeklinde bir model veriliyordu; bizden sadece θ parametrelerini veriden öğrenmemiz isteniyordu. Örnek: $\theta = (\mu, \sigma)$ ise Gaussian modeli $p(x \mid \mu, \sigma)$ elde edilir.

Bu iki yaklaşımın ortak adı **parametrik yöntemler**dir, çünkü her ikisinde de dağılımın yapısı (formu) baştan belli olup yalnızca belirli parametreler tahmin edilmektedir.

1.2 Parametrik Yöntemlerin Sınırlılıkları

Parametrik yöntemler, seçilen modelin gerçek veriyi ne kadar iyi temsil ettiğine bağlı olarak ciddi sorunlar yaratabilir. Bu sorunları iki başlık altında özetleyebiliriz.

1. Model belirsizliği. Elinizdeki verinin hangi dağılımdan geldiğini kesin olarak bilemezsiniz. Gaussian seçtiyseniz ve gerçek dağılım Gaussian değilse, ne kadar çok veri toplarsanız toplayın tahmininiz yanlış olmaya devam eder. Bu duruma *model yanlılığı* (model bias) denir.

2. Tek modlu dağılım varsayımı. Gaussian başta olmak üzere en yaygın parametrik dağılımlar tek bir tepe noktasına (*tek modlu, unimodal*) sahiptir. Ancak gerçek dünyadaki problemlerin büyük çoğunluğu **çok modlu (multimodal)** dağılımlar içerir.

Örnek

Bir balık fabrikasında somon (salmon) ve levrek (sea bass) balıklarını aydınlık değerine (lightness) göre ayırt etmeye çalıştığınızı düşünün. Somon balıklarının aydınlık değeri, hem küçük juvenil balıklar hem de büyük yetişkin balıklar nedeniyle iki farklı tepe noktasına sahip olabilir. Tek bir Gaussian bu iki grubu aynı anda temsil edemez.

Önemli

Parametrik yöntemler, modelin gerçekten uygun olduğu durumlarda güçlüdür. Ancak dağılım biçimi hakkında hiçbir güvenilir bilgimiz yoksa ya da gerçek dağılım karmaşık ve çok modluysa, parametrik modeller sistematik hatalar üretir.

1.3 Parametrik Olmayan Yöntemlerin Temel Fikri

Parametrik olmayan yöntemler (non-parametric methods), herhangi bir dağılım formu varsaymadan doğrudan veriden yoğunluk fonksiyonunu kestirmeyi amaçlar.

Tanım

Parametrik olmayan yöntemler:
Olasılık yoğunluk fonksiyonunun formu hakkında hiçbir önceden bilgi (ön varsayım) gerektirmeyen; yalnızca etiketlenmiş eğitim verilerinden hareketle dağılımı kestiren yöntemler bütünüdür.

Bu yaklaşımın temel mantığı şudur:

- **Çok şey biliniyorsa** (dağılım formu, parametreler vb.) $\Rightarrow$ problem daha kolaydır, parametrik yöntemler yeterlidir.
- **Az şey biliniyorsa** (yalnızca etiketli veri) $\Rightarrow$ problem daha zordur, parametrik olmayan yöntemler gerekir.

1.4 Bu Ünitede İşlenecek Yöntemler

Bu ünitede iki temel parametrik olmayan yöntem incelenecektir.

1. **Parzen Pencereleri (Parzen Windows)**
   Sabit boyutlu bir "pencere" (bölge) tanımlanır; bu pencerenin içine kaç veri noktasının düştüğü sayılarak yoğunluk kestirimi yapılır. Bu yöntem **olabilirlik fonksiyonunu** kestirmekte kullanılır:
   $$p(x \mid c_j)$$
2. **En Yakın Komşular (Nearest Neighbors, k-NN)**
   Sabit sayıda komşuyu kapsayan bölgenin hacmi veriden belirlenir. Bu yöntem olabilirlik kestirimi adımını atlayarak doğrudan **posterior olasılığını** kestirmekte kullanılabilir:
   $$P(c_j \mid x)$$

Sonuç

Parametrik olmayan yöntemlerin en önemli avantajı, dağılım formu konusundaki *model yanlılığı* sorununu ortadan kaldırmasıdır. Yeterli miktarda veri sağlandığında, bu yöntemler gerçek yoğunluk fonksiyonuna yakınsama (convergence) sağlayabilir.

2 Yoğunluk Kestirimi: Temel Fikir

2.1 Bölge Tabanlı Yaklaşım

Parametrik olmayan yöntemlerin temelinde şu sezgi yatar: **Bir bölgede ne kadar çok veri noktası gözlemleniyorsa, o bölgedeki gerçek yoğunluk o kadar yüksektir.**

Bu sezgiyi matematiksel bir çerçeveye oturtmak için önce olasılık ile yoğunluk arasındaki ilişkiyi hatırlayalım.

Sürekli bir x rastgele değişkeni için, x'in $\mathcal{R}$ adlı bir bölgeye düşme olasılığı yoğunluk fonksiyonu $f(x)$ ile şöyle ifade edilir:

$$\Pr[X \in \mathcal{R}] = \int_{\mathcal{R}} f(x)\, dx \tag{1}$$

Bu integral geometrik olarak şunu söyler: $\mathcal{R}$ bölgesi üzerinde $f(x)$ eğrisinin altında kalan alan, o bölgeye düşme olasılığına eşittir.

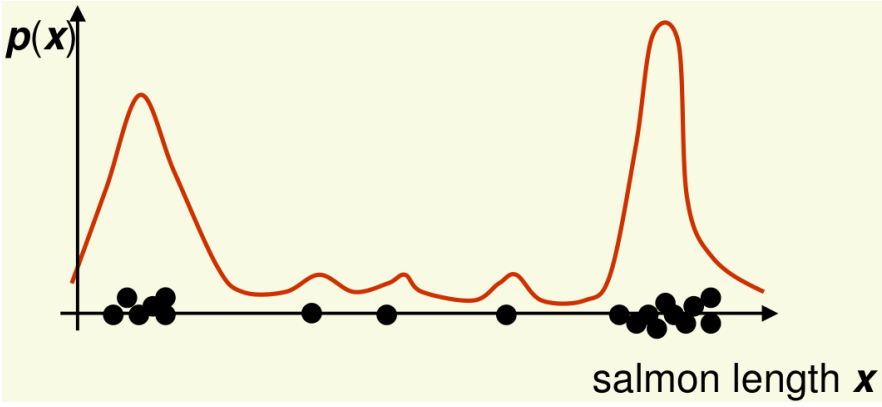

Şekil 1: Somon balığı uzunluk ölçümlerinin yoğunluk kestirimi. Yatay eksen balık uzunluğunu (x, cm), dikey eksen yoğunluk değerini $p(x)$ göstermektedir. Siyah noktalar gözlenen ölçümleri, kırmızı eğri ise bilinmeyen gerçek yoğunluk fonksiyonunu temsil eder.

Balık uzunluğu örneği

Somon balıklarının uzunluk dağılımını kestirmeye çalıştığımızı düşünelim.

- Yatay eksen: balık uzunluğu x (cm)

- Dikey eksen: yoğunluk $p(x)$
- Noktalar: gözlenen ölçümler
- Eğri: bilinmeyen gerçek yoğunluk fonksiyonu

$\mathcal{R}_1 = [25, 30]$ cm aralığına 6 balık düşmüş olsun. Toplam 20 balığımız varsa:

$$\Pr[X \in \mathcal{R}_1] \approx \frac{6}{20} = 0.30$$

2.2 Bölge Büyüklüğü ve Yoğunluk İlişkisi

Dikkat edilmesi gereken önemli bir nokta şudur: eşit olasılığa sahip iki bölgenin yoğunlukları eşit olmak zorunda değildir.

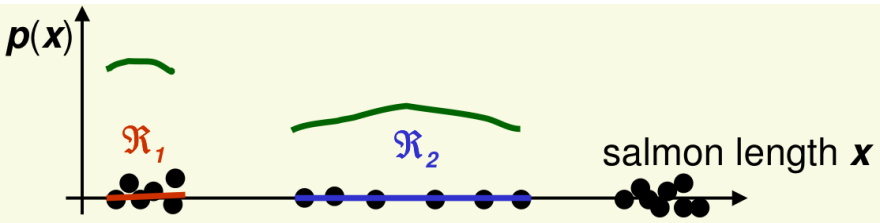

Şekil 2: Eşit olasılığa sahip fakat farklı genişlikteki iki bölge ($\mathcal{R}_1$ ve $\mathcal{R}_2$). Her iki bölge de aynı sayıda örnek içermesine karşın $\mathcal{R}_1$ daha dar olduğundan yoğunluk eğrisi orada daha yüksektir.

Bunu somutlaştırmak için iki bölge düşünelim:

- $\mathcal{R}_1$: dar bir aralık, 6 örnek içeriyor
- $\mathcal{R}_2$: $\mathcal{R}_1$'den 3 kat geniş bir aralık, yine 6 örnek içeriyor

Her ikisi için olasılık tahmini $\approx 6/20$ çıkar. Ancak (1) denkleminden şunu görebiliriz:

$$\Pr[X \in \mathcal{R}_i] = \int_{\mathcal{R}_i} f(x)\, dx \approx f(x) \cdot \text{Hacim}(\mathcal{R}_i)$$

Eğer her iki integral de 6/20'ye eşitse fakat $\mathcal{R}_1$ daha küçükse, $\mathcal{R}_1$ üzerindeki $f(x)$ değeri daha büyük olmalıdır. Yani **dar bölgede aynı sayıda veri varsa yoğunluk daha yüksektir.**

Önemli

Yoğunluk, ham sayımdan değil; sayımın bölge büyüklüğüne oranlanmasından elde edilir. Bu normalizasyon adımı, farklı boyutlardaki bölgeleri karşılaştırılabilir kılmak için zorunludur.

2.3 MLE ile Olasılık Tahmini

$\mathcal{R}$'ye k örnek düştüğünde ρ'yu tahmin etmek için Maksimum Olabilirlik Kestirimi (MLE, Maximum Likelihood Estimation) uygulayabiliriz.

Olabilirlik fonksiyonu:

$$\mathcal{L}(\rho) = \binom{n}{k} \rho^k (1-\rho)^{n-k}$$

Bu fonksiyon ρ cinsinden maksimize edildiğinde (log-olabilirlik türevi sıfıra eşitlenerek):

$$\hat{\rho} = \frac{k}{n} \tag{2}$$

elde edilir. Sonuç basit ve sezgiseldir: bölgeye düşen örnek sayısının toplam örnek sayısına oranı.

2.4 Temel Yoğunluk Kestirim İfadesinin Türetilmesi

Artık iki temel bileşeni elimizde topladık:

1. $\hat{\rho} = k/n$ (MLE ile bulunan oran tahmini)
2. $\int_{\mathcal{R}} p(x')\,dx' \approx p(x) \cdot V$ ($p(x)$'in $\mathcal{R}$ içinde yaklaşık sabit olduğu varsayımı; $V = \text{Hacim}(\mathcal{R})$)

Bu iki ifadeyi birleştirirsek:

$$\frac{k}{n} \approx \hat{\rho} = \int_{\mathcal{R}} p(x')\,dx' \approx p(x) \cdot V$$

Buradan $p(x)$'i yalnız bırakırsak:

$$\boxed{p(x) \approx \frac{k/n}{V}} \tag{3}$$

Bu ifade, parametrik olmayan tüm yoğunluk kestirim yöntemlerinin ortak çıkış noktasıdır.

Tanım

Parametrik olmayan yoğunluk kestirim formülü:

$$p(x) \approx \frac{k/n}{V}$$

- k: $\mathcal{R}$ bölgesi içindeki örnek sayısı
- n: toplam örnek sayısı
- V: $\mathcal{R}$ bölgesinin hacmi

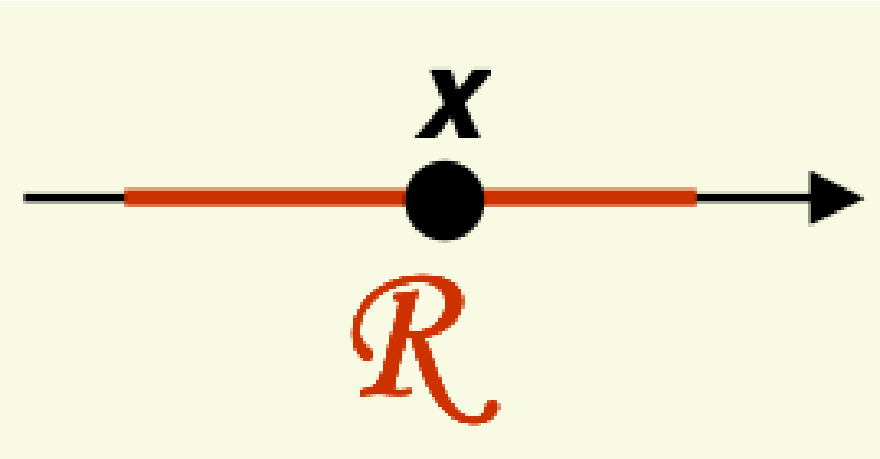

Şekil 3: Parametrik olmayan yoğunluk kestirim formülünün şematik gösterimi. $\mathcal{R}$ bölgesi içindeki k örnek, toplam n örnek ve bölge hacmi V kullanılarak $p(x)$ kestirimi elde edilir.

- x: $\mathcal{R}$ bölgesi içinde seçilen merkez nokta

Sonuç

(3) aslında şunu söyler: yoğunluk kestirimi = **yerel veri yoğunluğu** / **bölge büyüklüğü**. Küçük bir bölgede çok sayıda örnek varsa yoğunluk yüksektir; geniş bir bölgede aynı sayıda örnek varsa yoğunluk daha düşüktür.

3 Yoğunluk Kestirimi: Histogram Yaklaşımı ve Doğruluk

3.1 Histogram ile Yoğunluk Kestirimi

Bölüm 2'de elde ettiğimiz temel formül (3), uygulamada nasıl kullanılır? En doğal ve en basit yaklaşım **histogram**dur.

Histogram oluştururken veri uzayı birbirine komşu fakat birbirini *çakışmayan* bölgelere $(\mathcal{R}_1, \mathcal{R}_2, \mathcal{R}_3, \ldots)$ ayrılır. Bu bölgelere **kutu** (bin) denir. Her kutu için yoğunluk (3) ile ayrı ayrı hesaplanır ve kutu içinde yoğunluğun sabit olduğu kabul edilir.

Histogram hesabı

Toplam $n = 19$ örnek, üç kutuya ayrılmış olsun:

- $\mathcal{R}_1$ (genişlik $V_1 = 10$): 6 örnek

$$p(x) \approx \frac{6/19}{10} \approx 0.032$$

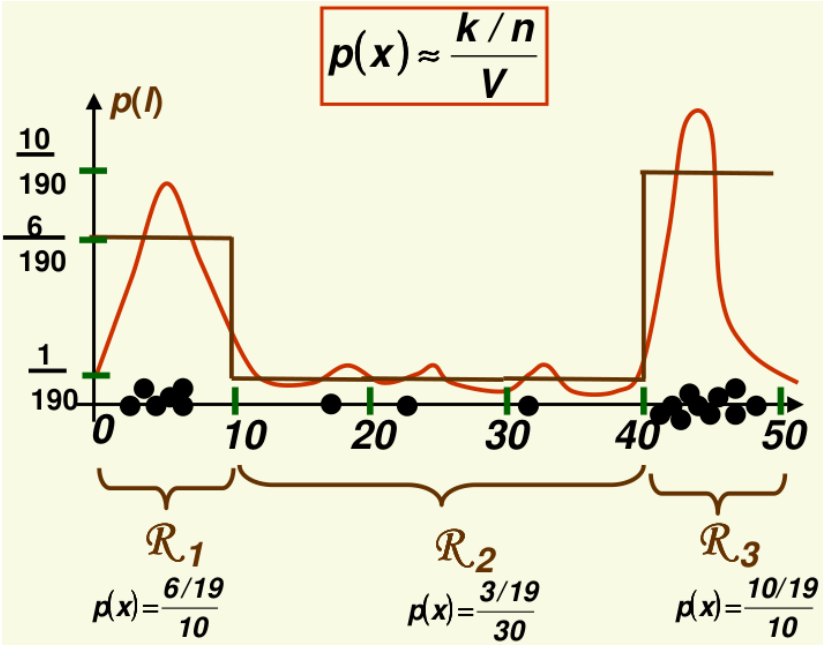

Şekil 4: Üç kutulu histogram örneği. Siyah noktalar veri örneklerini, kırmızı eğri gerçek yoğunluğu, dikdörtgenler ise her kutu için hesaplanan yaklaşık yoğunluğu göstermektedir.

- $\mathcal{R}_2$ (genişlik $V_2 = 30$): 3 örnek

$$p(x) \approx \frac{3/19}{30} \approx 0.005$$

- $\mathcal{R}_3$ (genişlik $V_3 = 10$): 10 örnek

$$p(x) \approx \frac{10/19}{10} \approx 0.053$$

Dikkat: $\mathcal{R}_2$ daha geniş olmasına rağmen daha az örnek içerdiğinden yoğunluğu en düşük kutudur.

Histogramın yorumu şöyledir:

- Her kutu, o aralıktaki yoğunluğu sabit bir dikdörtgenle temsil eder.
- Gerçek (bilinmeyen) yoğunluk eğrisi bu dikdörtgenlerle yaklaşık olarak ifade edilir.
- Kutular çakışmadığından histogram, veri uzayının tam bir bölümlenmesini (partition) oluşturur.

Önemli

Histogram, (3) formülünün en temel uygulamasıdır. Ama performansı tamamen **kutu genişliğinin** (bin width) ne kadar iyi seçildiğine bağlıdır. Bu, yöntemin en kritik hiperparametresidir.

3.2 Bölge Boyutu: Denge Sorunu (Trade-off)

Yukarıdaki iki nokta birbiriyle çelişir ve kritik bir dengeye yol açar:

$\mathcal{R}$ **büyük seçilirse**	$\mathcal{R}$ **küçük seçilirse**
k büyük olur, $\hat{\rho}$ güvenilir	k küçük olur, $\hat{\rho}$ güvenilmez
Ama $p(x)$ sabit sayılması zorlaşır	$p(x)$ sabit varsayımı daha geçerli
Detay kaybolur, dağılım düzleşir	Bölgede hiç veri olmayabilir

Özellikle, V çok küçük seçilirse birçok bölgede hiç veri bulunmaz. Bu durumda formül $p(x) \approx 0/n\,/\,V = 0$ verir; gerçekte yoğunluk sıfır olmadığı halde.

3.3 Pratik Durum: Sabit n ile Ne Yapılabilir?

Gerçek projelerde veri sayısı n sabittir ve artırılamaz. Bu durumda doğruluğu artırmanın tek yolu bölge boyutunu küçültmektir. Ancak bu da kendi sınırını beraberinde getirir.

Pratik rehber:

- V **çok küçük** olmamalı: bölge içinde en az birkaç veri noktası bulunmalıdır.
- V **çok büyük** olmamalı: bölge içinde $p(x)$'in yaklaşık sabit kalması beklenmelidir.
- Çoğu uygulamada V (ya da eşdeğeri olan h pencere genişliği) **çapraz doğrulama** (cross-validation) yöntemiyle seçilir.

Sonuç

Histogram ve buna dayanan tüm parametrik olmayan yöntemlerin başarısı, **bölge boyutu seçimine** doğrudan bağlıdır. Bu seçim modelin en kritik hiperparametresidir ve veriye göre ayarlanmak zorundadır.

4 İki Temel Yaklaşım: Parzen Pencereleri ve k-En Yakın Komşu

4.1 Temel Formülden İki Farklı Strateji

Bölüm 2'de elde ettiğimiz formül şuydu:

$$p(x) \approx \frac{k/n}{V} \tag{3}$$

Bu formülde iki bilinmeyen vardır: k ve V. Bunlardan *birini* sabit tutup *diğerini* veriden belirlemek, iki farklı yöntem ailesi doğurur.

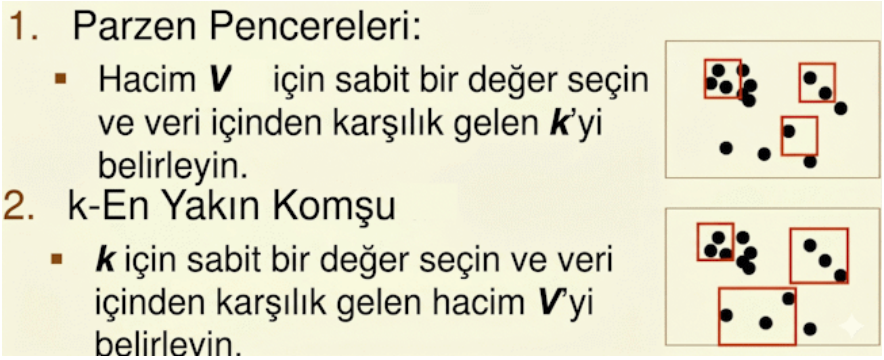

Şekil 5: Parzen pencereleri ve k-en yakın komşu yöntemlerinin karşılaştırması. Parzen'de bölge hacmi V sabit tutulurken içindeki nokta sayısı k değişir; k-NN'de ise k sabit tutulurken bölge hacmi V veriye göre belirlenir.

	Parzen Pencereleri	**k-En Yakın Komşu**
Sabit tutulan	V (bölge hacmi)	k (komşu sayısı)
Veriden belirlenen	k (düşen örnek sayısı)	V (kapsayan bölge hacmi)

Bu basit ayrım, iki yöntemin tüm davranış farklılıklarını belirler.

4.2 Parzen Pencereleri (Parzen Windows)

Strateji: Bölge boyutu V önceden sabit seçilir. Her x noktası için bu sabit boyutlu pencere x'in etrafına yerleştirilir ve içine kaç veri noktası düştüğü (k) sayılır.

- **Yoğun bölgede:** pencereye çok nokta düşer $\Rightarrow$ k büyük $\Rightarrow$ yüksek yoğunluk kestirimi
- **Seyrek bölgede:** pencereye az nokta düşer $\Rightarrow$ k küçük $\Rightarrow$ düşük yoğunluk kestirimi

Önemli

Parzen yönteminde V sabittir; yani pencere her x noktasında aynı boyutu korur. Yalnızca içindeki nokta sayısı k değişir. Performans tamamen **pencere boyutu h'nin** (dolayısıyla $V = h^d$'nin) ne kadar iyi seçildiğine bağlıdır.

4.3 k-En Yakın Komşu (k-NN)

Strateji: İçinde bulunmasını istediğimiz komşu sayısı k önceden sabit seçilir. Her x noktası için bu k komşuyu tam olarak kapsayan en küçük bölgenin hacmi V hesaplanır.

- **Yoğun bölgede:** k komşuya ulaşmak için küçük bir bölge yeterli $\Rightarrow$ V küçük $\Rightarrow$ yüksek yoğunluk kestirimi
- **Seyrek bölgede:** k komşuya ulaşmak için büyük bir bölge gerekli $\Rightarrow$ V büyük $\Rightarrow$ düşük yoğunluk kestirimi

Bu özellik sayesinde k-NN **adaptif** bir yöntemdir: bölge boyutu veri yoğunluğuna göre otomatik olarak ayarlanır.

Parzen ve k-NN karşılaştırması

20 balık ölçümünden oluşan bir veri setini düşünelim.

Parzen ($V = 10$ cm, sabit):

- Yoğun bölge ($[25, 35]$ cm): 8 nokta düşüyor $\Rightarrow p(x) \approx (8/20)/10 = 0.040$
- Seyrek bölge ($[50, 60]$ cm): 1 nokta düşüyor $\Rightarrow p(x) \approx (1/20)/10 = 0.005$

k-NN ($k = 5$, sabit):

- Yoğun bölge: 5 komşuya 4 cm'de ulaşılıyor $\Rightarrow p(x) \approx (5/20)/4 = 0.063$
- Seyrek bölge: 5 komşuya 18 cm'de ulaşılıyor $\Rightarrow p(x) \approx (5/20)/18 = 0.014$

k-NN, yoğunluğun değiştiği bölgelerde bölge boyutunu otomatik olarak ayarladığından daha esnek bir kestirim üretir.

4.4 Teorik Yakınsama Sonucu

Her iki yöntem de uygun koşullar altında, veri sayısı $n \to \infty$ iken gerçek yoğunluk fonksiyonuna yakınsar.

Yakınsama için gerekli teorik koşullar:

	Parzen	**k-NN**
Koşul 1	$V_n \to 0$	$k_n \to \infty$
Koşul 2	$nV_n \to \infty$	$k_n/n \to 0$

Sezgisel yorum:

- Parzen: pencere küçülmeli, ama içindeki örnek sayısı yine de sonsuza gitmelidir.
- k-NN: komşu sayısı artmalı, ama toplam örnek sayısına oranı sıfıra yaklaşmalıdır.

4.5 Pratik Karşılaştırma ve Yöntem Seçimi

Özellik	**Parzen Pencereleri**	**k-NN**
Bölge boyutu	Sabit (V değişmez)	Adaptif (V değişir)
Hesaplama kolaylığı	Daha basit	Biraz daha karmaşık
Yoğunluk değişimine uyum	Zayıf	Güçlü
Kritik hiperparametre	Pencere genişliği h	Komşu sayısı k
Doğrudan sınıflandırma	$p(x\|c_j)$ kestirimi gerekir	$P(c_j\|x)$ doğrudan kestirilebilir

Sonuç

- Veri yoğunluğu bölgeden bölgeye çok değişiyorsa $\Rightarrow$ **k-NN genellikle daha güçlüdür.**
- Basit, hızlı ve yorumlanması kolay bir çözüm gerekiyorsa $\Rightarrow$ **Parzen pencereleri yeterlidir.**
- Her iki yöntem de yeterli veriyle gerçek yoğunluğa yakınsayabilir; seçim çoğunlukla veri miktarına ve problemin yapısına göre yapılır.

5 Parzen Pencereleri: Yöntemin Detayı

5.1 Adım Adım Yöntem: Nasıl Hesaplanır?

Parzen yönteminin matematiksel ayrıntılarına geçmeden önce, belirli bir x noktası için yoğunluk kestirimin nasıl yapıldığını adım adım inceleyelim.

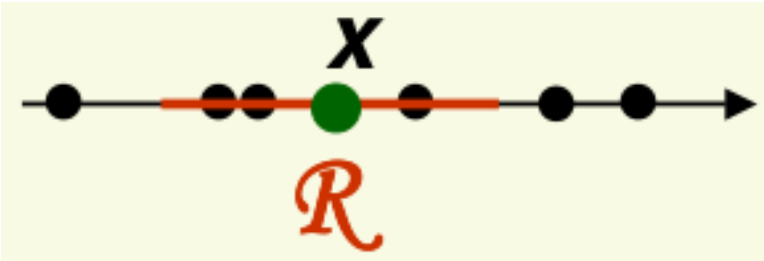

Şekil 6: 1 boyutlu Parzen penceresi örneği. x noktası (yeşil) merkeze alınır, $\mathcal{R}$ bölgesi (kırmızı aralık) etrafına yerleştirilir ve içine düşen siyah noktalar sayılır.

Amaç: Belirli bir x noktası için yoğunluğu $p(x)$ kestirmek.

1. **x noktasını merkeze al.**
   $\mathcal{R}$ bölgesini x'in etrafına yerleştir. Bölgenin şekli ve boyutu (h) önceden belirlidir.

2. **Bölge içindeki örnekleri say.**
   k: $\mathcal{R}$ içine düşen veri noktalarının sayısı.

3. **Formülü uygula:**
$$p(x) \approx \frac{k/n}{V}$$
   n: toplam veri sayısı, $V = h^d$: pencerenin hacmi.

Şekildeki sayısal örnek

Şekil 6'deki 1 boyutlu durumda:

- $\mathcal{R}$ içinde 3 nokta var $\Rightarrow k = 3$
- Toplam veri sayısı $n = 6$
- Bölge genişliği $V = 10$
$$p(x) \approx \frac{3/6}{10} = \frac{0.5}{10} = 0.05$$

x'in etrafında çok nokta varsa yoğunluk yüksek, az nokta varsa düşük çıkar; yöntem tamamen lokaldır.

5.2 Temel Varsayım: Hiperküp Pencere

Parzen yönteminde $\mathcal{R}$ bölgesinin şekli ve boyutu önceden belirlenir. En yaygın seçim, her kenarı h uzunluğunda olan **hiperküp** (hypercube) penceresidir.

d boyutlu uzayda hiperküpün hacmi:

$$V = h^d \tag{4}$$

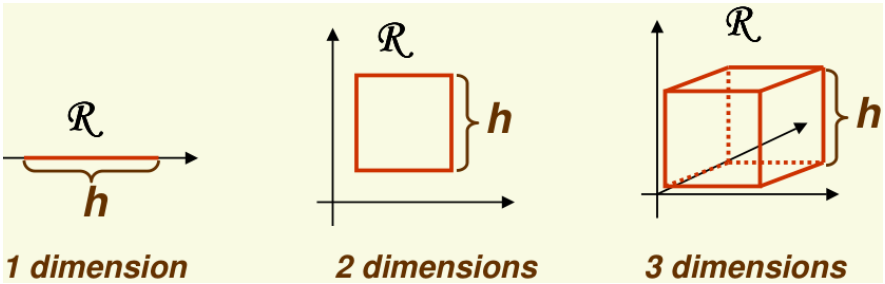

Şekil 7: 1, 2 ve 3 boyutlu hiperküp pencereleri. Kenar uzunluğu h sabit tutulduğunda hacim sırasıyla h, h^2 ve h^3 olarak üstel biçimde büyür.

Boyut (d)	**Şekil**	**Hacim**	**Örnek** ($h = 2$)
1	Aralık (interval)	h	2
2	Kare (square)	h^2	4
3	Küp (cube)	h^3	8
d	Hiperküp	h^d	2^d

Dikkat: Boyut d arttıkça aynı kenar uzunluğundaki hiperküpün hacmi üstel olarak büyür. Bu, **boyutun laneti** (curse of dimensionality) olarak bilinen soruna işaret eder ve yüksek boyutlu verilerde sabit bir pencere boyutunun yetersiz kalacağını gösterir.

5.3 Pencere Fonksiyonu $\varphi(u)$

Bir veri noktasının pencere içinde olup olmadığını matematiksel olarak ifade etmek için **pencere fonksiyonu** (window function) tanımlanır.

Tanım

Birim hiperküp pencere fonksiyonu:

$$\varphi(u) = \begin{cases} 1, & |u_j| \leq \dfrac{1}{2}, \quad j = 1, \ldots, d \\ 0, & \text{aksi hâlde} \end{cases} \tag{5}$$

burada $u \in \mathbb{R}^d$ normalize edilmiş uzaklık vektörüdür ve u_j, u'nun j. bileşenidir.

$\varphi(u)$, $[-1/2, 1/2]^d$ birim hiperküpü üzerinde 1, dışında 0 değerini alır. Geometrik olarak bu bir **kutu filtresi** (box filter) ya da **dikdörtgen çekirdeği** (rectangular kernel) olarak adlandırılır.

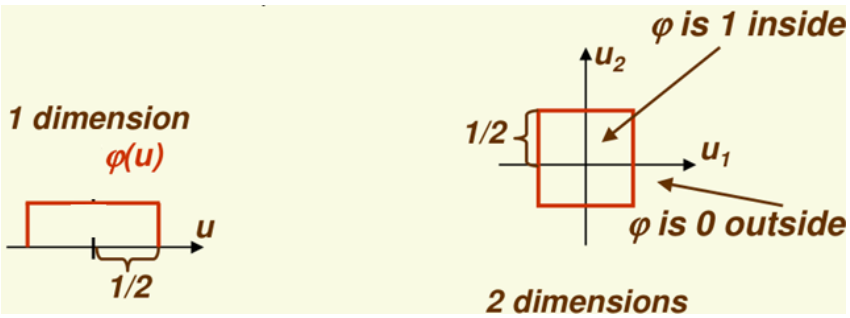

Şekil 8: Pencere fonksiyonu $\varphi(u)$'nun 1 ve 2 boyutlu gösterimi. 1 boyutta $[-1/2, 1/2]$ aralığında 1, dışında 0 değerini alır. 2 boyutta birim kare içinde $\varphi = 1$, dışında $\varphi = 0$'dır.

1 boyutlu pencere fonksiyonu

$d = 1$ durumunda:

$$\varphi(u) = \begin{cases} 1, & -\frac{1}{2} \leq u \leq \frac{1}{2} \\ 0, & \text{aksi hâlde} \end{cases}$$

Bu fonksiyon $[-0.5,\ 0.5]$ aralığında 1, dışında 0 veren basit bir dikdörtgen fonksiyondur.

5.4 Veri Noktasının Pencere İçinde Olup Olmadığını Belirleme

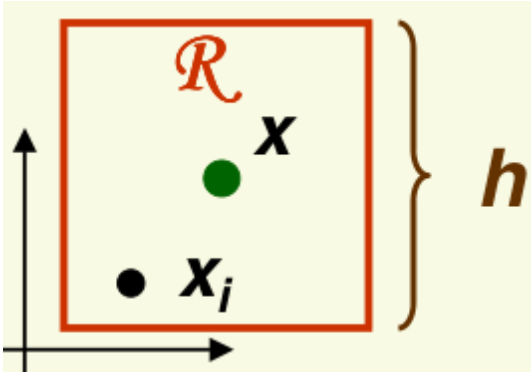

Şekil 9: x merkezli $\mathcal{R}$ bölgesi ve kenar uzunluğu h. x_i noktasının bu bölgenin içinde olup olmadığı $\varphi\left(\frac{x-x_i}{h}\right)$ ifadesiyle belirlenir.

Gerçek veride pencere x noktası merkezli ve kenar uzunluğu h olacak şekilde kurulduğunda, i. veri noktası x_i'nin bu pencerenin içinde olup olmadığı şu ifadeyle kontrol edilir:

$$\varphi\left(\frac{x - x_i}{h}\right) = \begin{cases} 1, & |x_j - x_{ij}| \leq \dfrac{h}{2}, \quad j = 1, \ldots, d \\ 0, & \text{aksi hâlde} \end{cases} \tag{6}$$

Burada $x - x_i$ farkı h'ye bölünerek normalize ediliyor; bu işlem problemi birim hiperküp üzerine taşıyor ve φ'nin tanımını doğrudan kullanmayı mümkün kılıyor.

Önemli

(6) ifadesi şu sorunun matematiksel karşılığıdır: *"x_i noktası, x merkezli ve genişliği h olan pencerenin içinde mi?"* Eğer içindeyse 1, değilse 0 döndürür. Böylece tek tek nokta saymak yerine matematiksel bir toplama işlemi yazılabilir hale gelir.

5.5 Pencere İçindeki Nokta Sayısı

n veri noktasının tamamı için (6) ifadesi toplanarak $\mathcal{R}$ bölgesine düşen toplam nokta sayısı k elde edilir:

$$k = \sum_{i=1}^{n} \varphi\left(\frac{x - x_i}{h}\right) \tag{7}$$

Bu toplam doğrudan pencerenin içindeki örnek sayısını verir; 1 katkısı yapan her terim bir "içeride" noktayı, 0 katkısı yapan her terim bir "dışarıda" noktayı temsil eder.

5.6 Analitik Yoğunluk Formu

Artık $k =$ (7) ve $V = h^d$ ifadelerini temel formül (3)'e koyabiliriz:

$$p(x) \approx \frac{k/n}{V} = \frac{1}{n} \cdot \frac{1}{h^d} \sum_{i=1}^{n} \varphi\left(\frac{x - x_i}{h}\right)$$

$$\boxed{p_\varphi(x) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{h^d} \varphi\left(\frac{x - x_i}{h}\right)} \tag{8}$$

Bu ifade Parzen yoğunluk kestiriminin tam analitik formudur. Formülün her terimi şu anlama gelir:

- $\frac{1}{h^d}$: hacim normalizasyonu; pencerenin boyutuna göre ölçekleme yapar.
- $\varphi\left(\frac{x - x_i}{h}\right)$: x_i'nin x merkezli pencereye katkısı (1 veya 0).
- $\frac{1}{n} \sum_{i=1}^{n}$: tüm veri noktalarının katkısının ortalaması.

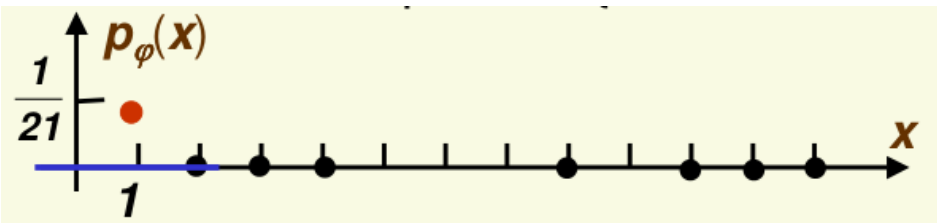

Şekil 10: $x = 1$ noktası için Parzen yoğunluk kestirimi. $D = \{2, 3, 4, 8, 10, 11, 12\}$ veri kümesinde $h = 3$ genişlikli pencere yalnızca $x_i = 2$ noktasını kapsadığından $p_\varphi(1) = 1/21$ elde edilir.

Parzen Pencereleri: 1 Boyutlu Örnek

Kullanılan formül (1 boyutta $V = h$):

$$p_\varphi(x) = \frac{1}{n}\sum_{i=1}^{n}\frac{1}{h}\,\varphi\left(\frac{x - x_i}{h}\right)$$

Verilenler:

- Veri kümesi: $D = \{2, 3, 4, 8, 10, 11, 12\}$, toplam örnek sayısı $n = 7$
- Pencere genişliği: $h = 3$
- Hesaplanacak nokta: $x = 1$

Adım 1 — Formüle yerleştir:

$$p_\varphi(1) = \frac{1}{7}\sum_{i=1}^{7}\frac{1}{3}\,\varphi\left(\frac{1 - x_i}{3}\right) = \frac{1}{21}\sum_{i=1}^{7}\varphi\left(\frac{1 - x_i}{3}\right)$$

Adım 2 — Hangi noktalar pencere içinde?
Koşul: $\left|\frac{1 - x_i}{3}\right| \leq \frac{1}{2}$, yani $|1 - x_i| \leq 1.5$

- $x_i = 2$: $|1 - 2| = 1 \leq 1.5 \Rightarrow$ **İçeride** $\Rightarrow \varphi = 1$
- $x_i = 3, 4, 8, 10, 11, 12$: hepsi $|1 - x_i| > 1.5 \Rightarrow$ Dışarıda $\Rightarrow \varphi = 0$

Adım 3 — Topla:

$$p_\varphi(1) = \frac{1}{21}\big[1 + 0 + 0 + \cdots + 0\big] = \frac{1}{21}$$

Yorum: $x = 1$ etrafında $h = 3$ genişlikli pencere $(-0.5,\ 2.5)$ aralığını kapsar. Bu aralığa yalnızca $x_i = 2$ düştüğünden yoğunluk çok düşük çıkmıştır. Daha yoğun bölgelerde ($x = 10$ gibi) pencereye daha fazla nokta gireceğinden yoğunluk değeri yükselecektir.

Parzen Pencereleri: Görsel Anlatım

Veriler: $D = \{2, 3, 4, 8, 10, 11, 12\}$, $n = 7$, pencere genişliği $h = 3$.
Her veri noktasının etrafına genişliği $h = 3$ olan bir kutu çizilir. Tüm kutular aynı yüksekliğe sahiptir:

$$\frac{1}{n\,h^d} = \frac{1}{7 \cdot 3} = \frac{1}{21}$$

Görseli nasıl okumalısın?

- **Alttaki renkli dikdörtgenler:** Her biri bir veri noktasına ait Parzen

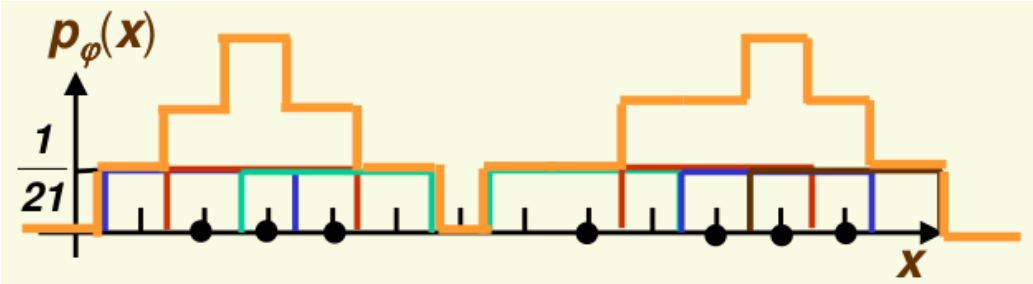

Şekil 11: $D = \{2, 3, 4, 8, 10, 11, 12\}$, $n = 7$, $h = 3$ için Parzen yoğunluk kestirimi. Alttaki renkli dikdörtgenler her veri noktasına ait Parzen kutularını, üstteki turuncu eğri ise bu kutuların üst üste toplanmasıyla elde edilen $p_\varphi(x)$'i göstermektedir.

kutusudur. Genişlikleri aynı ($h = 3$), yükseklikleri aynı ($1/21$).

- **Üstteki turuncu eğri:** Tüm bu kutuların üst üste toplanmış halidir; yani tüm x değerleri için hesaplanan $p_\varphi(x)$.

Görselden kritik çıkarım:

- **Sol bölge** ($x \approx 2, 3, 4$): Kutular üst üste geliyor; turuncu eğri yüksek çıkıyor.
- **Orta bölge** ($x \approx 5$–7): Bu aralıkta veri yok, kutu yok; yoğunluk sıfıra iniyor.
- **Sağ bölge** ($x \approx 10, 11, 12$): Kutular yeniden çakışıyor; yoğunluk tekrar artıyor.

Genel yorum: Bir x noktası birden fazla kutunun içine giriyorsa yükseklikler toplanır ve $p_\varphi(x)$ yükselir; hiçbir kutuya girmiyorsa yoğunluk 0 olur. Bu anlamda φ fonksiyonu bir **yerellik mekanizması** işlevi görür: yalnızca x'e yeterince yakın olan veri noktaları $p_\varphi(x)$'e katkı yapar, uzak noktalar tamamen göz ardı edilir.

Parzen yöntemi ile histogram arasındaki temel fark şudur:

- **Histogram:** bölgeler ($\mathcal{R}_i$) sabit ve önceden belirlenmiş; her x hangi kutuya düşüyorsa o kutunun yoğunluğunu alır.
- **Parzen:** her x için pencere *o noktanın etrafına* yeniden kurulur (kayan pencere, sliding window); yoğunluk o noktaya özeldir.

Bu fark sayesinde Parzen yöntemi daha pürüzsüz ve lokal bir yoğunluk kestirimi üretir.

Sonuç

(8) ifadesi, her veri noktasının x'e olan etkisini topladığı için **lokal veri yoğunluklarının ortalaması** olarak yorumlanabilir. Bu formül aynı zamanda **Çekirdek Yoğunluk Kestirimi** (Kernel Density Estimation, KDE) yönteminin kutu çekirdeği (box kernel) ile özel halidir. Farklı çekirdek fonksiyonları (φ yerine Gaussian vb.) seçilirse KDE'nin daha genel biçimleri elde edilir.

6 Parzen Yoğunluğunun Pencere Fonksiyonları

6.1 Pencere Fonksiyonunun Genelleştirilmesi: KDE

Kutu filtresi φ yerine başka fonksiyonlar da kullanılabilir; tek şart bu fonksiyonun negatif olmayan ve integrali 1'e eşit olmasıdır. Bu genel forma **Çekirdek Yoğunluk Kestirimi** (Kernel Density Estimation, KDE) denir:

$$p_K(x) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{h^d} K\left(\frac{x - x_i}{h}\right) \tag{9}$$

Yaygın kullanılan çekirdek fonksiyonları:

Çekirdek	Formül	Özellik
Kutu (Box)	$\varphi(u)$ (5)	Süreksiz, hesabı basit
Gaussian	$\frac{1}{\sqrt{2\pi}} e^{-u^2/2}$	Pürüzsüz, en çok kullanılan
Üçgen (Triangular)	$(1 - \lvert u \rvert)\, \mathbf{1}_{\lvert u \rvert \leq 1}$	Basit, pürüzsüz

Önemli

Çekirdek türü seçimi genellikle yoğunluk kestiriminin kalitesini çok etkilemez; asıl önemli parametre her zaman **bant genişliği** h'dir (bandwidth). h küçük seçilirse kestirim çok dalgalı (düşük yanlılık, yüksek varyans), büyük seçilirse çok düzgün (yüksek yanlılık, düşük varyans) olur.

6.2 Hiperküp (Box) Kernel'in Dezavantajı

Hiperküp pencere fonksiyonu φ hesaplaması ve anlaşılması kolay bir yaklaşım sunar; ancak temel bir sorunu vardır: **pencere içindeki tüm noktalara eşit katkı payı verir.**

Temel problem. x noktasının yakınında x_1, daha uzağında x_2 olmak üzere iki veri noktası olsun. Her ikisi de x merkezli pencerenin içine giriyorsa:

$$\varphi\left(\frac{x - x_1}{h}\right) = \varphi\left(\frac{x - x_2}{h}\right) = 1$$

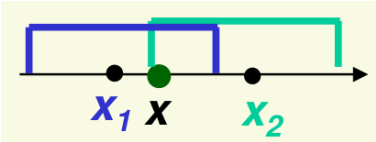

Şekil 12: Aynı pencere içindeki iki farklı noktanın katkısı. x_1 noktası x'e çok yakın, x_2 ise daha uzaktadır. Buna karşın her ikisi de $\varphi = 1$ katkısı yapar.

Şekil 12'de görüldüğü gibi x_1 noktası x'e çok yakınken x_2 sınıra yakın konumdadır. Sezgisel olarak x_1'in $p_\varphi(x)$'e daha fazla katkı yapması beklenirdi; oysa kutu kernel her iki noktaya da aynı ağırlığı (1) verir. **Mesafe bilgisi tamamen göz ardı edilmektedir.**

Önemli

Kutu kernel şu kaba kuralı uygular: *"Pencere içindeysen 1, dışındaysan 0."* Ara değer yoktur; x'e 0.01 birim uzaklıktaki nokta da, $h/2$ uzaklıktaki nokta da aynı katkıyı yapar.

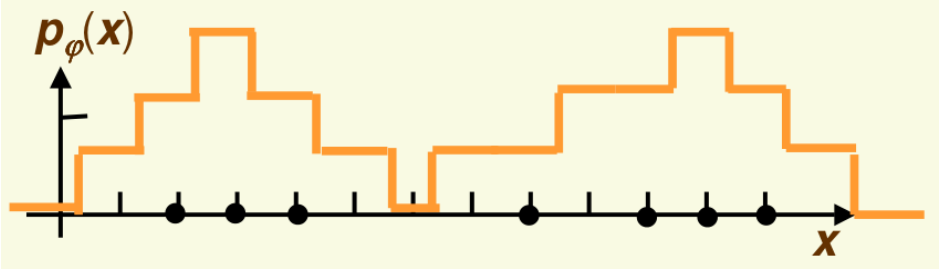

Şekil 13: Kutu kernel ile elde edilen $p_\varphi(x)$ eğrisi. Basamaklı (step-like) yapı ve ani sıçramalar, bir veri noktasının pencere içine girmesi veya çıkmasıyla oluşur.

Yoğunluk eğrisine yansıması. Şekil 13'deki turuncu eğri, kutu kernel ile elde edilen $p_\varphi(x)$'i göstermektedir. Eğri **basamaklı** (step-like) bir yapıya sahiptir:

- Yeni bir veri noktası x'in penceresine girdiği anda yoğunluk bir anda artar.
- Pencereden çıktığı anda bir anda düşer.
- Sonuç: **süreksizlikler** (discontinuities) içeren, gerçek dağılımı iyi temsil etmeyen kaba bir eğri.

Sonuç

Hiperküp (box) kernel basit ve hızlıdır; ancak mesafe bilgisini kullanmadığından keskin, basamaklı ve gerçekçi olmayan bir yoğunluk eğrisi üretir. Bu nedenle uygulamada genellikle **Gaussian** gibi pürüzsüz (smooth) kernel fonksiyonları tercih edilir. Gaussian kernel, pencere içindeki her noktaya uzaklığına göre azalan bir ağırlık verir; böylece hem süreksizlik sorunu ortadan kalkar hem de mesafe

bilgisi korunur.

6.3 Ünite Özeti

Bu ünitede parametrik olmayan yoğunluk kestiriminin temelleri işlendi.

Sonuç

Parametrik olmayan yöntemler, dağılım formu hakkında hiçbir varsayım gerektirmeden eğitim verisinden yoğunluk kestirimi yapabilir. Yeterli veri sağlandığında hem Parzen pencereleri hem de k-NN gerçek yoğunluğa yakınsar. Her iki yöntemin performansı da bölge boyutunu belirleyen hiperparametrenin (h veya k) iyi seçilmesine bağlıdır.