BLM0462 – Örüntü Tanıma

(Pattern Recognition)

Ünite 4

Parametrik Olmayan Yöntemler

(Non-Parametric Methods)

Prof. Dr. Turgay Tugay BİLGİN

Bilgisayar Mühendisliği Bölümü

3. Sınıf Ders Notu

Kaynak: Duda, Hart & Stork, *Pattern Classification*, Bölüm 4

1 Parzen Pencereleri: Gaussian Çekirdeği

Parzen pencereleri yönteminde kritik seçim, pencere fonksiyonu φ'nin nasıl tanımlandığıdır. Önceki bölümlerde kullanılan **hiperküp (box) fonksiyonu**, basit olmasına rağmen ciddi sınırlamalara sahipti. Bu bölümde, bu problemi çözen en yaygın yaklaşım olan **Gaussian (normal dağılım) çekirdeği** ele alınır.

1.1 Genel Parzen Formülü (Hatırlatma)

Yoğunluk kestirimi şu şekilde yazılır:

$$p_\varphi(x) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{h^d} \varphi\left(\frac{x - x_i}{h}\right) \tag{1}$$

Bu formülde:

- x_i: veri noktaları
- h: pencere genişliği (bandwidth)
- d: boyut (dimension)
- φ: çekirdek (kernel) fonksiyonu

Bu yapı aslında her veri noktasının x noktasına yaptığı katkıyı toplar.

1.2 Gaussian Çekirdek Tanımı

Kutu fonksiyonu yerine önerilen seçim:

$$\varphi(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2} \tag{2}$$

Bu ifade, standart normal dağılımın yoğunluk fonksiyonudur.

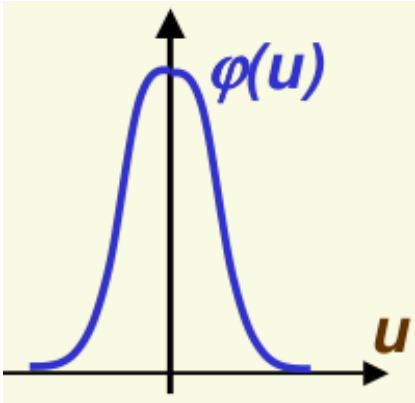

Şekil 1: Gaussian çekirdek fonksiyonu $\varphi(u)$. Çan şeklinde, $u = 0$'da maksimum değerini alır ve uzaklaştıkça yumuşak şekilde azalır. Hiçbir noktada ani kesilme yoktur.

$\varphi(u)$ fonksiyonunun temel özellikleri şunlardır:

- Eğri **çan şeklindedir** (bell-shaped).
- En yüksek değer $u = 0$'da elde edilir.
- $|u|$ arttıkça değer **yumuşak şekilde azalır**.
- Hiçbir noktada ani kesilme yoktur.

Bu özellikler şu anlama gelir: x, x_i'ye çok yakınsa katkı yüksektir; uzaklaştıkça katkı giderek azalır, ama hiçbir zaman aniden sıfıra düşmez.

1.3 Box Kernel ile Fark

Önceki yaklaşım olan hiperküp (box) kernel ile Gaussian kernel arasındaki temel farklar şöyle özetlenebilir:

Box Kernel	**Gaussian Kernel**
Pencere içinde $\to 1$	Sürekli değer üretir
Pencere dışında $\to 0$	Mesafeye duyarlıdır
Mesafe bilgisi yok	Yakınlık arttıkça katkı artar

Bu fark, Gaussian kernel ile elde edilen modelin çok daha gerçekçi davranmasını sağlar.

1.4 İki Temel Problemi Nasıl Çözüyor?

1. Mesafe duyarsızlığı problemi. Box kernel, pencere içindeki yakın ve uzak noktaya aynı ağırlığı veriyordu. Gaussian kernel ise yakın noktalara daha fazla ağırlık verir, uzak noktaların etkisi doğal olarak azalır. Böylece daha anlamlı bir yoğunluk tahmini oluşur.

2. Süreksizlik problemi. Box kernel ile elde edilen yoğunluk eğrisi basamaklı (step-like) bir yapıdaydı ve ani sıçramalar içeriyordu. Gaussian kernel ise **pürüzsüz (smooth)** bir yoğunluk fonksiyonu üretir; sonuç sürekli ve türevlenebilir bir yapıdadır. Bu sayede elde edilen kestirim, gerçek dağılımlara çok daha yakındır.

Sonuç

Gaussian kernel kullanıldığında yoğunluk fonksiyonu daha stabil olur, gürültüye daha dayanıklı hale gelir ve gerçek dağılımı daha iyi yakalar. Bu nedenle uygulamada en sık tercih edilen çekirdek fonksiyonu Gaussian çekirdeğidir.

2 Parzen Pencereleri: Gaussian Çekirdek ile Örnek

Bu bölümde Parzen yöntemi ile Gaussian çekirdeğin birlikte nasıl çalıştığı somut bir örnek üzerinden gösterilmektedir.

2.1 Verilenler

- Veri kümesi: $D = \{2, 3, 4, 8, 10, 11, 12\}$
- Toplam örnek sayısı: $n = 7$
- Pencere genişliği: $h = 1$

Kullanılan formül ($h = 1$ olduğu için ölçekleme sadeleşir):

$$p_\varphi(x) = \frac{1}{7} \sum_{i=1}^{7} \varphi(x - x_i) \tag{3}$$

2.2 Görselin Okunması

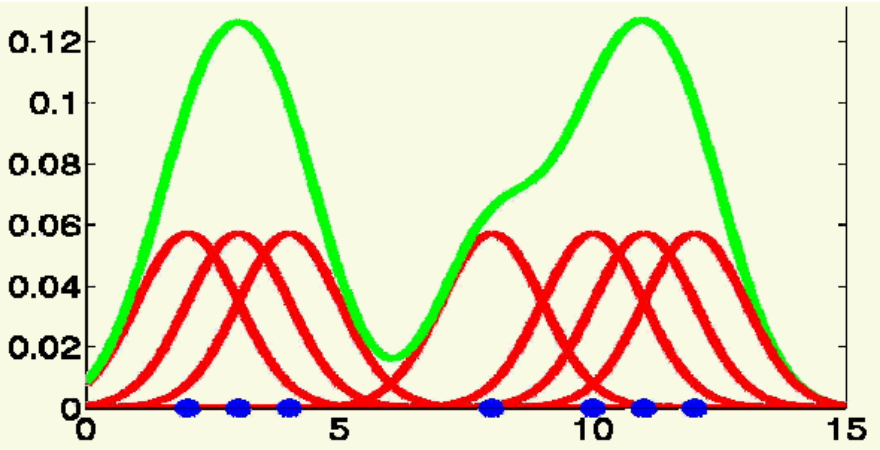

Şekil 2: Gaussian çekirdek ile Parzen yoğunluk kestirimi. Kırmızı eğriler her veri noktasına ait bireysel Gaussian fonksiyonlarını, yeşil eğri ise bunların toplamından elde edilen $p_\varphi(x)$ kestirimini göstermektedir. Mavi noktalar veri örnekleridir.

Grafikte iki önemli bileşen vardır:

(a) Kırmızı eğriler. Her biri bir veri noktasına (x_i) karşılık gelir. Her x_i için bir Gaussian çizilmiştir ve tepe noktaları veri noktalarının üzerindedir (2, 3, 4, 8, 10, 11, 12). Yani her veri noktası kendi etrafında bir "yayılmış etki" oluşturur.

(b) Yeşil eğri. Tüm kırmızı eğrilerin toplamıdır. Bu, tahmin edilen yoğunluk fonksiyonu $p_\varphi(x)$'e karşılık gelir.

2.3 Yoğunluk Nasıl Oluşuyor?

Yöntem şu şekilde çalışır:

1. Her veri noktası bir Gaussian fonksiyonu üretir.
2. Bu fonksiyonlar üst üste toplanır.
3. Sonuçta pürüzsüz bir yoğunluk eğrisi elde edilir.

Bir bölgede çok veri noktası varsa Gaussian'lar üst üste biner ve toplam yükselir. Veri seyrekse eğriler az örtüşür ve yoğunluk düşer.

Grafikte bu durum açıkça görülmektedir:

- $x \approx 2, 3, 4$ civarında birinci tepe oluşur.
- $x \approx 10, 11, 12$ civarında ikinci bir tepe oluşur.
- Arada ($x \approx 5$–7 civarı) veri olmadığından çukur meydana gelir.

2.4 Matematiksel Anlam

Formül açık biçimde yazıldığında:

$$p_\varphi(x) = \frac{1}{7}\Big[\varphi(x-2)+\varphi(x-3)+\varphi(x-4)+\varphi(x-8)+\varphi(x-10)+\varphi(x-11)+\varphi(x-12)\Big]$$

Her terim bir veri noktasının x'e olan katkısını ifade eder; toplam ise tüm veri noktalarının birleşik etkisini verir.

2.5 Bu Yaklaşımın Önemi

Gaussian çekirdek kullanıldığında artık box kernel'deki gibi sert sınırlar yoktur; sürekli ve pürüzsüz (smooth) bir yapı elde edilir. Model, veri yoğunluğunun nerede arttığını ve nerede azaldığını doğal bir biçimde öğrenir.

Sonuç

Parzen yöntemi Gaussian çekirdek ile her veri noktasını bir dağılıma dönüştürür, bu dağılımları toplar ve sonuçta pürüzsüz bir yoğunluk fonksiyonu üretir. Verinin yoğun olduğu bölgelerde Gaussian'lar üst üste binerek tepe noktaları oluşturur; seyrek bölgelerde ise yoğunluk doğal olarak düşer.

2.6 Pencere Genişliği ve Örnek Sayısının Etkisi

Bu alt bölümde Parzen yönteminin bilinen bir gerçek yoğunluk fonksiyonu üzerinde farklı h ve n değerleri ile nasıl davrandığı incelenir. Burada gerçek dağılım olarak

standart normal dağılım $N(0,1)$ kullanılmaktadır. Hatırlatma: $N(\mu, \sigma^2)$ genel normal dağılımın $\mu = 0$ ve $\sigma^2 = 1$ özel halidir; yani ortalaması sıfır, varyansı bir olan simetrik çan eğrisidir.

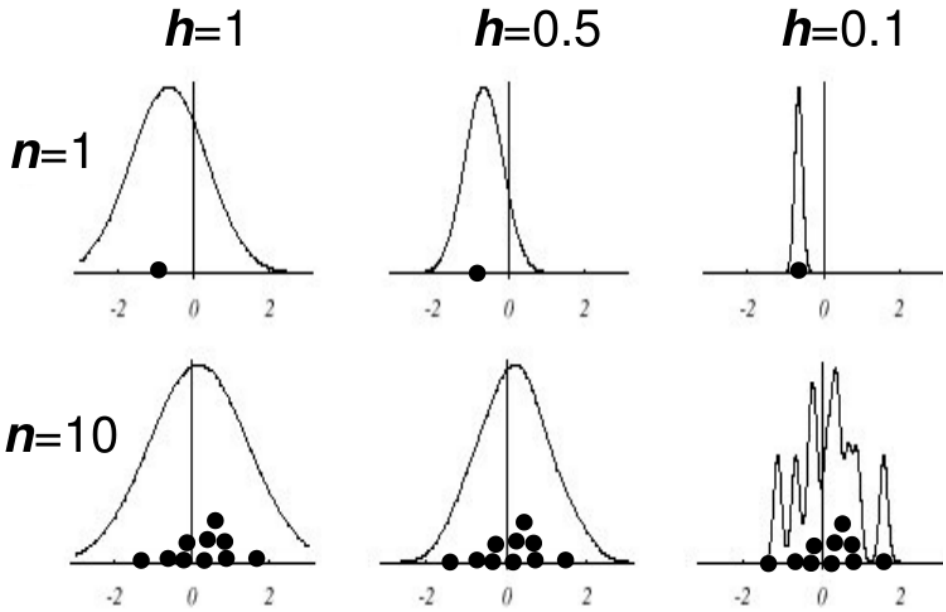

Şekil 3: Parzen yoğunluk kestirimi: örnek sayısı n ve pencere genişliği h'nin etkisi. Satırlar örnek sayısını ($n = 1$ ve $n = 10$), sütunlar pencere genişliğini ($h = 1$, 0.5, 0.1) göstermektedir. Gerçek dağılım $N(0,1)$'dir.

Görselde iki parametre değişmektedir:

- **Satırlar:** örnek sayısı n (üstte $n = 1$, altta $n = 10$)
- **Sütunlar:** pencere genişliği h (1, 0.5, 0.1)

Üst sıra ($n = 1$). Tek bir veri noktası bulunmaktadır. h küçüldükçe yoğunluk kestirimi bu tek noktaya aşırı daralır ve gerçek dağılımı temsil edemez hale gelir.

Alt sıra ($n = 10$). Daha fazla veri mevcuttur. Pencere genişliğine göre üç farklı davranış gözlenir:

- $h = 1$: Kestirim çok düzgün ancak fazla yayılmış durumdadır (over-smoothing). Detaylar kaybolur.
- $h = 0.5$: En iyi dengeyi sağlar; gerçek Gaussian'a en yakın kestirim bu değerle elde edilir.
- $h = 0.1$: Kestirim çok dalgalıdır. Gürültü yüksektir ve modelde aşırı uyum (overfitting) görülür.

Önemli

Bu örnekten çıkarılması gereken temel dersler şunlardır:

- Az veri $\Rightarrow$ model zayıf kalır.
- Çok küçük $h \Rightarrow$ gürültüye duyarlı, dalgalı kestirim.
- Çok büyük $h \Rightarrow$ detay kaybı, aşırı düzleşme.
- Doğru h + yeterli veri $\Rightarrow$ gerçek dağılıma yakın iyi bir tahmin.

2.7 Genişletilmiş Deney: Büyük Örnek Sayıları

Önceki alt bölümde $n = 1$ ve $n = 10$ ile gözlemler yapıldı. Şimdi örnek sayısı $n = 100$ ve $n \to \infty$ durumlarına genişletilerek Parzen yönteminin yakınsama davranışı incelenir. Gerçek dağılım yine standart normal dağılım $N(0, 1)$'dir ($N(\mu, \sigma^2)$ genel formunda $\mu = 0$, $\sigma^2 = 1$).

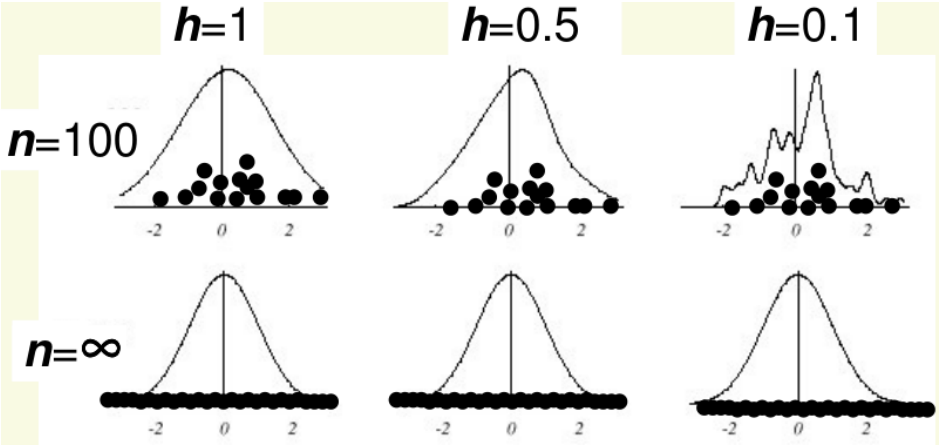

Şekil 4: Parzen yoğunluk kestirimi: genişletilmiş deney. Satırlar örnek sayısını ($n = 100$ ve $n \to \infty$), sütunlar pencere genişliğini ($h = 1$, 0.5, 0.1) göstermektedir. Gerçek dağılım $N(0, 1)$'dir.

Üst sıra ($n = 100$). Veri artık yeterince fazladır. Pencere genişliğine göre davranışlar şöyledir:

- $h = 1$: Kestirim fazla yumuşatılmıştır (over-smoothing); eğri gerçek dağılımdan daha geniş ve basık çıkar.
- $h = 0.5$: En iyi dengeyi sağlar; gerçek Gaussian'a en yakın kestirim bu değerle elde edilir.
- $h = 0.1$: Hala dalgalı bir yapı gözlenir; gürültü etkisi tamamen ortadan kalkmamıştır.

Alt sıra ($n \to \infty$). Veri sayısı sonsuza gittiğinde tüm h değerleri için tahmin gerçek Gaussian dağılıma yakınsar. Artık h'nin etkisi ortadan kalkar; hangi pencere genişliği seçilirse seçilsin sonuç aynı gerçek dağılıma ulaşır.

Sonuç

Bu deneylerden çıkan temel mesaj şudur:

- Yeterince veri sağlandığında Parzen yöntemi gerçek yoğunluğu öğrenir. Hatta h farklı olsa bile sonuç aynı olur (yakınsama, convergence).
- Az veya orta miktarda veri varsa h seçimi çok kritiktir ve modelin başarısını doğrudan belirler.
- Çok veri olduğunda yöntem garantili olarak doğru yoğunluğa yakınsar.

3 Parzen Pencerelerinde Pencere Genişliği h

3.1 h Neyi Kontrol Ediyor?

Pencere genişliği h, "yoğunluk bu bölgede sabit" varsayımının yapıldığı aralığın büyüklüğünü belirler. Başka bir deyişle h, ne kadar geniş bir bölgede ortalama aldığımızı kontrol eder.

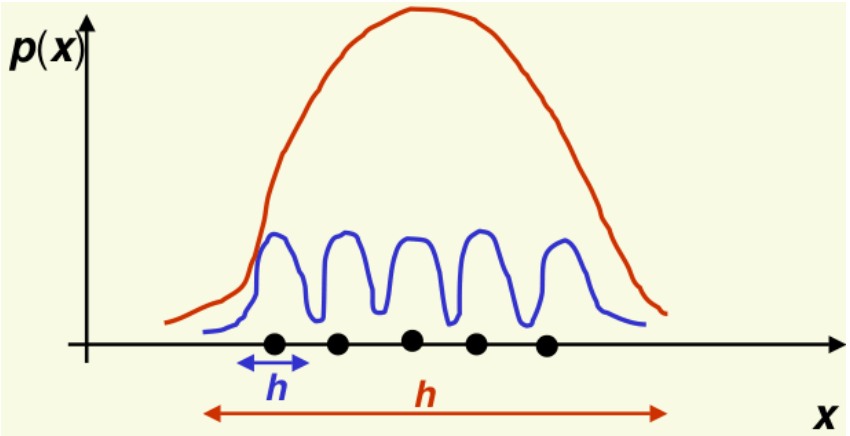

Şekil 5: Pencere genişliği h'nin etkisi. Kırmızı eğri gerçek yoğunluğu, siyah noktalar veri örneklerini göstermektedir. Küçük h (mavi) dar bir etki alanı oluşturarak dalgalı bir kestirim üretirken, büyük h geniş bir alanı kapsayarak aşırı düzleşmiş bir kestirime yol açar.

Şekil 5'deki görselde iki farklı h değerinin sonuçları karşılaştırılmaktadır:

Küçük h (mavi eğri). Her veri noktası yalnızca çok dar bir bölgede etkilidir. Sonuç olarak dalgalı, zıplayan bir eğri elde edilir.

Büyük h (kırmızı ok ile gösterilen geniş aralık). Veri noktaları geniş bir alanı etkilemektedir. Sonuç olarak aşırı düzleşmiş bir eğri ortaya çıkar.

Bu görselin vermek istediği mesaj şudur: h aslında ne kadar lokal baktığımızı belirler.

3.2 Küçük h Durumu

Pencere genişliği küçük seçildiğinde her veri noktası dar bir etki alanına sahip olur. Ortaya çıkan yapıda çok sayıda keskin tepe gözlenir. Bu durumun problemleri şunlardır:

- Gürültüye aşırı duyarlılık (yüksek varyans).
- Aşırı uyum (overfitting): model veriyi ezberler, genelleme yapamaz.

3.3 Büyük h Durumu

Pencere genişliği büyük seçildiğinde her veri noktası geniş bir alanı etkiler. Ortaya çıkan yapı yumuşak ancak fazla düzdür. Bu durumun problemleri şunlardır:

- Detay kaybı (yüksek yanlılık).
- Yetersiz uyum (underfitting): model gerçek yapıyı kaçırır.

3.4 Asıl Problem ve Kritik Çıkarım

Pratikte gerçek dağılım bilinmemektedir. Dolayısıyla "yoğunluk nerede sabit?" sorusu belirsizdir ve doğru h değerini seçmek güçtür. Üstelik tek bir "en iyi h" her zaman mevcut değildir; farklı bölgelerde farklı h değerleri gerekebilir.

Sonuç

- Küçük $h \Rightarrow$ gürültüye duyarlı, dalgalı kestirim.
- Büyük $h \Rightarrow$ aşırı düzleşme, detay kaybı.
- Doğru $h \Rightarrow$ veri ile genelleme arasında denge.

Bu nedenle pratikte h genellikle **veriden öğrenilir** (model selection). En yaygın yöntem çapraz doğrulamadır (cross-validation).